


Otimização em Engenharia de Software

(Search-Based Software Engineering)

Introdução a Metaheurísticas



Prof. Thelma Elita Colanzi
thelma@din.uem.br

Metaheurística

*Combinação de duas palavras gregas: **heuriskein**, que significa “encontrar”, e o sufixo **meta** significando “além, em um nível mais alto”.*

Refere-se a uma estratégia inteligente de **alto nível** que guia um processo de busca, explorando **eficientemente** um espaço de soluções a procura de soluções ótimas ou **sub-ótimas**.

Exemplos de Metaheurísticas

Mono-objetivas **Algoritmos Genéticos**

Têmpera Simulada

GRASP

Multi-objetiva **NSGA-II** (até 3 objetivos)

NSGA-III (4+ objetivos)



Algoritmos Genéticos




Introdução

Método de busca inspirado na **Teoria da Evolução Natural** de Charles Darwin

Introduzido por John Holland (1975) e popularizado por um dos seus alunos, David Goldberg (1989).

- Naturalista Britânico
- 1859 – Livro “A Origem das Espécies”
- Conceitos Fundamentais
 - Evolução é natural
 - Seleção Natural
 - Sobrevivência dos mais Adaptados
 - Propagação genética
 - Mutação



Charles Darwin (1809 – 1882)

```
procedimento ALGORITMO_GENÉTICO()  
  cria_população_inicial(P);  
  repita  
    P' ← avaliação_da_população(P);  
    P'' ← seleção_dos_pais (P');  
    P' ← recombinação_dos_pais(P'');  
    P' ← mutação(P'');  
    P ← P';  
  enquanto condição de parada não for atingida  
fim ALGORITMO_GENÉTICO
```

Pseudocódigo
do
Algoritmo
Genético

Representação Genética

Um AG processa populações de cromossomos.

Um cromossomo é uma estrutura de dados, geralmente vetor ou cadeia de bits (cadeia de bits é a estrutura mais tradicional, porém nem sempre a melhor), que representa uma possível solução do problema a ser otimizado.

O primeiro passo para resolver um problema utilizando AGs é representar uma possível solução deste problema na forma de um cromossomo.

População Inicial

Um Algoritmo Genético começa com uma população inicial de N cromossomos.

Essa população pode ser gerada de forma aleatória ou a partir de conhecimentos prévios do problema.

O tamanho da população inicial deve ser determinado de acordo com cada problema.

Seleção

Inspirado no processo de seleção natural de seres vivos.

O AG seleciona os melhores cromossomos (aqueles de alta aptidão) com maior probabilidade para gerar cromossomos filhos (que são variantes dos pais) através dos operadores de crossover e mutação.

Métodos de Seleção

Método da Roleta

- Seleciona um cromossomo com probabilidade proporcional a sua aptidão.

Método de Torneio

- Seleciona um cromossomo a partir de competições, normalmente envolvendo dois cromossomos.

Cruzamento (ou *Crossover*)

Processo de combinação de dois cromossomos para a geração de dois filhos.

Garante a propagação de material genético.

Respeita uma Taxa de Cruzamento (entre 60 e 90%) determinada *a priori*.

Métodos de Cruzamento

Cruzamento de 1 ponto

- ...

Cruzamento de 2 pontos

- ...

Mutação

Processo de alteração genética aleatório.

Permite a adição de material genético inédito.

Respeita uma Taxa de Mutação (até 5%) determinada *a priori*.

Calibragem dos Parâmetros

Tamanho da População

Número de Populações

Taxa de Reprodução

Taxa de Mutação

Critério de Parada

Alternativas

- Número de Gerações
- Qualidade da Solução
- Ausência de Evolução
- Tempo



NSGA-II



Introdução

AG multi-objetivo desenvolvido em Deb et al. (2000)


Utiliza dois algoritmos de ordenação

1. Non-dominated Sorting Algorithm

Busca por soluções próximas a Fronteira de Pareto

2. Crowding Distance Sorting

Busca por soluções bem distribuídas no espaço



Non-dominated Sorting

Para cada solução calcula-se quantas outras soluções a dominam e quais soluções são dominadas por ela

Faz-se um ciclo no qual a cada iteração são retiradas as soluções que não são dominadas e diminui-se o contador das soluções dominadas por estas que foram retiradas


A cada ciclo, uma nova fronteira é criada com as soluções retiradas do conjunto

Crowding Distance Sorting

Utiliza uma função de cálculo de distância entre soluções que estejam na mesma fronteira para garantir um melhor fitness àquelas que estejam em áreas menos povoadas no espaço de busca.

Para cada função objetivo as soluções com valores extremos são classificadas como tendo distância infinita.

As outras soluções tem sua distância recalculada de acordo com uma fórmula normalizada que utiliza a diferença de valores para esta solução e as duas mais próximas a ela.



Referências

T. Baeck, D.B. Fogel, e Z. Michalewicz (eds.). Evolutionary Computation 2: Advanced Algorithms and Operators. Institute of Physics Publishing, 2000.

C. A. C. Coello, G.L. Lamont, e D.A. van Veldhuizen. Evolutionary Algorithms for Solving Multi-Objective Problems. Genetic and Evolutionary Computation. Springer, Berlin, Heidelberg, 2nd edition, 2007.

T. E. Colanzi, W. K. G. Assunção, S. R. Vergilio, P. R. Farah, G. Guizzo: The Symposium on Search-Based Software Engineering: Past, Present and Future. Inf. Softw. Technol. 127: 106372, 2020.

K. Deb, A. Pratap, S. Agarwal, e T. Meyarivan. A fast and elitist multiobjective genetic algorithm: NSGA-II. IEEE Transactions on Evolutionary Computation, 6(2):182 {197, abril de 2002.

Goldberg, D. Genetic Algorithms in Search, Optimization and Machine Learning. Addison-Wesley Longman Publishing Co., 1989.

HARMAN, M.; MANSOURI, A.; ZHANG, Y. Search Based Software Engineering: Trends, Techniques and Applications. ACM Computing Surveys. 45(1): Article 11, 2012.

HARMAN, M.; MCMINN, P.; SOUZA, J. T.; YOO, S. Search Based Software Engineering: Techniques, Taxonomy, Tutorial. Lecture Notes in Computer Science, v. 7007, p. 1-59, 2012.

Obrigada!

Thelma Elita Colanzi

Universidade Estadual de Maringá (UEM)
thelma@din.uem.br

