Indicadores de qualidade

Resumo aplicado: oito configurações, uma arquitetura



Prof. Dr. João Choma

Universidade Estadual de Maringá - DIN/CTC

github.com/JoaoChoma

Maringá

A pergunta do experimento

Qual configuração produz melhores soluções para a mesma arquitetura?

- Comparar NSGA-III e R-NSGA-III, com duas opções de elitismo e duas de tratamento de restrições.
- Executar as oito configurações sob o mesmo orçamento e condições comparáveis.
- Medir a qualidade de cada execução e a variação entre execuções.
- Concluir quanto uma configuração melhora e com qual incerteza.

Roteiro: indicadores → amostras → descrição e pressupostos → testes → interpretação. O caso das imagens orienta a aula. Os valores e gráficos numéricos seguintes são didáticos; não são resultados reais desse experimento.

O desenho: $2 \times 2 \times 2 = 8$ configurações



Configuração	Algoritmo	Elitismo	Restrição
C1	NSGA-III	ON	PENALTY
C2	NSGA-III	OFF	PENALTY
C3	R-NSGA-III	ON	PENALTY
C4	R-NSGA-III	OFF	PENALTY
C5	NSGA-III	ON	KILL
C6	NSGA-III	OFF	KILL
C7	R-NSGA-III	ON	KILL
C8	R-NSGA-III	OFF	KILL

10 execuções por configuração = 80 execuções. ON/OFF refere-se à opção de elitismo definida na implementação. PENALTY penaliza inviáveis; KILL os descarta, conforme o protocolo.

Objetivos da busca e indicadores do resultado

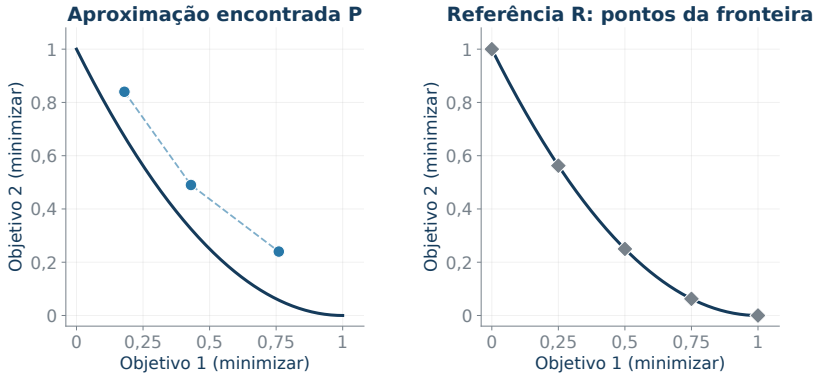


Objetivo arquitetural do exemplo	Direção
Acoplamento	Minimizar
Coesão	Maximizar
Overhead de rede	Minimizar
Modularização de funcionalidade	Maximizar
Reúso	Maximizar

Os **objetivos** avaliam cada arquitetura candidata. **HV e IGD+** avaliam o conjunto de compromissos retornado por uma execução.

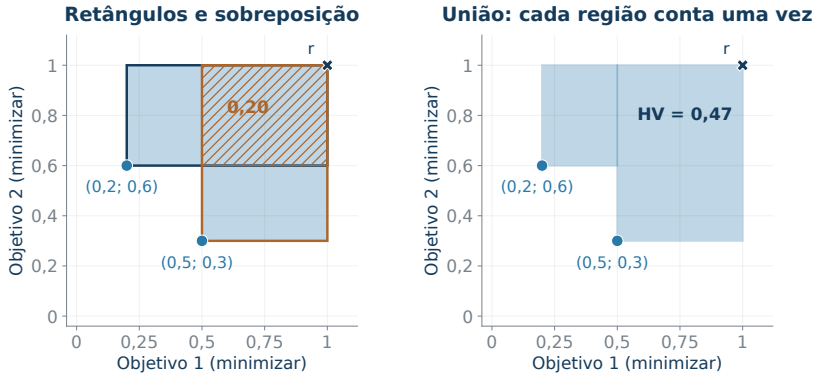
Defina a fórmula e a unidade de cada objetivo. Converta as direções e normalize com a mesma régua para todas as configurações. Fixe a referência e a regra para falhas antes da comparação.

Pareto: fronteira verdadeira e aproximação



A curva é a **fronteira verdadeira** do problema didático: nenhum ponto viável a domina. P é uma aproximação encontrada; R é uma amostra da fronteira conhecida. Em problemas reais, uma referência empírica reúne bons resultados, mas não prova otimalidade. Aqui, ambos os objetivos são minimizados.

HV: quanto espaço o conjunto domina?



Maior é melhor. Com r = (1; 1), a união dos retângulos vale $\mathbf{0{,}32 + 0{,}35 - 0{,}20 = 0{,}47}$. A sobreposição conta uma vez. HV dispensa a fronteira verdadeira, mas exige a mesma escala e referência em todas as comparações.

Quais medidas realmente precisamos?

Medida	O que acrescenta	Cuidado
HV	Região dominada pelo conjunto	Escala e ponto de referência comuns
IGD+	Representação do conjunto de referência	Referência comum e bem definida
GD / IGD	Proximidade / cobertura por distâncias	GD $= 0$ não garante cobertura
Épsilon aditivo	Pior lacuna frente à referência	Menor é melhor; depende da escala
Sucesso e custo	Frequência de atingir a meta e esforço	Registrar falhas e timeouts

Neste experimento: HV primário e IGD+ complementar. Defina a prioridade antes de ver os resultados. Não escolha o indicador que favoreceu o algoritmo desejado.

Amostra: o que conta como observação?



Uma execução gera um valor de HV e um valor de IGD+. Assim, cada indicador tem oito grupos de 10 observações.

- As soluções de uma execução pertencem ao mesmo conjunto; não são réplicas independentes do indicador.
- Reinicie o estado, registre sementes e evite interferência entre execuções.
- A mesma arquitetura e o mesmo índice na planilha não criam pareamento entre execuções.
- As 10 repetições são um ponto de partida: suficiência depende da precisão, variabilidade e efeito relevante.

A conclusão vale para essa arquitetura e esse protocolo. Mais execuções não substituem diversidade de arquiteturas.

Organização dos dados



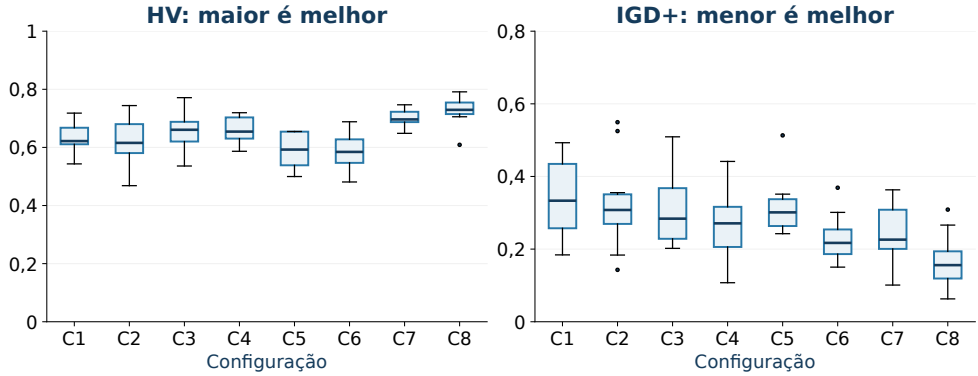
Formato recomendado: uma linha por execução. Exemplo fictício:

Arquitetura	Configuração	Execução	HV	IGD+	Status
S1	C1	1	0,71	0,34	OK
S1	C1	2	0,68	0,37	OK
S1	C2	1	0,65	0,39	OK
S1	C8	1	0,80	0,21	OK

Registre também algoritmo, elitismo, restrição, semente, orçamento e tempo. Preserve as soluções que originaram os indicadores.

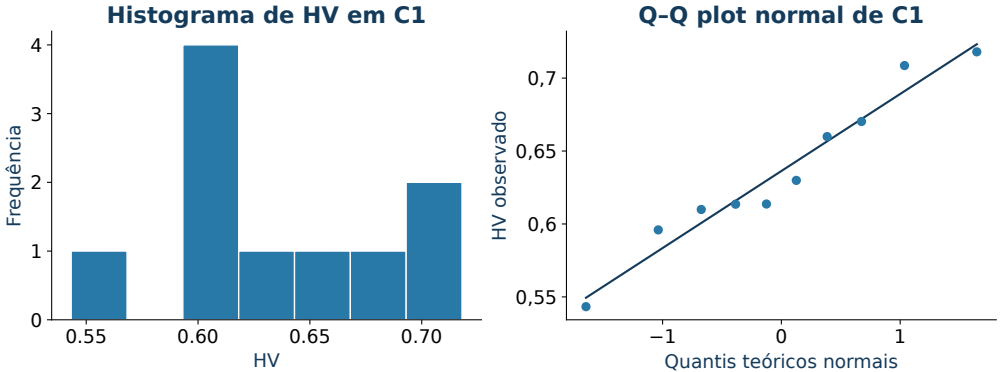
A análise separa HV de IGD+, mas mantém a identificação da execução. Não apague falhas para melhorar a média; documente seu tratamento.

Descrever antes de testar



Dados sintéticos, 10 execuções por grupo. A linha central indica a mediana; a caixa vai de Q1 a Q3 e IQR = Q3 − Q1. Os bigodes seguem a regra de 1,5 IQR. Compare localização, dispersão e extremos; a ordenação visual não demonstra significância. Relate também média, desvio-padrão e número de falhas.

Normalidade: olhar a variável certa



Exemplo sintético de uma configuração. O histograma mostra a forma; o Q–Q plot compara os quantis observados aos de uma normal. Na ANOVA, examine erros/resíduos e distribuições por grupo. No t pareado, examine as diferenças. Não misture as oito configurações para "testar normalidade".

Shapiro–Wilk e Levene: diagnósticos

Teste	Hipótese nula	O que examina
Shapiro–Wilk	Distribuição normal	Forma da distribuição
Levene	Variâncias iguais	Dispersão entre grupos

Com $\alpha = 0{,}05$: $\mathbf{p \leq 0{,}05}$ traz evidência contra H0; $\mathbf{p > 0{,}05}$ não a rejeita, mas não comprova o pressuposto.

Use gráficos, tamanho da amostra e conhecimento do experimento. Amostras pequenas podem esconder desvios; grandes podem detectar desvios pouco relevantes. **$\mathbf{n = 10}$ não torna os dados normais.**

Independência vem do desenho experimental; nenhum desses testes a verifica.

Teste global para oito grupos independentes



Pergunta e condições	Método candidato
Comparar médias; erros adequados ao modelo e variâncias semelhantes	ANOVA de uma via
Comparar médias; variâncias diferentes e inferência de médias adequada	ANOVA de Welch
Comparar distribuições por postos, com inferência apropriada	Kruskal–Wallis

Na ANOVA, **H0: todas as médias são iguais**. Em Kruskal–Wallis, igualdade de distribuições é a hipótese nula usual; interpretar como medianas exige condições adicionais de forma e dispersão.

Shapiro não escolhe sozinho o teste. Assimetria ou extremos graves podem exigir outro modelo ou método robusto que preserve a pergunta de interesse.

Comparar configurações ou explicar fatores?



Oito grupos: pergunta "quais configurações diferem?". ANOVA de uma via ou outra análise entre grupos responde a essa comparação.

Desenho fatorial $2 \times 2 \times 2$: pergunta "qual o efeito de algoritmo, elitismo e restrição, e como interagem?". Use modelo fatorial com interações e pressupostos adequados.

Interação: o benefício de ligar elitismo pode depender do algoritmo ou do tratamento de restrições. Uma média geral pode esconder isso.

Com várias arquiteturas, preserve os blocos ou a hierarquia. Friedman é candidato para postos dos algoritmos nos mesmos blocos independentes; não para tratar as 80 execuções em S1 como 80 arquiteturas.

Pós-hoc e múltiplas comparações

Análise global planejada	Comparações específicas usuais
ANOVA clássica	Tukey HSD
ANOVA de Welch	Games–Howell
Kruskal–Wallis	Dunn com ajuste planejado

O teste global não informa quais pares diferem. Oito grupos geram **28 pares por indicador**. Defina a família de comparações e o protocolo de pós-hoc antes da análise. **Holm** controla a chance de algum falso positivo na família. **BH/FDR** controla a proporção esperada de falsos entre os rejeitados, sob suas condições. Tukey já trata multiplicidade entre pares: não aplique BH novamente por rotina.

Significância, magnitude e incerteza

p-value: sob H0 e o modelo, probabilidade de uma estatística tão extrema quanto a observada ou mais. Não é a probabilidade de H0 ser verdadeira.

Exemplo hipotético: diferença média de HV = 0,03; IC de 95% = [0,01; 0,05].

- Há indicação de ganho positivo, mas o tamanho ainda é incerto.
- Se o ganho mínimo útil é 0,02, o intervalo inclui melhorias menores que o desejado.
- Um p pequeno não garante utilidade prática.
- Um p grande não prova igualdade ou equivalência.

Relate sempre **diferença estimada + intervalo + teste**, no contexto da arquitetura e do orçamento.

Tamanho de efeito: Vargha–Delaney A



Para grupos independentes e HV, em que maior é melhor:

```
A_BA = (vitórias de B + 0,5 × empates) / (n_B × n_A)
```

Exemplo: A = [1; 2; 3] e B = [2; 3; 4]. Nos nove pares cruzados, B tem seis vitórias, dois empates e uma derrota: **$\hat{A}_{BA} = 7/9 \approx 0{,}778$**.

A medida estima a chance de B superar A, dando meio peso a empates. **0,778 não significa "77,8% melhor".** Para IGD+, conte como vitória o menor valor.

$\hat{A} = 0{,}5$ indica equilíbrio nessa medida, não distribuições idênticas. Apresente também diferenças na escala original e incerteza.

Como apresentar a conclusão



Tabela por configuração e indicador: n válido, falhas, mediana, IQR, média e desvio-padrão. Mostre boxplots ou pontos individuais.

Tabela por comparação planejada: diferença estimada, intervalo, p ajustado e tamanho de efeito.

Texto da conclusão: qual configuração se destacou, quanto melhorou e sob quais condições. Se HV e IGD+ discordarem, explique o compromisso; não esconda a divergência.

As imagens não fornecem as 80 execuções. Portanto, não permitem calcular os testes nem declarar uma vencedora real.

Protocolo essencial do experimento



1. Definir a arquitetura, as oito configurações e o mesmo orçamento.
2. Fixar HV e IGD+, normalização, referências e regra para falhas.
3. Coletar execuções independentes e justificar o tamanho amostral.
4. Descrever resultados e avaliar gráficos, resíduos e variâncias.
5. Aplicar a análise planejada, pós-hoc e controle de multiplicidade.
6. Concluir pela magnitude, incerteza e relevância prática.

A pergunta final: a vantagem é consistente e útil nesta arquitetura, sob este orçamento? O teste apoia essa resposta; ele não substitui o desenho experimental.

Referências para aplicação



- pymoo: HV e indicadores de distância.
- SciPy: Shapiro–Wilk e Levene.
- SciPy: Tukey e Games–Howell.
- scikit-posthocs: Dunn e ajustes.
- statsmodels: modelos fatoriais e interações.
- Vargha e Delaney (2000): tamanho de efeito.

Material de apoio: a versão completa da aula contém cálculos adicionais, outros desenhos e cuidados de interpretação.