Otimização da Modernização de Sistemas Legados para Arquiteturas de Microsserviços

Daniel Arruda de Santana Kananda Caroline Vieira da Silva Luciano Trevisan Alberti
Programa de Pós-Graduação em Ciência da Computação
Departamento de Informática – DIM
Universidade Estadual de Maringá – UEM
Maringá, Paraná, Brasil

***Resumo*—A identificação de microsserviços em sistemas legados é um problema de otimização com objetivos conflitantes, e abordagens interativas colocam o arquiteto dentro do ciclo evolutivo para incorporar suas preferências. Resta saber quanto a configuração do algoritmo afeta o que é devolvido ao decisor. Este trabalho avalia empiricamente a ferramenta *i-toMicroservices* sob oito configurações, resultantes do cruzamento de algoritmo (NSGA-III ou R-NSGA-III), elitismo (ligado ou desligado) e tratamento de restrições (*penalty* ou *kill*). Foram executadas 80 otimizações independentes de 1.000 gerações, em dois sistemas Java de referência, todas conduzidas sob a mesma persona de arquiteto, que intervém em três pontos da evolução. O desempenho foi medido por quatro indicadores (*hypervolume*, IGD+ e a distância euclidiana ao ponto ideal, tomada como média e como mínima), com Kruskal-Wallis, pós-hoc de Dunn com correção de Benjamini-Hochberg e tamanho de efeito de Vargha-Delaney. Na análise por fator isolado, que compara 20 execuções contra 20, apenas o tratamento de restrições separa os resultados: a mediana das configurações com *penalty* é melhor nos quatro indicadores e nos dois sistemas, com diferença significativa em sete das oito combinações de sistema e indicador, enquanto algoritmo e elitismo não são significativos em nenhuma. Nenhuma configuração isolada, contudo, se mostrou superior em todos os cenários. A análise das arquiteturas devolvidas mostra ainda que essa vantagem é acompanhada de microsserviços desbalanceados: de 88% a 100% das arquiteturas finais dessas configurações violam a faixa de tamanho definida pelo problema, contra 0% a 24% das configurações com *kill*. O trabalho conclui que a comparação por indicadores agregados, isoladamente, favorece configurações que admitem soluções inválidas, e reúne sugestões de melhoria para a ferramenta.**

***Index Terms*—Engenharia de software baseada em busca, identificação de microsserviços, otimização interativa, modernização de sistemas legados, NSGA-III, estudo empírico.**

I. Introdução

Sistemas legados monolíticos concentram, em uma única unidade de implantação, responsabilidades que evoluíram por anos sob pressões distintas. A migração desses sistemas para arquiteturas de microsserviços é hoje uma das formas mais procuradas de modernização, mas esbarra em uma decisão difícil: *onde* cortar o monólito. A escolha das fronteiras de cada serviço precisa equilibrar objetivos que competem entre si (reduzir o acoplamento entre serviços sem destruir a coesão interna, limitar o *overhead* de comunicação sem inflar a granularidade, preservar funcionalidade e reúso) e o número de particionamentos possíveis cresce de forma combinatória com o tamanho do sistema. Não há, portanto, uma resposta única a ser calculada: há um conjunto de soluções de compromisso a ser explorado.

Esse é exatamente o tipo de problema que a Engenharia de Software Baseada em Busca (SBSE) trata, reformulando a decisão de projeto como um problema de otimização guiado por uma função de aptidão [1]. Quando os objetivos são conflitantes, formulações multiobjetivo entregam ao decisor um conjunto de alternativas em vez de um único resultado [1], [2]. A abordagem *toMicroservices* [3] aplica essa ideia à identificação de microsserviços a partir de um grafo de dependências entre métodos, otimizando cinco objetivos com o NSGA-III; sua versão interativa, a ferramenta *i-toMicroservices* [4], acrescenta um elemento decisivo: o arquiteto participa da busca, inspecionando soluções e intervindo em pontos pré-definidos da evolução. A otimização deixa de ser um processo fechado e passa a incorporar a preferência de quem vai conviver com a arquitetura resultante, fator que a literatura recente aponta como determinante para a aceitação das soluções em ambientes reais [5].

Essa interatividade, porém, levanta uma questão prática que este trabalho investiga: **a configuração do algoritmo importa, e quanto?** A ferramenta permite variar o algoritmo evolutivo, o uso de elitismo e a forma de tratar soluções inválidas; não é evidente, a priori, qual combinação entrega as melhores fronteiras nem se as soluções devolvidas refletem de fato o que o arquiteto pediu durante a interação.

O objetivo deste trabalho é avaliar empiricamente o comportamento da *i-toMicroservices* sob oito configurações distintas, na perspectiva de uma persona de arquiteto, respondendo a duas questões de pesquisa:

- **RQ1** — Qual configuração teve melhor desempenho em termos de indicadores de qualidade?
- **RQ2** — Os resultados retornados pela ferramenta estão condizentes com as preferências da persona que interagiu durante o processo de otimização?

Para respondê-las, executamos um experimento com dois sistemas Java de referência (*spring-petclinic* e *jpetstore*) e oito configurações, cada uma repetida cinco vezes por sistema, totalizando 80 execuções independentes de 1.000 gerações. Em todas elas, a interação seguiu a mesma persona, **P2-Systematic-Decoupler**, que intervém em três pontos da evolução (30%, 55% e 80% das gerações). O desempenho foi medido por quatro indicadores, derivados de três famílias:

o *hypervolume* (HV) [6], o *Inverted Generational Distance Plus* (IGD+) [7] e a distância euclidiana ao ponto ideal (ED), tomada como média e como mínima sobre a fronteira. As diferenças entre configurações foram avaliadas por testes não paramétricos com correção para comparações múltiplas e tamanho de efeito, seguindo as recomendações para algoritmos randomizados em engenharia de software [8].

As contribuições do trabalho são: (i) uma comparação empírica das oito configurações da *i-toMicroservices* sob uma mesma persona, com teste estatístico e tamanho de efeito; (ii) a constatação de que, entre os três fatores de configuração, é a *estratégia de tratamento de restrições* que separa os resultados (as configurações com *penalty* alcançam medianas melhores nos quatro indicadores e nos dois sistemas, enquanto algoritmo e elitismo não são significativos em nenhuma combinação), acompanhada da ressalva de que essa vantagem vem de arquiteturas que violam a faixa de tamanho admitida pelo problema; e (iii) um conjunto de sugestões de melhoria para a ferramenta, derivadas da própria experiência de uso e de defeitos observados durante as execuções.

O restante do artigo está organizado como segue. A Seção II apresenta a fundamentação teórica. A Seção III descreve a metodologia: sistemas, configurações, persona, indicadores e ameaças à validade. A Seção IV apresenta e discute os resultados. A Seção V reúne sugestões de melhoria para a ferramenta e a Seção VI traz as considerações finais.

II. Fundamentação Teórica

Esta seção reúne os conceitos necessários para situar o experimento. A Seção II-A trata da otimização em engenharia de software: a formulação de decisões de projeto como problemas de busca, o caso multiobjetivo e os dois algoritmos comparados neste trabalho, o NSGA-III e sua variante orientada a pontos de referência, o R-NSGA-III. A Seção II-B trata do problema de aplicação: o que caracteriza um sistema legado monolítico, por que a decomposição em microsserviços é um problema de otimização e como a abordagem *toMicroservices* e sua versão interativa, a *i-toMicroservices*, o resolvem.

A. Otimização em Engenharia de Software

Reformular uma decisão de engenharia de software como um problema de otimização exige três elementos: uma representação das soluções candidatas, uma função que as ordene e operadores que produzam novas candidatas a partir das existentes. As subseções a seguir percorrem esses elementos, do caso geral da SBSE à otimização multiobjetivo e, daí, aos dois algoritmos usados no experimento.

1) Engenharia de Software Baseada em Busca (SBSE): A Engenharia de Software Baseada em Busca (*Search-Based Software Engineering* – SBSE) reformula problemas de engenharia de software como problemas de otimização, que são tratados por técnicas de busca, em especial metaheurísticas [1]. Nesse contexto, o termo "busca" não se refere à recuperação de textos, mas à exploração de um espaço de soluções candidatas, orientada por uma função que distingue as melhores das piores [1]. As primeiras aplicações de otimização à engenharia de software remontam a 1976, na área de testes, enquanto o termo SBSE foi utilizado pela primeira vez em 2001 [1], [9].

Essa abordagem é especialmente útil em problemas com espaços de busca amplos e objetivos concorrentes, nos quais encontrar uma solução ótima de forma exata pode ser inviável [1], [2]. Sua aplicação depende, fundamentalmente, da representação do problema e da definição de uma função de aptidão (*fitness*), à qual se somam os operadores responsáveis por gerar novas soluções [1], [5]. Entre as técnicas mais utilizadas estão os algoritmos genéticos, o *Simulated Annealing* e o *Hill Climbing* [1]. A definição da função de aptidão é uma das etapas mais críticas, pois é ela que conduz a busca em direção às soluções desejadas [2]. Nesse sentido, as métricas de software constituem candidatas naturais para compor essa função [1].

A SBSE tem sido aplicada ao longo de todo o ciclo de vida do software, incluindo requisitos, gerenciamento de projetos, testes, projeto e manutenção [1]. No projeto e na reestruturação de sistemas, um problema amplamente estudado é o agrupamento de módulos, em que o sistema é representado por um grafo de dependências e a busca procura aumentar a coesão e reduzir o acoplamento [1], [2]. Como esses objetivos frequentemente são conflitantes, formulações multiobjetivo permitem oferecer ao decisor um conjunto de alternativas de compromisso [1]. Trabalhos recentes também destacam que a aceitação das soluções pelos especialistas pode ser determinante para seu uso em ambientes industriais [5].

2) Otimização Multiobjetivo: A otimização multiobjetivo consiste na busca por soluções que atendam simultaneamente a duas ou mais funções objetivo, frequentemente conflitantes entre si. Diferentemente da otimização mono-objetivo, na qual se busca minimizar ou maximizar uma única função, problemas multiobjetivo envolvem a avaliação de diferentes critérios de desempenho. Dessa forma, a melhoria de um determinado objetivo pode implicar a deterioração de outro, tornando necessária a identificação de soluções que representem diferentes compromissos entre os critérios considerados [10].

Matematicamente, um problema de otimização multiobjetivo pode ser formulado como na Equação 1:

$$\min_{\mathbf{x}\in\Omega} \quad \mathbf{F}(\mathbf{x}) = [f_1(\mathbf{x}), f_2(\mathbf{x}), \ldots, f_m(\mathbf{x})] \tag{1}$$

em que $\mathbf{x}$ representa o vetor de variáveis de decisão, Ω corresponde ao conjunto de soluções viáveis e $f_i(\mathbf{x})$ representa a i-ésima função objetivo, para $i = 1, \ldots, m$. O conjunto viável pode ser delimitado por restrições de igualdade, desigualdade e limites das variáveis de decisão.

Em problemas dessa natureza, geralmente não existe uma única solução capaz de otimizar simultaneamente todos os objetivos. Em vez disso, procura-se identificar um conjunto de soluções que apresentem diferentes relações de compromisso. Para comparar essas soluções, utiliza-se o conceito de dominância de Pareto, segundo o qual uma solução domina outra quando apresenta desempenho igual ou superior em todos os objetivos e desempenho estritamente melhor em pelo menos um deles [10].

Considerando um problema de minimização, uma solução $\mathbf{x}^{(a)}$ domina uma solução $\mathbf{x}^{(b)}$ se valem, simultaneamente, as Equações 2 e 3:

$$\forall i \in \{1, \ldots, m\}, \quad f_i(\mathbf{x}^{(a)}) \leq f_i(\mathbf{x}^{(b)}) \tag{2}$$

e

$$\exists j \in \{1, \ldots, m\}, \quad f_j(\mathbf{x}^{(a)}) < f_j(\mathbf{x}^{(b)}) \tag{3}$$

Uma solução é considerada não dominada quando não existe outra solução viável que seja pelo menos tão boa em todos os objetivos e estritamente melhor em pelo menos um deles. O conjunto de todas as soluções não dominadas do espaço viável constitui o conjunto ótimo de Pareto, enquanto sua representação no espaço das funções objetivo é denominada fronteira de Pareto [10].

A identificação dessa fronteira é um dos principais propósitos dos algoritmos de otimização multiobjetivo, pois permite analisar diferentes alternativas sem estabelecer previamente que um objetivo possui maior importância do que os demais. Nesse contexto, dois aspectos são fundamentais para avaliar a qualidade das soluções obtidas: a convergência, relacionada à proximidade das soluções encontradas em relação à fronteira ótima de Pareto, e a diversidade, associada à distribuição das soluções ao longo dessa fronteira. Um algoritmo eficiente deve buscar um equilíbrio entre esses aspectos, produzindo soluções próximas da fronteira ótima e suficientemente distribuídas para representar diferentes possibilidades de decisão.

3) Algoritmo NSGA-III: O *Non-dominated Sorting Genetic Algorithm III* (NSGA-III), proposto por Deb e Jain [11], é um algoritmo evolutivo desenvolvido para resolver problemas de otimização que envolvem múltiplos objetivos, especialmente aqueles classificados como *many-objective*, caracterizados pela presença de quatro ou mais funções objetivo. O algoritmo foi desenvolvido como uma extensão do NSGA-II, buscando superar algumas limitações dos métodos tradicionais de otimização evolutiva em espaços de busca com elevada dimensionalidade.

Conforme Deb e Jain [11], o aumento do número de objetivos torna mais complexa a identificação e a seleção de soluções, uma vez que uma parcela crescente da população tende a apresentar soluções não dominadas. Esse comportamento reduz a capacidade discriminatória da dominância de Pareto e dificulta a manutenção da diversidade populacional. Além disso, mecanismos tradicionais, como a distância de aglomeração (*crowding distance*) utilizada no NSGA-II, podem apresentar dificuldades computacionais e de distribuição das soluções quando aplicados a problemas com muitos objetivos.

Para enfrentar essas limitações, o NSGA-III mantém a estrutura de classificação por dominância não dominada (*non-dominated sorting*) do NSGA-II, mas substitui o mecanismo de preservação da diversidade baseado na distância de aglomeração por uma estratégia fundamentada em pontos de referência distribuídos no espaço dos objetivos. Esses pontos orientam a seleção dos indivíduos e favorecem a obtenção de soluções distribuídas em diferentes regiões da fronteira de Pareto [11].

O processo evolutivo inicia-se com uma população de indivíduos P_t, a partir da qual são gerados novos indivíduos por meio de operadores genéticos de cruzamento e mutação, formando a população descendente Q_t. Em seguida, as duas populações são combinadas, conforme a Equação 4:

$$R_t = P_t \cup Q_t \tag{4}$$

A população resultante R_t é classificada em diferentes níveis de dominância, representados por $F_1, F_2, \ldots, F_l$, sendo priorizadas as soluções pertencentes às primeiras fronteiras não dominadas. As fronteiras são incorporadas sucessivamente até que o número de indivíduos alcance ou ultrapasse o tamanho predefinido da população. Quando a última fronteira considerada possui mais indivíduos do que as posições disponíveis, o NSGA-III utiliza um mecanismo de seleção baseado em pontos de referência para determinar quais soluções serão preservadas na próxima geração [11].

Uma das principais características do NSGA-III é a utilização de pontos de referência previamente definidos, distribuídos sobre um hiperplano normalizado. Para sua construção, Deb e Jain [11] adotam o método de Das e Dennis [12], no qual a quantidade de pontos de referência é determinada em função do número de objetivos e das divisões consideradas em cada eixo. A quantidade total de pontos é calculada pela Equação 5:

$$H = \binom{M + p - 1}{p} \tag{5}$$

em que H representa a quantidade de pontos de referência, M corresponde ao número de funções objetivo e p indica o número de divisões adotadas em cada eixo. Essa distribuição permite estabelecer diferentes direções de referência no espaço dos objetivos, favorecendo a manutenção de soluções em distintas regiões da fronteira de Pareto.

Para permitir a associação adequada entre os indivíduos e os pontos de referência, o algoritmo realiza a normalização adaptativa dos valores das funções objetivo. Inicialmente, determina-se o ponto ideal a partir dos menores valores observados para cada objetivo, realizando-se a translação dos valores em relação a esse ponto. Posteriormente, são identificados pontos extremos e calculados os interceptos de um hiperplano, utilizados para normalizar os objetivos conforme a Equação 6:

$$f_i^n(\mathbf{x}) = \frac{f_i(\mathbf{x}) - z_i^{\min}}{a_i} \tag{6}$$

em que $f_i^n(\mathbf{x})$ representa o valor normalizado da i-ésima função objetivo, $z_i^{\min}$ corresponde ao valor utilizado como referência ideal e a_i representa o intercepto obtido após a translação dos objetivos. Esse procedimento permite reduzir os efeitos provocados por diferenças de escala entre as funções objetivo [11].

Após a normalização, cada indivíduo é associado ao ponto de referência cuja direção apresenta a menor distância perpendicular em relação à sua posição no espaço normalizado

dos objetivos. Essa associação possibilita identificar a distribuição dos indivíduos entre as diferentes regiões de referência, fornecendo informações para o mecanismo de preservação da diversidade.

A seleção dos indivíduos restantes é realizada por meio de um procedimento de nicho (*niching*), que prioriza pontos de referência associados a um menor número de soluções já selecionadas. Quando um ponto de referência ainda não possui indivíduos associados na próxima população, é priorizada a solução candidata com a menor distância perpendicular à sua direção. Caso já existam indivíduos associados a esse ponto, a escolha entre os candidatos correspondentes é realizada aleatoriamente. Esse procedimento é repetido até que todas as posições disponíveis na população sejam preenchidas [11].

Dessa forma, o NSGA-III combina a classificação por dominância de Pareto com uma estratégia de seleção orientada por pontos de referência, buscando conciliar a convergência das soluções e a preservação da diversidade. A principal contribuição do algoritmo está na substituição do mecanismo tradicional de distância de aglomeração por uma abordagem capaz de orientar a distribuição populacional em problemas com muitos objetivos. Segundo Deb e Jain [11], essa característica permite ao NSGA-III apresentar resultados satisfatórios em diferentes problemas de otimização, incluindo experimentos com até quinze funções objetivo.

4) Algoritmo R-NSGA-III: O R-NSGA-III (*Reference Point Based NSGA-III*) é uma extensão do NSGA-III voltada à busca por soluções preferenciais [13]. Em vez de aproximar toda a frente de Pareto, o algoritmo concentra a população nas regiões de interesse do decisor, indicadas por K pontos de aspiração definidos no espaço de M objetivos. Os operadores genéticos e o processo de seleção de sobrevivência são mantidos; a principal diferença está na forma de gerar os pontos de referência [13].

A cada geração, os pontos de aspiração são normalizados com base nos valores mínimo e máximo de cada objetivo e, em seguida, projetados no hiperplano unitário ao longo da reta que os liga ao ponto ideal, originando os pontos $\dot{\mathbf{r}}^{(k)}$. Paralelamente, H pontos de Das e Dennis [12], denotados por $\mathbf{h}^{(j)}$, são gerados no hiperplano e encolhidos por um fator $\mu \in (0, 1)$. O conjunto resultante é então transladado para cada ponto projetado:

$$\mathbf{z}^{(j,k)} = \mu\, \mathbf{h}^{(j)} + \left(\dot{\mathbf{r}}^{(k)} - \mathbf{g}\right), \tag{7}$$

em que $\mathbf{g}$ é o centroide dos pontos encolhidos. Assim, μ controla a proximidade entre os pontos de referência e, consequentemente, influencia a dispersão das soluções ao redor de cada região de interesse.

Aos $K \cdot H$ pontos obtidos, somam-se M pontos extremos, que auxiliam o procedimento de normalização, totalizando $K \cdot H + M$ pontos de referência [13]. O tamanho da população corresponde ao menor número par maior que esse total. Ao final da execução, considera-se apenas a solução mais próxima de cada direção de referência, desconsiderando-se as direções extremas. Dessa forma, o R-NSGA-III permite tanto obter soluções mais concentradas nas regiões de interesse quanto verificar se determinadas regiões da frente de Pareto de fato contêm soluções ótimas [13].

B. Modernização de Sistemas Legados Utilizando Microsserviços

Um sistema legado é, antes de tudo, um sistema bem-sucedido: ele continua sustentando operações relevantes do negócio e, por isso mesmo, não pode ser simplesmente desligado ou reescrito, embora tenha se tornado caro e arriscado de modificar [14]. O acúmulo de alterações ao longo de anos corrói a estrutura original, dilui as fronteiras entre responsabilidades e faz com que o conhecimento sobre o sistema passe a residir mais no código em execução do que em sua documentação. Modernizar esse tipo de sistema significa, portanto, reestruturá-lo preservando o comportamento que ele já entrega.

Quando o sistema legado foi construído como um monólito, todas as responsabilidades compartilham uma única unidade de implantação, um único processo e, com frequência, um único banco de dados. Essa organização é conveniente no início (a chamada entre dois módulos é uma chamada de método, e não há infraestrutura de comunicação a administrar), mas se torna onerosa quando o sistema cresce: qualquer alteração exige reimplantar o todo, a escalabilidade só pode ser obtida replicando o conjunto inteiro, e equipes distintas passam a competir pelo mesmo artefato. Em uma arquitetura de microsserviços, ao contrário, o sistema é decomposto em serviços pequenos, implantáveis de forma independente e organizados em torno de capacidades de negócio, que se comunicam por interfaces remotas. Os estudos com a indústria mostram que a migração é motivada sobretudo por manutenibilidade, escalabilidade e autonomia das equipes, mas também que ela cobra um preço em complexidade de comunicação, de dados distribuídos e de operação [15], [16].

O ponto crítico dessa migração é a *decomposição*: decidir quais elementos do monólito pertencem a cada serviço. Revisões da literatura de refatoração para microsserviços apontam a definição da granularidade e das fronteiras dos serviços como a questão mais discutida e a de solução menos consensual [16], [17]. As abordagens propostas diferem principalmente na evidência que utilizam para agrupar os elementos: análise estática do código e de suas dependências, análise do domínio e dos casos de uso, informação histórica extraída de repositórios, e análise dinâmica a partir de rastros de execução, que tem a vantagem de refletir o comportamento efetivamente exercitado pelo sistema em vez de apenas sua estrutura declarada [17], [18]. Independentemente da evidência utilizada, a decisão envolve critérios que se opõem: separar responsabilidades reduz o acoplamento, mas transforma chamadas locais em chamadas remotas e aumenta o *overhead* de comunicação; agrupar elementos relacionados aumenta a coesão, mas tende a produzir serviços grandes, que reproduzem em menor escala o problema do monólito.

Essa combinação de um espaço de decomposições que cresce de forma combinatória com o número de elementos

e de critérios conflitantes entre si caracteriza um problema de otimização, o que justifica a adoção de técnicas de SBSE [1]. A abordagem *toMicroservices* [3] segue esse caminho: representa o sistema legado por um grafo de dependências entre métodos, obtido a partir da análise estática do código e de rastros de execução associados às funcionalidades do sistema, e trata a identificação dos microsserviços como um problema *many-objective*, resolvido com o NSGA-III [11]. Cada solução é uma atribuição dos métodos a um número fixo de microsserviços, avaliada por cinco objetivos: acoplamento, coesão, *overhead* de rede, modularização das funcionalidades e reúso. O resultado não é uma arquitetura única, mas um conjunto de soluções de compromisso entre esses cinco critérios.

Entregar ao arquiteto uma frente de Pareto com dezenas de alternativas, porém, apenas desloca a decisão: alguém precisa escolher. A ferramenta *i-toMicroservices* [4] responde a isso colocando o arquiteto dentro do ciclo evolutivo. Em pontos pré-definidos da execução a busca é interrompida e o decisor (*Decision Maker*, DM) inspeciona a população corrente, seleciona um candidato e pode editá-lo diretamente, movendo métodos entre microsserviços, dividindo um microsserviço sobrecarregado, unindo dois deles ou congelando aqueles que considera estáveis. A solução resultante é devolvida à busca, que prossegue a partir dela. Essa realimentação é operada por mecanismos que a própria ferramenta permite configurar: o algoritmo pode concentrar a busca na região preferida pelo decisor, com o R-NSGA-III [13], em vez de cobrir toda a frente; o elitismo pode preservar explicitamente a solução editada nas gerações seguintes; e as soluções que violam a restrição de tamanho dos microsserviços podem ser penalizadas ou descartadas. São esses três mecanismos que este trabalho avalia.

III. Metodologia

O experimento é um fatorial completo 2^3 replicado: os três fatores de configuração da ferramenta (algoritmo, elitismo e tratamento de restrições) geram oito configurações, cada uma executada cinco vezes em cada um dos dois sistemas-alvo, o que totaliza 80 execuções independentes de 1.000 gerações. Todas as execuções seguiram a mesma persona de arquiteto, que intervém em três pontos fixos da evolução, de modo que a única fonte de variação planejada seja a configuração. As subseções a seguir descrevem os sistemas (Seção III-A), as configurações e os parâmetros mantidos fixos (Seção III-B), a persona (Seção III-C), os indicadores e os testes estatísticos (Seção III-D) e as ameaças à validade (Seção III-E).

A. Sistemas Utilizados

O experimento utilizou os dois sistemas-alvo distribuídos com o pacote do estudo, *spring-petclinic* e *jpetstore*, ambos aplicações Java de código aberto amplamente conhecidas e frequentemente adotadas como referência em pesquisa e ensino. O *spring-petclinic* é a aplicação de exemplo oficial do projeto Spring e modela a rotina de uma clínica veterinária: donos de animais, animais, veterinários e consultas. O *jpetstore* é a aplicação de exemplo mantida pelo projeto MyBatis, construída sobre MyBatis, Spring e Stripes, e modela uma loja virtual de animais: catálogo, carrinho, conta do cliente e pedido.

Tabela I
Características dos sistemas-alvo.

	spring-petclinic	*jpetstore*
Pacotes	3	3
Classes	14	17
Métodos (elementos da busca)	67	225
Dependências entre métodos	214	590
Funcionalidades	4	3
Métodos em > 1 funcionalidade	19	94
Microsserviços iniciais	4	4

A escolha desses dois sistemas é justificada por três razões. A primeira é a rastreabilidade: ambos acompanham o pacote do estudo já instrumentados, com o grafo de dependências (`dependency.xml`) e os rastros de execução por funcionalidade (`entry-file.log`) prontos, o que elimina a variação que seria introduzida se cada participante gerasse os insumos por conta própria. A segunda é o custo: com 1.000 gerações, população de 132 indivíduos e três pausas para interação humana em cada uma das 80 execuções, sistemas maiores tornariam o experimento inviável no prazo disponível (Seção III-B). A terceira é o contraste: os dois sistemas têm domínios distintos e portes distintos, o que permite verificar se o comportamento das configurações se repete ou muda de um sistema para o outro.

A Tabela I resume as características dos dois sistemas, medidas nos próprios artefatos processados pela ferramenta. Os elementos manipulados pela busca são métodos: o *spring-petclinic* contribui com 67 métodos, distribuídos em 14 classes e 3 pacotes, ligados por 214 dependências; o *jpetstore*, com 225 métodos, em 17 classes e 3 pacotes, ligados por 590 dependências.[1] Como a granularidade da decomposição é o método, e não a classe, uma mesma classe pode ter seus métodos distribuídos entre microsserviços diferentes.

As funcionalidades mapeadas são *Owner*, *Pet*, *Vet* e *Visit* no *spring-petclinic*, e *Order*, *SelectItems* e *UpdateProfile* no *jpetstore*. Elas são o insumo do objetivo de modularização das funcionalidades e ajudam a explicar por que os objetivos entram em conflito: 19 dos 67 métodos do primeiro sistema e 94 dos 225 do segundo são exercitados por mais de uma funcionalidade, de modo que nenhuma atribuição consegue manter todas as funcionalidades inteiramente dentro de um único microsserviço.

A diferença de porte entre os dois sistemas também delimita o espaço de busca. Fixado em quatro o número de microsserviços, o número de atribuições possíveis é da ordem de $4^{67} \approx 10^{40}$ no *spring-petclinic* e de $4^{225} \approx 10^{135}$ no *jpetstore*, limites superiores, já que microsserviços são intercambiáveis e a restrição de tamanho elimina parte das combinações, mas suficientes para evidenciar que a enumeração exaustiva está

[1] O grafo contém ainda um nó sintético de entrada, desconsiderado nessas contagens.

Tabela II
AS OITO CONFIGURAÇÕES AVALIADAS.

Config.	Algoritmo	Elitismo	Restrição
1	NSGA-III	ligado	penalty
2	NSGA-III	desligado	penalty
3	R-NSGA-III	ligado	penalty
4	R-NSGA-III	desligado	penalty
5	NSGA-III	ligado	kill
6	NSGA-III	desligado	kill
7	R-NSGA-III	ligado	kill
8	R-NSGA-III	desligado	kill

Tabela III
ORDEM DE EXECUÇÃO, POR PARTICIPANTE. CADA BLOCO REÚNE AS CINCO REPETIÇÕES DE UMA CONFIGURAÇÃO EM UM SISTEMA, EXECUTADAS EM SEQUÊNCIA.

Part.	Ordem dos blocos (config. – sistema)	Período
A	1-PC, 2-PC, 1-JP, 2-JP, 7-PC, 8-PC	15 a 19/10
B	5-PC, 5-JP, 6-PC, 6-JP, 7-JP	23/10
C	8-JP, 3-JP, 4-JP, 3-PC, 4-PC	23 e 24/10

PC: *spring-petclinic*; JP: *jPetStore*. Os participantes estão anonimizados e nomeados pela ordem em que começaram.

fora de questão em ambos os casos. Essa diferença se reflete no custo das execuções: o *jpetstore* consumiu, em média, cerca de 40% mais tempo decorrido por execução do que o *spring-petclinic* (Seção III-B).

B. Configurações Utilizadas

As oito configurações avaliadas resultam do cruzamento completo de três fatores oferecidos pela *i-toMicroservices*:

- **Algoritmo**: NSGA-III [11], [19] ou R-NSGA-III [13];
- **Elitismo**: ligado ou desligado;
- **Tratamento de restrições**: *penalty*, que penaliza a aptidão da solução inválida e a mantém na população, ou *kill*, que a descarta e a substitui.

A Tabela II enumera as combinações. A restrição em questão é a faixa admitida de tamanho dos microsserviços, delimitada por $minRatio = 0{,}02$ e $maxRatio = 0{,}30$ do total de elementos: cada microsserviço deve conter entre 2% e 30% dos elementos do grafo. A ferramenta aplica esses percentuais sobre o grafo completo, incluindo o nó sintético de entrada, isto é, sobre 68 elementos no *spring-petclinic* e 226 no *jpetstore*, o que resulta em limites de 1,4 a 20,4 e de 4,5 a 67,8 elementos, respectivamente. Esses são os limites usados em todas as verificações de faixa deste trabalho; eles não coincidem com os percentuais aplicados às contagens de métodos da Tabela I, que excluem o nó sintético.

Os demais parâmetros foram mantidos fixos em todas as execuções, de modo que qualquer diferença observada seja atribuível aos três fatores acima: população de 132 indivíduos, 1.000 gerações, número inicial de microsserviços igual a 4, 5 divisões na geração dos pontos de referência, fator de encolhimento $\mu = 0{,}1$, *seedRatio* de 0,2 e três pontos de interação, fixados em 30%, 55% e 80% das gerações (gerações 300, 550 e 800). A população inicial é determinística: o particionamento ordena as classes por nome e divide em quatro partes, de modo que todos os indivíduos da geração 0 partem do mesmo vetor de *fitness* e a diversidade só aparece a partir da geração 1. Isso é verificável nos próprios registros: na geração 0, a média e o melhor valor da população coincidem nos cinco objetivos, em todas as 80 execuções (Seção IV-B).

Cada configuração foi executada cinco vezes para cada um dos dois sistemas, totalizando $8 \times 2 \times 5 = 80$ execuções independentes. As execuções foram distribuídas entre os três autores: as configurações 1 e 2 com um participante, 3 e 4 com outro, 5 e 6 com o terceiro, e as configurações 7 e 8 divididas por sorteio, cada uma com um participante por sistema. O resultado é que cada *combinação de configuração e sistema* foi conduzida integralmente por um único autor, e que cada autor conduziu entre 25 e 30 das 80 execuções. A Seção III-E discute o que esse arranjo permite e o que não permite concluir. Todas usaram a mesma persona (Seção III-C) e o mesmo roteiro de interação.

A ordem de execução, reconstruída a partir do horário registrado no manifesto de cada execução, está na Tabela III. Cada participante executou seus blocos em sequência, um de cada vez, e dentro de cada bloco as cinco repetições foram feitas em seguida, da 1 à 5. A ordem *não* seguiu a numeração das configurações: ela foi definida pela disponibilidade de cada participante entre 15 e 24 de outubro de 2026, e os blocos de participantes diferentes chegaram a se sobrepor no tempo, em instâncias separadas da ferramenta.

Quanto ao ambiente de execução, cada participante rodou a ferramenta em seu próprio computador, a partir do contêiner Docker distribuído com o pacote do estudo. Os manifestos das 80 execuções registram o mesmo ambiente: versão 1.0.0 do *backend*, Java 21.0.12 e sistema operacional Linux, o do contêiner. O *hardware* de cada máquina não é registrado pela ferramenta. Todas as execuções pararam pelo critério de gerações, ao fim das 1.000 gerações, sem limite de tempo configurado.

O tempo total decorrido foi de aproximadamente 25 horas, com média de 949 s por execução no *spring-petclinic* e de 1.315 s no *jpetstore*. Esse tempo é *decorrido*, não de processamento: a ferramenta não separa o custo da busca do tempo em que ela fica parada esperando a decisão do arquiteto, e as medianas, de 612 s e 987 s, ficam bem abaixo das médias justamente porque algumas pausas de interação foram longas. Como as máquinas eram diferentes, o tempo também não seria comparável entre participantes. Por isso o tempo não é usado como indicador de desempenho neste trabalho (Seção III-D) e a separação dos dois componentes aparece entre as sugestões de melhoria (Seção V).

C. Descrição da Persona

Em um processo interativo, o resultado depende tanto do algoritmo quanto de quem decide. Para que as oito configurações fossem comparáveis entre si e entre os três autores, o comportamento do decisor foi padronizado por uma persona, isto é, um perfil de arquiteto descrito previamente e seguido

em todas as execuções. Este trabalho utilizou a persona **P2, Decoplador Sistemático** (*P2-Systematic-Decoupler*), definida pelo pacote do experimento em duas versões equivalentes, uma para cada sistema-alvo, que diferem apenas nos exemplos de decisão.

A P2 é descrita como um arquiteto pragmático, de perfil "engenheiro de produção", que encara a decomposição como *quebrar o que está sobrecarregado*: para ela, microsserviços que concentram muitas dependências e chamadas pesadas são o problema a ser atacado, e um microsserviço que mistura assuntos distintos (*visit* com *owner* no *spring-petclinic*, *catalog* com *order* no *jpetstore*) deve ser separado. Suas decisões são rápidas, repetíveis e orientadas a remover gargalos estruturais, e cada uma é registrada com a mesma justificativa objetiva: "separando microsserviços que fazem coisas demais".

As prioridades da persona entre os cinco objetivos são assimétricas:

- ***Overhead* de rede** e **acoplamento**: objetivos primários, a serem reduzidos;
- **Coesão** e **funcionalidade**: objetivos secundários, a serem mantidos em níveis razoáveis, sem perseguir extremos;
- **Reúso**: apenas mantido estável.

O protocolo de atuação é igualmente explícito. A cada ponto de interação, a persona inspeciona a população corrente, seleciona um candidato que represente um bom *trade-off* (e não o melhor valor isolado em um único objetivo) e evita fixar-se sempre no mesmo candidato ou no primeiro da lista, variando deliberadamente entre alternativas ao longo da execução. Sobre o candidato escolhido, as operações admitidas são *mover métodos em lote*, usada como operação principal, e *dividir* um microsserviço quando ele estiver claramente sobrecarregado; as operações de *unir* e *congelar* são proibidas para esta persona. O número inicial de microsserviços, fixado em quatro pelo experimento, não é alterado. O ritmo é regular e previsível: a persona intervém em três momentos distintos, em intervalos constantes, sem antecipar nem postergar decisões (no desenho deste experimento, nas gerações 300, 550 e 800; ver Seção III-B).

A persona pode ser resumida na frase que encerra sua própria definição: "ritmo constante e decisões objetivas: quebrar o que está sobrecarregado e reduzir acoplamento e *overhead* de rede sem perseguir extremos". Todas as 80 execuções adotaram essa mesma persona e esse mesmo roteiro, de modo que a comparação entre configurações não é afetada por mudanças de perfil do decisor. O roteiro, porém, não foi seguido com a mesma intensidade em todas as execuções: as operações proibidas nunca foram usadas e a variação na escolha dos candidatos ocorreu como prescrito, mas em pouco mais da metade das pausas nenhuma edição foi aplicada. A Seção IV-G quantifica essa conformidade por configuração, na Tabela XVII, e discute o que ela implica para a RQ2. Isso não elimina, contudo, a variação entre os três autores que encarnaram a persona nem o fato de cada combinação de configuração e sistema ter sido conduzida por um único deles, limitações discutidas na Seção III-E.

D. Indicadores de Qualidade e Testes Estatísticos Utilizados

A avaliação usa dois conjuntos distintos de medidas, que não devem ser confundidos. O primeiro descreve a *arquitetura* contida em cada solução e é o que interessa ao arquiteto; o segundo descreve o *comportamento do algoritmo* que produziu o conjunto de soluções e é o que permite comparar configurações entre si.

1) Indicadores de Qualidade Arquitetural: Uma solução é uma atribuição de cada método do sistema a exatamente um dos quatro microsserviços, avaliada pelos cinco objetivos da formulação *toMicroservices* [3], cujas definições formais estão naquele trabalho e cuja implementação é usada aqui tal como distribuída:

- **Acoplamento**: número de dependências entre métodos alocados em microsserviços diferentes. É a única das cinco medidas que se reproduz diretamente a partir dos artefatos exportados pela ferramenta, e foi conferida contra eles em todas as soluções analisadas.
- **Coesão**: grau em que as dependências de cada microsserviço são internas a ele, agregado sobre a arquitetura.
- ***Overhead* de rede**: custo estimado das chamadas que passam a ser remotas por cruzarem a fronteira entre microsserviços, ponderado pelo volume observado nos rastros de execução.
- **Modularização das funcionalidades**: grau em que cada funcionalidade mapeada fica contida em um único microsserviço.
- **Reúso**: grau em que os métodos compartilhados por mais de uma funcionalidade são aproveitados dentro de um mesmo microsserviço.

Duas convenções da ferramenta valem para toda a análise. A primeira é que os cinco objetivos são *minimizados*: coesão, modularização das funcionalidades e reúso são exportados já invertidos, de modo que, nos cinco eixos, menor é melhor. A segunda é que o número de microsserviços é fixo em quatro e não é um objetivo; a granularidade entra no problema como *restrição* de tamanho, pela faixa descrita na Seção III-B. Por isso a análise da granularidade, na Seção IV-C, é feita sobre o tamanho dos microsserviços de cada arquitetura devolvida e sobre a proporção de arquiteturas que violam essa faixa, e não sobre a contagem de serviços.

2) Indicadores de Desempenho dos Algoritmos: O desempenho de cada execução é resumido por quatro indicadores calculados sobre a fronteira final que ela devolve, em um espaço objetivo normalizado por (persona $\times$ sistema) a partir dos valores mínimo e máximo observados no conjunto das execuções daquela combinação:

- **HV**, o *hypervolume* [6]: volume do espaço objetivo dominado pela fronteira em relação a um ponto de referência, fixado em 1,1 em cada um dos cinco eixos normalizados. Resume convergência e diversidade em um único número e é o único indicador em que *maior é melhor*. Como o ponto de referência é 1,1 em cinco dimensões, o valor máximo possível é $1{,}1^5 \approx 1{,}61$, e não 1: valores acima de 1 são esperados.

- **IGD+** [7]: distância média, com a correção de dominância proposta por Ishibuchi *et al.*, de cada ponto de uma fronteira de referência Z^* ao ponto mais próximo da fronteira obtida. Como não existe fronteira ótima conhecida para o problema, Z^* é empírica, construída a partir das soluções não dominadas reunidas das execuções da mesma persona e do mesmo sistema (425 pontos no *jpetstore* e 162 no *spring-petclinic*).
- **ED média** e **ED mínima**: distância euclidiana ao ponto ideal $(0, 0, 0, 0, 0)$ no espaço normalizado, tomada como média sobre todos os pontos da fronteira e como mínimo sobre eles. A primeira descreve a fronteira como um todo; a segunda, apenas a melhor solução que ela contém. São indicadores distintos e, como mostra a Seção IV, levam a conclusões distintas.

Por dependerem de limites de normalização e de uma Z^* específicos de cada sistema, os quatro indicadores são *relativos* ao conjunto observado: comparam configurações dentro de um mesmo sistema e não medem distância a um ótimo absoluto. Por isso nenhuma comparação de valores entre os dois sistemas é feita neste trabalho.

O tempo de execução não é usado como indicador de desempenho. A ferramenta registra apenas o tempo decorrido de cada execução, que mistura o custo da busca com o tempo em que o processo fica parado esperando a decisão do arquiteto (Seção III-B); sem essa separação, qualquer comparação de custo computacional entre configurações mediria sobretudo a velocidade de quem interagiu.

3) Testes Estatísticos: Cada combinação de sistema e indicador é analisada separadamente, sobre oito grupos de cinco observações. A descrição usa média, mediana, desvio-padrão, mínimo e máximo, para distinguir o desempenho central da variação entre execuções.

A comparação é inteiramente não paramétrica. Com cinco observações por grupo, um teste de normalidade não tem poder para sustentar a escolha de um procedimento paramétrico, e a recomendação para a comparação de algoritmos randomizados em engenharia de software é usar testes de postos em todos os casos [8]; escolher o teste indicador por indicador, além disso, tornaria os resultados de indicadores diferentes não comparáveis entre si. Os resultados de Shapiro-Wilk e de Levene são reportados no Apêndice apenas como descrição dos dados, não como critério de escolha de teste.

A hipótese nula do teste global, para cada combinação de sistema e indicador, é que as oito configurações provêm da mesma distribuição; a alternativa é que ao menos uma difere. O teste é o de Kruskal-Wallis [24], com $\alpha = 0{,}05$. Quando ele rejeita a nula, o pós-hoc é o teste de Dunn [20] sobre as 28 comparações par a par, com os valores-p corrigidos pelo procedimento de Benjamini-Hochberg [21] dentro de cada combinação de sistema e indicador.

Além da comparação entre as oito configurações, cada *fator* é analisado isoladamente, agregando as execuções pelos dois níveis do fator e deixando os outros dois fatores variarem livremente: 20 execuções contra 20, por sistema e por indicador. Essa comparação usa o teste de Wilcoxon *rank-sum* com correção de Holm [22] sobre os três fatores. É a análise com maior poder disponível neste desenho, e é dela que vêm as afirmações sobre o efeito de cada fator.

Todo valor-p é relatado ao lado do tamanho de efeito $\hat{A}_{12}$ de Vargha-Delaney [23], orientado pela direção de melhoria do indicador: valores acima de 0,5 favorecem o primeiro grupo da comparação e abaixo de 0,5 favorecem o segundo. A magnitude é classificada por $d = |\hat{A}_{12} - 0{,}5|$, com os limiares usuais: desprezível para $d \leq 0{,}06$, pequena para $0{,}06 < d \leq 0{,}14$, média para $0{,}14 < d \leq 0{,}21$ e grande para $d > 0{,}21$. Significância e tamanho de efeito são interpretados em conjunto: um efeito grande sem significância descreve uma predominância observada, mas não estabelece diferença; e um resultado não significativo não demonstra equivalência, como alertam Arcuri e Briand [8].

E. Ameaças à Validade

Validade interna. A ameaça mais relevante deste experimento é o confundimento entre configuração e participante: cada combinação de configuração e sistema foi conduzida integralmente por um único autor (Seção III-B), de modo que o efeito da configuração não pode ser separado, com os dados disponíveis, do efeito do estilo de interação de quem a executou. O confundimento não atinge igualmente todas as comparações, e vale registrar onde ele morde. As duas comparações par a par deste trabalho que isolam algoritmo e elitismo no *jpetstore*, entre as configurações 8 e 6 e entre 8 e 7 (Seção IV-G), opõem execuções de participantes diferentes e são, portanto, inteiramente confundidas; são relatadas como descrição e não sustentam conclusão sobre esses dois fatores. Em contrapartida, no *spring-petclinic* as configurações 1, 2, 7 e 8 foram conduzidas pelo mesmo participante, de modo que os pares 1 contra 7, 1 contra 8, 2 contra 7 e 2 contra 8, todos significativos e todos na mesma direção, comparam *penalty* com *kill dentro* de um único estilo de interação. Somam-se a isso duas mitigações gerais: todos seguiram a mesma persona, com regras explícitas de decisão, e a análise por fator isolado (20 execuções por nível) faz cada nível agregar execuções dos três participantes. Ainda assim, uma replicação em que cada participante execute todas as configurações é necessária para isolar o efeito. A isso se soma uma segunda diferença, mensurável, entre os participantes: o número de edições aplicadas por pausa de interação variou muito entre eles (16 operações em 75 pausas para um deles, contra 61 e 74 para os outros dois), ao ponto de duas combinações de configuração e sistema não terem recebido nenhuma edição (Tabela XVII). Como essas combinações coincidem com configurações específicas, a intensidade da interação é um terceiro fator que varia junto com a configuração, e não apenas o estilo de decisão. Além disso, a ferramenta não expõe controle de semente aleatória (*seed* nula em todas as execuções), o que impede a reprodução exata de uma execução; as cinco repetições por configuração existem justamente para absorver essa variação.

Validade de construção. Os indicadores foram calculados sobre um espaço objetivo normalizado por (persona $\times$ sistema), com ponto de referência fixo em 1,1, e a fronteira

de referência Z^* usada no IGD+ foi construída a partir das próprias execuções, pois não existe fronteira ótima conhecida para o problema. Os quatro indicadores são, portanto, medidas *relativas* ao conjunto observado: comparam configurações entre si, dentro de um mesmo sistema, e não medem distância a um ótimo absoluto. Pela mesma razão, não se comparam valores entre os dois sistemas. A ED ao ponto ideal $(0, 0, 0, 0, 0)$, seja a média ou a mínima, é uma aproximação da noção de "boa solução" que ignora o quanto cada objetivo importa para a persona; ela complementa, mas não substitui, a análise de aderência à preferência conduzida na RQ2. Um dos cinco objetivos, o reúso, variou muito pouco neste experimento (Seção IV-C), de modo que os indicadores são, na prática, dominados por quatro dimensões; isso não invalida a comparação entre configurações dentro de um sistema, mas enfraquece a leitura do problema como genuinamente de cinco objetivos.

Validade de conclusão. O número de execuções por configuração (cinco) é pequeno, e isso limita diretamente o que se consegue detectar na comparação par a par: com cinco contra cinco, o menor valor-p alcançável por um teste de postos é $2/\binom{10}{5} \approx 0{,}0079$, e a correção recai sobre 28 pares. É por essa razão, e não por uma escolha de conveniência, que nenhuma conclusão deste trabalho se apoia em um par isolado: as afirmações que sustentamos vêm da análise por fator, que compara 20 execuções contra 20 (Tabela XVI), e do padrão que se repete em todos os indicadores e nos dois sistemas. Vale registrar, ainda, que a prova de controle da taxa de falsas descobertas de Benjamini e Hochberg supõe estatísticas de teste independentes [21], e as 28 comparações par a par de um mesmo sistema compartilham grupos (cada configuração entra em sete delas), de modo que a garantia formal não se aplica integralmente a este desenho; mantemos o procedimento porque é o recomendado no pacote do estudo, mas as decisões por par devem ser lidas como indicativas. Relatamos tamanho de efeito ($\hat{A}_{12}$) [23] ao lado de todo valor-p, justamente para não confundir ausência de significância com ausência de diferença, como recomendam Arcuri e Briand [8].

Validade externa. Foram usados dois sistemas Java de código aberto, de porte pequeno a médio, amplamente empregados como referência na literatura de decomposição de monólitos. Os resultados não se generalizam automaticamente para sistemas industriais de larga escala, para outras linguagens ou para sistemas com acoplamento por banco de dados compartilhado. Da mesma forma, o experimento cobre uma única persona, entre as três definidas na disciplina: a dominância observada de uma estratégia de restrição pode interagir com o perfil de preferência do decisor, o que só uma comparação entre personas pode revelar.

IV. Resultados e Discussão

Esta seção apresenta os resultados das oito configurações avaliadas nos sistemas *jPetStore* e *spring-petclinic*, considerando cinco execuções por configuração e a interação da persona P2 (Decoplador Sistemático). A apresentação distingue a qualidade arquitetural das soluções, o desempenho multiobjetivo e as evidências estatísticas, relacionando esses resultados às questões de pesquisa.

Deste ponto em diante, as configurações são referidas pelo identificador de 1 a 8 definido na Tabela II, para que a leitura dos resultados não precise repetir a combinação de algoritmo, elitismo e tratamento de restrições a cada menção. A Seção IV-G retoma as combinações ao discutir o efeito de cada fator.

A. Fronteiras Geradas por Configuração

As Figuras 1 a 4 apresentam, em coordenadas paralelas, todas as soluções não dominadas devolvidas ao final das execuções: um painel por configuração, uma linha por solução e uma cor por execução. Para manter a legibilidade, cada sistema ocupa duas figuras, separadas pela estratégia de tratamento de restrições (*penalty* nas configurações 1 a 4 e *kill* nas configurações 5 a 8), com os eixos normalizados pelos mesmos limites nas quatro figuras de um mesmo sistema, o que permite compará-las diretamente. Os cinco eixos seguem a convenção de minimização adotada pela ferramenta (coesão, funcionalidade e reúso aparecem invertidos), de modo que, em todos eles, *mais baixo é melhor*.

A leitura das figuras reproduz o padrão que os indicadores apontam. No *spring-petclinic*, as quatro configurações com *penalty* (Figura 1) espalham as soluções por uma faixa mais larga de acoplamento e alcançam valores mais baixos nesse eixo, enquanto as configurações com *kill* (Figura 2) concentram as linhas em uma faixa estreita e mais alta. As medianas sobre todas as soluções confirmam a leitura visual: acoplamento 72 contra 80 e *overhead* 760 contra 864, em favor do *penalty*. No *jpetstore* a diferença é mais acentuada no *overhead*: mediana de 328 nas configurações com *penalty* contra 528 nas com *kill*, com acoplamento de 145 contra 154.

Dois aspectos pedem registro. O primeiro é o eixo de reúso, praticamente plano em todos os painéis. No *spring-petclinic* ele é exatamente uma reta: a métrica vale 1,0 em todas as soluções finais das 40 execuções. No *jpetstore* ela varia muito pouco, mas varia: 138 das 5.049 soluções finais (2,7%) assumem 1,25 ou 1,3333, distribuídas por 14 das 40 execuções, todas em configurações com *penalty* ou na configuração 8. Nos dois sistemas, portanto, há pouco ou nenhum compromisso a negociar nesse objetivo, o que significa que a busca opera, na prática, sobre quatro dimensões efetivas e não cinco. O segundo é a configuração 8 no *jpetstore* (Figura 4, painel inferior direito), que se distingue das demais configurações com *kill* por produzir um leque bem mais aberto, com soluções tanto de acoplamento muito baixo quanto de *overhead* muito alto; é a mesma configuração que, nos indicadores, aparece com a melhor média de HV nesse sistema.

B. Evolução do Fitness

As Figuras 5 e 6 acompanham o *fitness* médio da população nos cinco objetivos, da geração 0 até a geração 999, com pontos nas três gerações em que houve interação da persona (300, 550 e 800). Os valores citados neste texto são a mediana, entre as execuções de um mesmo grupo, dessa média populacional

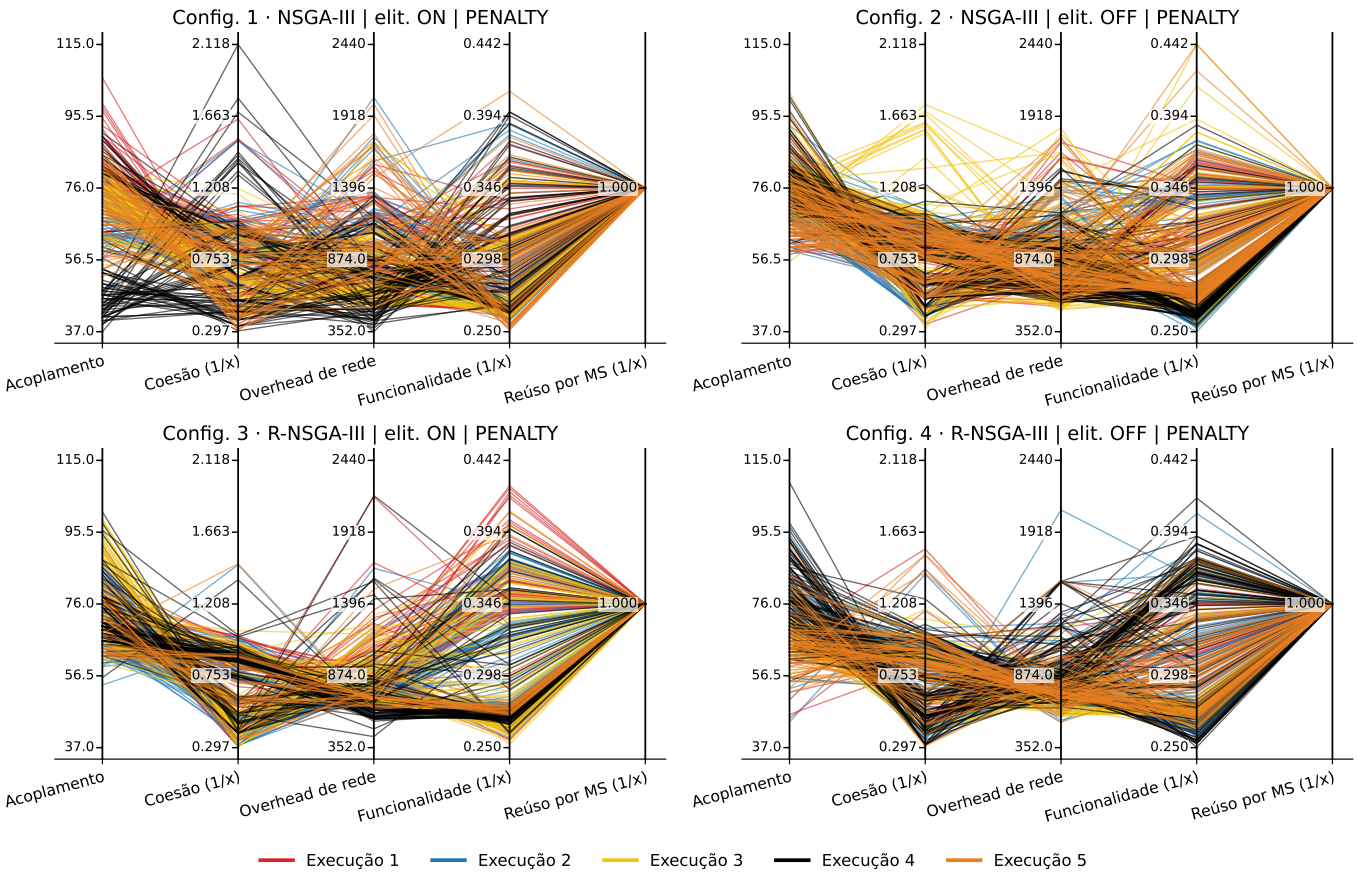


Figura 1. spring-petclinic: fronteiras finais das configurações 1 a 4 (*penalty*). Cada linha é uma solução não dominada; a cor identifica a execução. Todos os eixos estão na convenção de minimização (mais baixo é melhor).

por geração; a mediana entre execuções é preferida à média de médias para não deixar uma execução atípica conduzir a curva. A geração 0 é determinística e idêntica em todas as execuções, o que dá um ponto de partida comum: acoplamento 97 e *overhead* 1.488 no *spring-petclinic*; 331 e 2.152 no *jpetstore*.

A maior parte do ganho ocorre *antes* da primeira intervenção. Até a geração 300, o acoplamento médio cai de 97 para cerca de 86 no *spring-petclinic* e de 331 para cerca de 204 no *jpetstore*; o *overhead* médio cai de 1.488 para cerca de 1.160 e de 2.152 para cerca de 920, respectivamente. Nesse trecho as oito configurações são praticamente indistinguíveis. Isso é esperado em parte, mas não inteiramente: até a primeira pausa, nenhuma preferência havia sido expressa e o elitismo, que preserva a solução editada, ainda não tinha o que preservar, de modo que as configurações diferiam apenas no algoritmo e no tratamento de restrições. Que a estratégia de restrição, já ativa desde a geração 0, não separe as curvas nesse trecho indica que seu efeito só se manifesta depois de a população passar a recombinar o material devolvido pelo decisor.

A separação aparece depois da primeira interação. Entre as gerações 300 e 999, as configurações com *penalty* continuam melhorando os dois objetivos prioritários da persona, enquanto as com *kill* estabilizam cedo. No *spring-petclinic*, o acoplamento médio vai de 85,9 a 72,0 com *penalty* e de 86,3 a 81,0 com *kill*; o *overhead* médio vai de 1.157 a 837 contra 1.163 a 971. No *jpetstore*, a diferença no *overhead* é maior: de 935 para 414 com *penalty* e de 906 para 632 com *kill*. A coesão acompanha o mesmo padrão: continua caindo sob *penalty* e, sob *kill*, estaciona e piora levemente (0,85 para 0,73 contra 0,84 para 0,87 no *spring-petclinic*). O reúso permanece em 1,0 do início ao fim no *spring-petclinic* e oscila de forma desprezível no *jpetstore*, sem tendência.

Esse comportamento é compatível com a hipótese de que descartar as soluções inválidas empobrece a população justamente na fase em que ela precisaria recombinar o material devolvido pelo decisor. Vale, porém, a ressalva: o experimento não possui um braço sem interação, de modo que não é possível separar o efeito das intervenções do efeito da busca que continuaria operando de qualquer forma. O que as figuras sustentam é a existência da diferença entre as estratégias de restrição, não a atribuição causal de cada melhoria a uma intervenção específica.

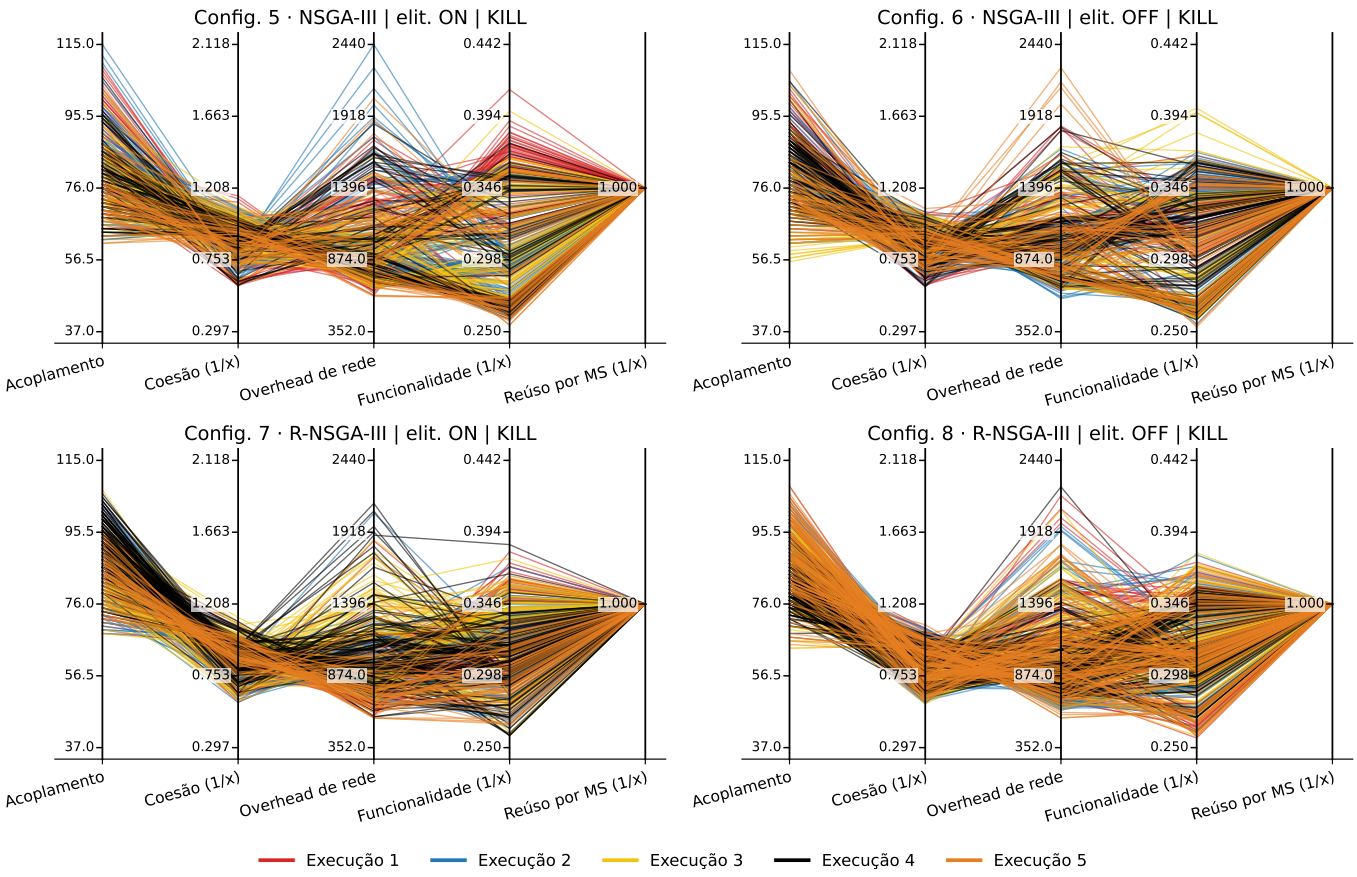


Figura 2. spring-petclinic: fronteiras finais das configurações 5 a 8 (*kill*), nos mesmos eixos da Figura 1.

C. Resultados da Qualidade Arquitetural

A avaliação da qualidade arquitetural considera os cinco objetivos definidos na Seção III-D1: acoplamento, coesão, *overhead* de rede, funcionalidade e reúso. Para a persona P2, a redução do acoplamento e do overhead constitui a prioridade, enquanto coesão e funcionalidade devem permanecer em níveis razoáveis e o reúso deve ser mantido estável.

Essa perspectiva exige examinar os compromissos entre os objetivos. Uma redução de acoplamento, por exemplo, deve ser interpretada em conjunto com seus efeitos sobre o overhead e a organização dos microsserviços. Da mesma forma, o número de microsserviços não deve ser considerado isoladamente como evidência de qualidade: a análise da granularidade precisa observar como as responsabilidades são distribuídas entre eles.

Os valores desta subseção têm dois critérios de agregação, declarados para não misturar arquiteturas distintas. Os quatro objetivos reportados são a mediana sobre *todas* as soluções da fronteira final de uma configuração, somando as cinco execuções (não são o melhor valor de cada objetivo, e nenhuma solução isolada apresenta simultaneamente os quatro). Já o tamanho dos microsserviços e a verificação da faixa de tamanho são calculados sobre arquiteturas inteiras: as cinco soluções de melhor valor em cada objetivo que a ferramenta devolve ao final de cada execução, 25 por configuração. O reúso não aparece na tabela porque sua mediana é 1,0 em todas as 16 combinações de sistema e configuração: ele é constante no *spring-petclinic* e varia em apenas 2,7% das soluções finais do *jpetstore*.

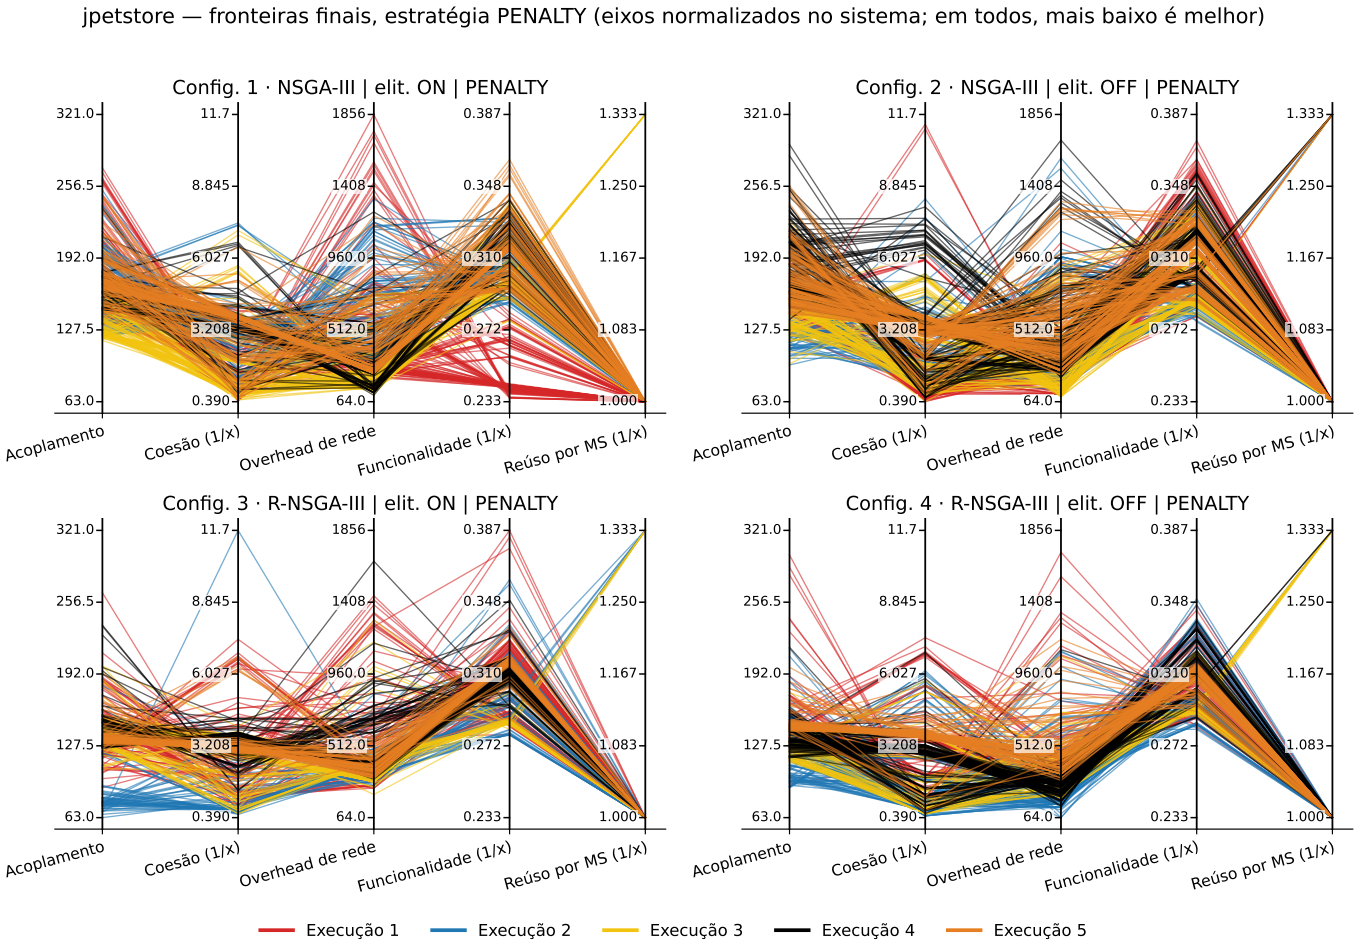


Figura 3. jPetStore: fronteiras finais das configurações 1 a 4 (*penalty*). Cada linha é uma solução não dominada; a cor identifica a execução. Todos os eixos estão na convenção de minimização (mais baixo é melhor).

Tabela IV
QUALIDADE ARQUITETURAL DAS FRONTEIRAS FINAIS, POR CONFIGURAÇÃO.

Config.	Acopl.	*Overh.*	Coesão	Maior MS	Fora da faixa
spring-petclinic (faixa: 1,4 a 20,4 métodos)					
1	73	760	0,63	28	96%
2	75	808	0,77	26	96%
3	69	720	0,73	24	92%
4	68	752	0,76	29	88%
5	76	824	0,93	20	0%
6	74	868	0,90	20	0%
7	84	796	0,90	20	24%
8	85	936	0,83	20	4%
jPetStore (faixa: 4,5 a 67,8 métodos)					
1	162	288	3,17	90	92%
2	160	336	2,29	109	96%
3	133	384	3,11	95	96%
4	133	304	2,74	95	100%
5	154	480	3,23	67	0%
6	153	496	3,30	67	0%
7	133	472	3,39	66	0%
8	176	684	2,07	67	4%

Acoplamento, *overhead* e coesão: mediana sobre todas as soluções da fronteira final, na convenção de minimização (menor é melhor). Maior MS: mediana, em métodos, do maior microsserviço das 25 arquiteturas devolvidas por configuração. "Fora da faixa": proporção dessas arquiteturas com ao menos um microsserviço fora dos limites de tamanho. Funcionalidade e reúso foram omitidos por variarem pouco entre configurações: a mediana da funcionalidade fica entre 0,277 e 0,314 no *spring-petclinic* e entre 0,248 e 0,314 no *jPetStore*, e a do reúso é 1,0 em todas elas.

A Tabela IV mostra, nos dois sistemas, a vantagem das configurações com *penalty* nos objetivos que a persona P2 declara como primários. No *spring-petclinic*, as medianas de acoplamento ficam entre 68 e 75 com *penalty* e entre 74 e 85 com *kill*; no *jPetStore*, a diferença se concentra no *overhead*, com medianas de 288 a 384 contra 472 a 684. A coesão acompanha a mesma direção no *spring-petclinic* (0,63 a 0,77 com *penalty*, contra 0,83 a 0,93 com *kill*), mas não no *jPetStore*, onde a melhor coesão mediana é justamente a da configuração 8 (2,07), com *kill*, abaixo de qualquer configuração com *penalty* (2,29 a 3,17). A funcionalidade permanece quase estável entre configurações (mediana de 0,248 a 0,314, com o extremo inferior na configuração 8 do *jPetStore*), ainda que entre soluções individuais ela varie de 0,233 a 0,442; o reúso praticamente não varia.

A granularidade acrescenta a outra metade do quadro. As arquiteturas devolvidas pelas configurações 5, 6 e 7, todas com *kill*, são equilibradas: no *jPetStore*, o menor microsserviço tem mediana de 30 a 47 métodos e o maior, de 66 a 67, ou seja, quatro serviços de porte semelhante. A configuração 8 é a exceção dentro do *kill*: embora respeite o teto (mediana de

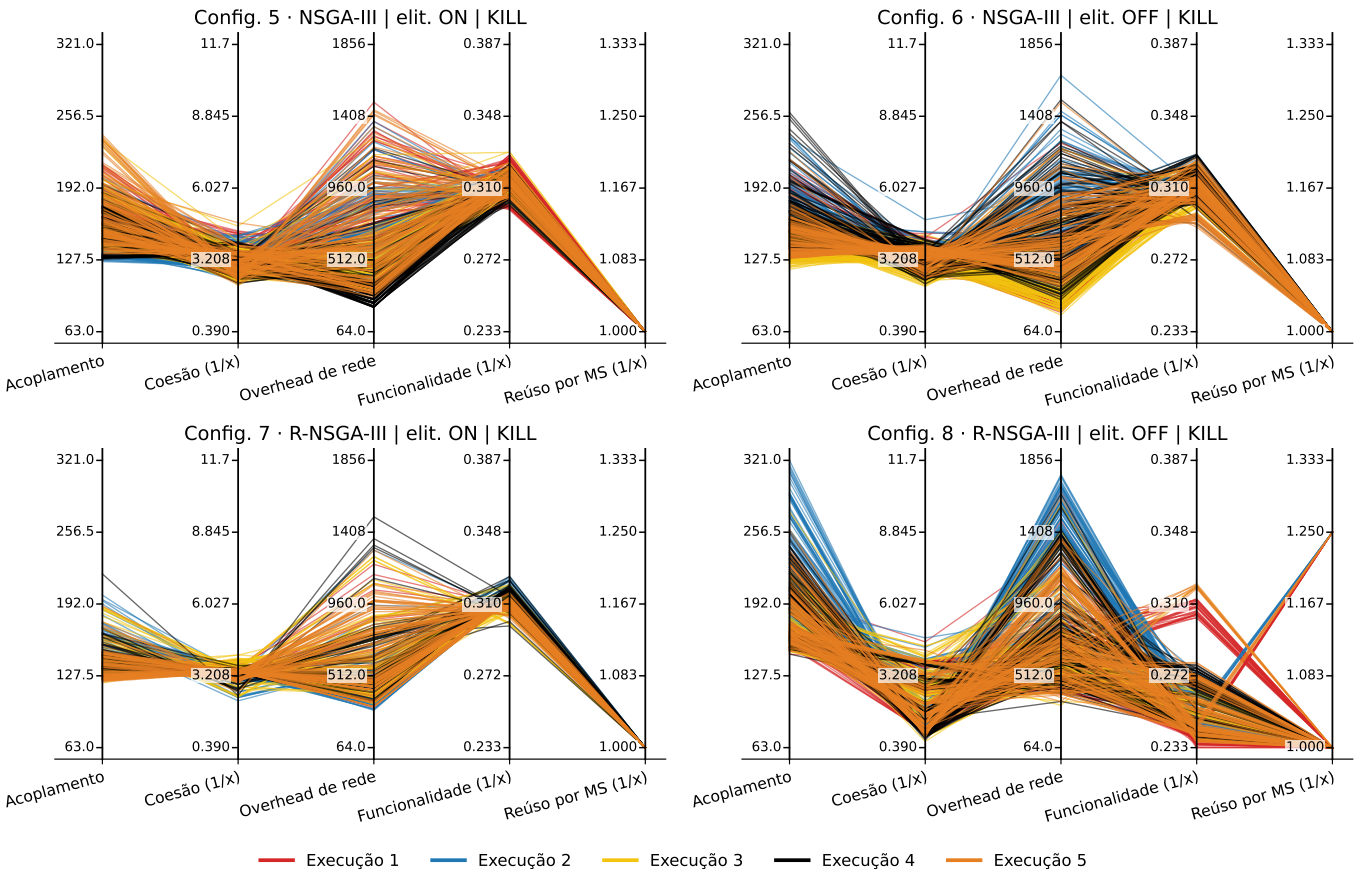


Figura 4. jPetStore: fronteiras finais das configurações 5 a 8 (*kill*), nos mesmos eixos da Figura 3.

67 métodos no maior microsserviço), a mediana do menor cai para 6, de modo que ela devolve arquiteturas bem menos uniformes que as demais configurações da sua estratégia. As configurações com *penalty* devolvem arquiteturas assimétricas, com um microsserviço de 90 a 109 métodos (perto da metade dos 225 métodos do sistema) ao lado de outro com três ou quatro métodos. No *spring-petclinic* o padrão se repete em menor escala: de 24 a 29 métodos no maior serviço com *penalty*, contra 20 com *kill*, que é exatamente o teto admitido.

A última coluna da tabela mostra o mecanismo por trás disso. A faixa de tamanho é a única restrição do problema, e é ela que as duas estratégias tratam de modo diferente: o *kill* descarta a solução que a viola, o *penalty* apenas penaliza sua aptidão e a mantém na população. O efeito aparece no que é devolvido ao arquiteto: de 88% a 100% das arquiteturas das configurações com *penalty* têm pelo menos um microsserviço fora dos limites, contra 0% a 24% das configurações com *kill*. Parte da vantagem que o *penalty* apresenta nos indicadores vem, portanto, de soluções que o próprio experimento define como inválidas, e que um arquiteto dificilmente aceitaria: concentrar metade do sistema em um único serviço reproduz o monólito que a decomposição pretendia desfazer.

Isso não anula o resultado das configurações com *penalty*: elas de fato alcançam acoplamento e *overhead* menores, e parte dessa melhoria ocorre dentro da faixa admitida, como mostram as configurações 3 e 4 no *jPetStore*, que combinam o menor acoplamento mediano (133) com *overhead* entre os mais baixos. O que a tabela acrescenta é um critério de leitura: para esta persona, comparar configurações apenas pelos indicadores agregados favorece sistematicamente quem admite arquiteturas desbalanceadas, e a escolha final precisa olhar também a composição dos microsserviços.

D. Comparação do Desempenho Multiobjetivo

Esta subseção resume o comportamento dos quatro indicadores de desempenho definidos na Seção III-D, por sistema; a Seção IV-E traz a descrição numérica completa e os testes. Vale lembrar que maiores valores de HV e menores valores dos demais indicadores representam melhor desempenho, e que, por dependerem de limites de normalização específicos de cada sistema, os valores só se comparam dentro de um mesmo sistema; entre sistemas comparam-se apenas os padrões.

Um aspecto da fronteira devolvida precisa ser registrado antes, porque condiciona a leitura de HV e IGD+: a car-

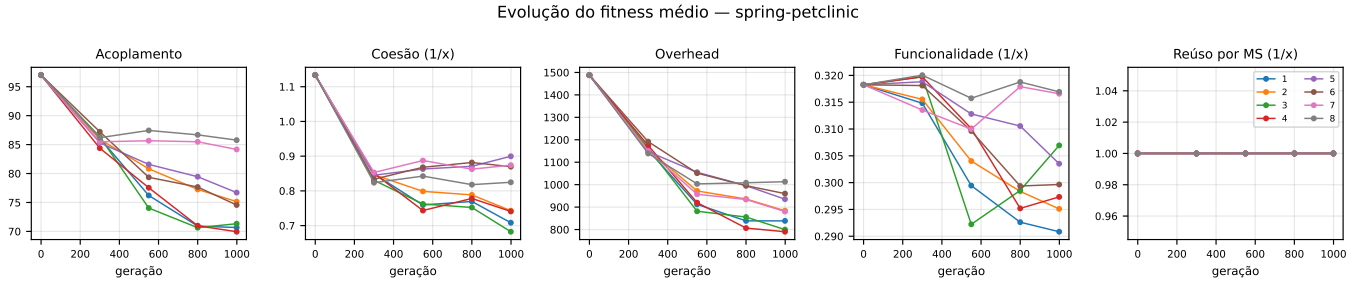


Figura 5. spring-petclinic: *fitness* médio da população por geração, nos cinco objetivos, para as oito configurações. Os pontos marcam as gerações 0, 300, 550, 800 e 999; as três intermediárias são os momentos de interação da persona.

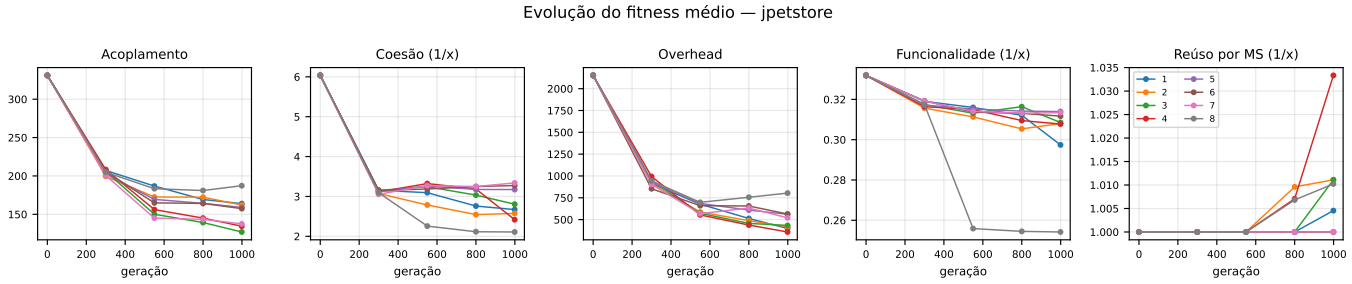


Figura 6. jPetStore: *fitness* médio da população por geração, nos cinco objetivos, para as oito configurações.

dinalidade. Das 132 soluções da população final, o número de pontos distintos não dominados variou de 29 a 131 entre as 80 execuções, com o restante composto por duplicatas. A configuração 8 é a única que devolve fronteiras quase cheias nos dois sistemas (de 107 a 128 pontos, com 4 a 15 duplicatas), enquanto as configurações 1 a 4 do *spring-petclinic* ficaram entre 29 e 104 pontos, chegando a 103 duplicatas em uma execução. Como HV e IGD+ premiam cobertura, parte da diferença entre configurações nesses dois indicadores pode refletir quantos pontos distintos a fronteira contém, e não apenas onde ela está situada.

a) jPetStore.: As quatro configurações com Penalty e a configuração 8 apresentaram resultados favoráveis de HV e IGD+ em relação às configurações 5, 6 e 7. A configuração 8 obteve a maior média de HV e as menores médias de IGD+ e ED mínima, apesar de usar Kill. Entretanto, sua vantagem descritiva não estabeleceu superioridade estatística sobre as configurações com Penalty em nenhum indicador.

A ED mínima reproduziu o mesmo padrão de HV e IGD+, com dez pares significativos. A ED média, ao contrário, apresentou comportamento diferente: as menores médias foram obtidas pelas configurações 4 e 3, sem diferença global significativa entre as oito configurações. Esse resultado mostra que a obtenção de uma fronteira favorável em HV e IGD+ não implica, necessariamente, a menor distância média ao ideal.

b) spring-petclinic.: As configurações com Penalty apresentaram médias mais favoráveis nos quatro indicadores do que as configurações com Kill. A configuração 1 obteve as melhores médias de HV, IGD+ e ED mínima, enquanto a configuração 4 apresentou a menor ED média.

As configurações 1 e 4 também diferiram quanto à regularidade dos resultados. A configuração 4 apresentou menor dispersão em HV, IGD+ e ED mínima, enquanto a configuração 1 apresentou menor dispersão em ED média. Portanto, a comparação envolve tanto os valores centrais quanto a variação entre execuções.

c) Convergência, diversidade e preferências.: HV e IGD+ fornecem perspectivas complementares da qualidade das fronteiras finais, envolvendo sua aproximação e cobertura em relação às referências adotadas. Contudo, esses indicadores não isolam todos os aspectos de diversidade nem descrevem, por si só, a trajetória da busca ao longo das gerações: a distribuição dos pontos ao longo da fronteira e a evolução da população são tratadas, respectivamente, pela cardinalidade reportada acima e pelas Figuras 5 e 6.

A ED média considera a distância média dos pontos de uma fronteira ao ideal, enquanto a ED mínima considera apenas o ponto mais próximo desse ideal em cada execução. Assim, uma boa ED mínima pode coexistir com uma ED média menos favorável, caso a fronteira contenha outras soluções mais distantes do ideal.

O atendimento às preferências da persona constitui uma dimensão adicional. Os indicadores utilizados não atribuem explicitamente prioridade ao acoplamento e ao overhead conforme desejado pela P2. Consequentemente, o desempenho multiobjetivo precisa ser relacionado aos valores dos objetivos e às soluções retornadas para avaliar essa aderência.

E. Análise Estatística dos Resultados

O procedimento adotado foi analisar separadamente cada sistema e indicador, considerando oito grupos de cinco execu-

Tabela V
KRUSKAL-WALLIS ENTRE AS OITO CONFIGURAÇÕES ($\alpha = 0{,}05$).

Sistema	Indicador	H	p	η^2
spring-petclinic	HV	33,97	<0,001	0,843
spring-petclinic	IGD+	33,01	<0,001	0,813
spring-petclinic	ED média	27,57	<0,001	0,643
spring-petclinic	ED mínima	28,08	<0,001	0,659
jpetstore	HV	27,34	<0,001	0,636
jpetstore	IGD+	27,26	<0,001	0,633
jpetstore	ED média	8,89	0,260	0,059
jpetstore	ED mínima	25,78	<0,001	0,587

ções. Inicialmente, foram calculadas a média, a mediana e o desvio-padrão de cada configuração. Essas medidas permitem distinguir o desempenho central da variação entre execuções.

O teste global é o de Kruskal-Wallis [24] em todas as oito combinações de sistema e indicador, e o pós-hoc, quando ele rejeita a nula, é o teste de Dunn [20] sobre as 28 comparações par a par, com valores-p corrigidos por Benjamini-Hochberg (BH) [21] dentro de cada combinação. O procedimento é o mesmo para os quatro indicadores, pelas razões expostas na Seção III-D: com cinco observações por grupo, a ausência de rejeição em um teste de normalidade não comprova normalidade e não sustenta a escolha de um procedimento paramétrico; escolher o teste indicador por indicador tornaria os resultados não comparáveis entre indicadores; e a recomendação para algoritmos randomizados em engenharia de software é usar testes de postos em todos os casos [8]. Os resultados de Shapiro-Wilk e de Levene são relatados adiante e no Apêndice como descrição dos dados, sem papel na escolha do teste.

A Tabela V reúne os testes globais. Sete das oito combinações rejeitam a hipótese nula; a exceção é a ED média no *jPetStore*, onde não há evidência de diferença entre as oito configurações e, por isso, nenhum pós-hoc é calculado.

O tamanho do efeito foi avaliado pelo A12 de Vargha-Delaney [23], considerando a direção de melhoria de cada indicador. Valores acima de 0,5 favorecem a primeira configuração; valores abaixo de 0,5 favorecem a segunda. A classificação de magnitude considerou $d = |A12 - 0,5|$: desprezível para $d \leq 0,06$, pequena para $0,06 < d \leq 0,14$, média para $0,14 < d \leq 0,21$ e grande para $d > 0,21$.

A significância estatística e o tamanho do efeito foram interpretados conjuntamente. Um efeito grande sem significância descreve uma predominância observada, mas não estabelece diferença significativa. Da mesma forma, um resultado não significativo não demonstra equivalência entre configurações.

1) jPetStore:

a) HV.: Como é possível observar na Tabela VI e na Figura 7, a configuração 8 apresentou a maior média de HV (0,8287), mediana de 0,8561 e desvio-padrão de 0,0714. A maior mediana foi obtida pela configuração 2 (0,8803), cuja média foi 0,7931 e o desvio-padrão, 0,1686. As configurações 1, 3 e 4 apresentaram médias próximas de 0,80, mas maior dispersão que a configuração 8.

Tabela VI
JPETSTORE – HV – ANÁLISE DESCRITIVA.

Config.	n	Média	Mediana	DP	Mínimo	Máximo
1	5	0,7977	0,7119	0,1801	0,6406	1,0678
2	5	0,7931	0,8803	0,1686	0,6073	0,9422
3	5	0,7980	0,8489	0,1778	0,5904	1,0402
4	5	0,8089	0,7971	0,1303	0,6352	1,0024
5	5	0,5123	0,5066	0,0235	0,4905	0,5517
6	5	0,5495	0,5407	0,0431	0,4994	0,6182
7	5	0,5004	0,5045	0,0220	0,4650	0,5260
8	5	0,8287	0,8561	0,0714	0,7030	0,8756

DP: desvio-padrão amostral entre as cinco execuções. Maior HV indica melhor desempenho.

Na descrição dos dados, o teste de Shapiro-Wilk (Apêndice A, Tabela XVIII, com os gráficos quantil-quantil na Figura 9) rejeita a normalidade na configuração 8 ($p = 0,0142$) e Levene não detecta heterogeneidade das variâncias ($p = 0,1549$). O Kruskal-Wallis identificou diferença significativa entre os grupos ($H = 27,34$; $p < 0,001$).

Foram identificados 11 pares significativos, conforme tabela XIX do Apêndice A. As configurações 1, 2, 3 e 4 superaram 5 e 7, enquanto a configuração 8 superou 5, 6 e 7. Os valores de p ajustados variaram de 0,0187 a 0,0380. Todos esses efeitos foram grandes, com $A12 = 1$ quando orientados pela configuração favorecida e observados na tabela XX do Apêndice A.

Entre as cinco configurações em destaque, relembradas na Tabela VII, nenhum par foi significativo. O melhor valor descritivo da configuração 8, portanto, fica dentro da faixa de variação das configurações com Penalty.

Tabela VII
SISTEMA JPETSTORE - HV - CONFIGURAÇÕES EM DESTAQUE

id	Config
1	nsgaiii__elit_on__penalty
2	nsgaiii__elit_off__penalty
3	rnsgaiii__elit_on__penalty
4	rnsgaiii__elit_off__penalty
8	rnsgaiii__elit_off__kill

b) IGD+.: A configuração 8 apresentou a menor média (0,1706), mediana de 0,1590 e desvio-padrão de 0,0373, observados tanto na Tabela VIII quanto na Figura 7. A configuração 2 apresentou a menor mediana (0,1556), mas média de 0,2092 e maior dispersão (0,0898). Entre as configurações com Penalty, a configuração 4 teve a menor média (0,1952), com mediana de 0,1912 e desvio-padrão de 0,0594.

Na descrição dos dados, o Shapiro-Wilk rejeita a normalidade na configuração 2 ($p = 0,0320$) e Levene não detecta heterogeneidade ($p = 0,2055$), conforme a Tabela XXI e a Figura 10 do Apêndice B. O Kruskal-Wallis foi significativo ($H = 27,26$; $p < 0,001$).

Os 11 pares significativos reproduziram o padrão observado no HV: as configurações 1 a 4 superaram 5 e 7, e a configuração 8 superou 5, 6 e 7 (Apêndice B, Tabela XXII). Todas essas comparações apresentaram p ajustado de aproximadamente

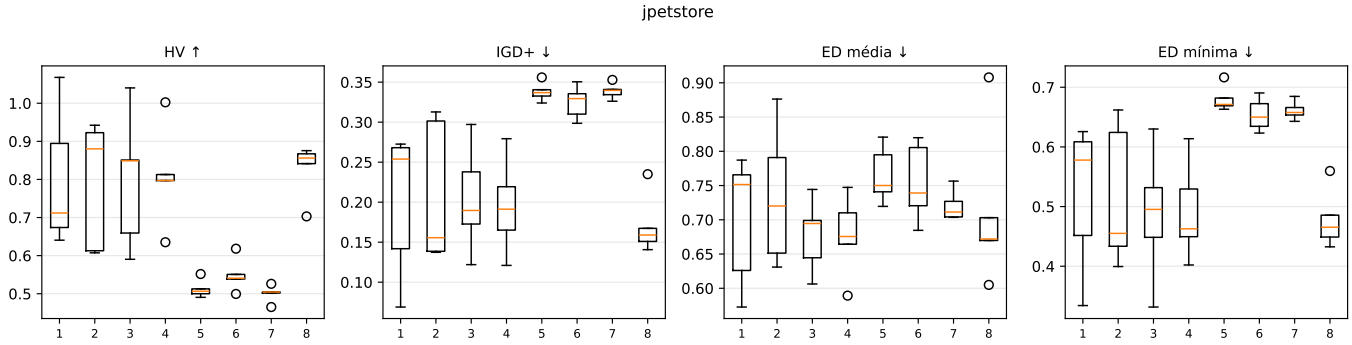


Figura 7. jPetStore: distribuição dos quatro indicadores nas cinco execuções de cada configuração. A seta ao lado do nome indica a direção de melhora.

Tabela VIII
JPETSTORE – IGD+ – ANÁLISE DESCRITIVA.

Config.	n	Média	Mediana	DP	Mínimo	Máximo
1	5	0,2011	0,2538	0,0913	0,0689	0,2726
2	5	0,2092	0,1556	0,0898	0,1373	0,3128
3	5	0,2038	0,1896	0,0666	0,1220	0,2971
4	5	0,1952	0,1912	0,0594	0,1210	0,2793
5	5	0,3380	0,3369	0,0118	0,3240	0,3559
6	5	0,3248	0,3295	0,0206	0,2986	0,3504
7	5	0,3388	0,3397	0,0098	0,3261	0,3528
8	5	0,1706	0,1590	0,0373	0,1407	0,2350

0,0204 e efeito grande, com $A12 = 1$ na direção favorável (Apêndice B, Tabela XXIII).

A concordância entre HV e IGD+ reforça o destaque das configurações 1, 2, 3, 4 e 8, mas não permite identificar uma vencedora estatística entre elas.

c) ED média.: Como observado na Tabela IX, as configurações 4 e 3 apresentaram as menores médias, respectivamente 0,6773 e 0,6777. Suas medianas foram 0,6756 e 0,6946, com desvios-padrão de 0,0589 e 0,0533. A configuração 8 apresentou a menor mediana (0,6720), mas média de 0,7115 e o maior desvio-padrão (0,1154). Os mesmos resultados aparecem na Figura 7.

Tabela IX
JPETSTORE - ED MÉDIA - ANÁLISE DESCRITIVA.

Config.	n	Média	Mediana	DP	Mínimo	Máximo
1	5	0,7006	0,7515	0,0952	0,5726	0,7871
2	5	0,7339	0,7202	0,1014	0,6310	0,8762
3	5	0,6777	0,6946	0,0533	0,6063	0,7443
4	5	0,6773	0,6756	0,0589	0,5893	0,7473
5	5	0,7652	0,7501	0,0414	0,7196	0,8207
6	5	0,7539	0,7391	0,0573	0,6846	0,8198
7	5	0,7205	0,7113	0,0222	0,7036	0,7565
8	5	0,7115	0,6720	0,1154	0,6049	0,9079

DP: desvio-padrão amostral entre as cinco execuções. Menores valores indicam melhor desempenho.

Na descrição dos dados, o Shapiro-Wilk não rejeita a normalidade em nenhum grupo (Tabela XXIV e Figura 11 do Apêndice C) e Levene não detecta heterogeneidade ($p = 0,6061$). O Kruskal-Wallis não identificou diferença significativa ($H = 8,89$; $p = 0,260$) e, por isso, não foram realizados testes pós-hoc. É a única das oito combinações de sistema e indicador em que o teste global não rejeita a hipótese nula.

Ainda assim, algumas comparações apresentaram efeitos grandes (Tabela XXV do Apêndice C): as configurações 3 e 4, por exemplo, ficam à frente da configuração 5 em todas as comparações de execuções, com $A12 = 0,92$. É uma predominância observada nos dados, não uma diferença estabelecida, já que o teste global não rejeitou a hipótese nula para este indicador.

d) ED mínima.: De acordo com a análise descritiva contida na Tabela X, a configuração 8 apresentou a menor média (0,4784), mediana de 0,4654 e desvio-padrão de 0,0495. As configurações 3 e 4 também apresentaram médias baixas, de 0,4874 e 0,4915, respectivamente. A menor mediana foi obtida pela configuração 2 (0,4550), cuja média foi 0,5148 e o desvio-padrão, 0,1195. A mesma informação aparece na Figura 7.

Tabela X
JPETSTORE - ED MÍNIMA - ANÁLISE DESCRITIVA.

Config.	n	Média	Mediana	DP	Mínimo	Máximo
1	5	0,5196	0,5779	0,1241	0,3341	0,6256
2	5	0,5148	0,4550	0,1195	0,3995	0,6619
3	5	0,4874	0,4952	0,1097	0,3316	0,6300
4	5	0,4915	0,4627	0,0821	0,4021	0,6138
5	5	0,6803	0,6712	0,0213	0,6632	0,7165
6	5	0,6541	0,6499	0,0274	0,6232	0,6904
7	5	0,6609	0,6577	0,0157	0,6429	0,6847
8	5	0,4784	0,4654	0,0495	0,4325	0,5596

DP: desvio-padrão amostral entre as cinco execuções. Menores valores indicam melhor desempenho.

Na descrição dos dados, o Shapiro-Wilk não rejeita a normalidade (Tabela XXVI e Figura 12 do Apêndice D) e Levene não detecta heterogeneidade ($p = 0,1689$). O Kruskal-Wallis foi significativo ($H = 25,78$; $p < 0,001$).

Dez pares apresentaram diferenças significativas (Tabela XXVII do Apêndice D). As configurações 1 e 2 superaram a 5; a configuração 3 superou 5 e 7; e as configurações 4 e 8 superaram 5, 6 e 7. Os valores de p ajustados variaram de 0,0209 a 0,0450, e todos esses efeitos foram grandes, com

$A12 = 1$ na direção favorável (Tabela XXVIII do Apêndice D).

Nenhuma diferença significativa foi detectada entre as configurações 1, 2, 3, 4 e 8. Portanto, a configuração 8 apresentou a melhor média, mas não superioridade estatística sobre as configurações com Penalty.

e) Resumo do sistema.: HV, IGD+ e ED mínima apresentaram resultados concordantes, destacando as configurações 1, 2, 3, 4 e 8. A configuração 8 obteve as melhores médias nesses três indicadores, sem superioridade estatística sobre as configurações com Penalty em nenhum deles.

A ED média é o único indicador em que o teste global não detectou diferença entre as oito configurações. Nos outros três, todas as diferenças significativas se dão de uma configuração com Penalty, ou da configuração 8, sobre uma das configurações 5, 6 e 7. Portanto, não foi identificada uma configuração superior em todos os indicadores.

2) spring-petclinic:

a) HV.: Como detalhado na Tabela XI e na Figura 8, a configuração 1 apresentou a maior média (1,0477) e a maior mediana (0,9901), mas também o maior desvio-padrão (0,2090). A configuração 4 apresentou média de 0,9814, mediana de 0,9728 e menor dispersão (0,0526).

Tabela XI
SPRING-PETCLINIC – HV – ANÁLISE DESCRITIVA.

Config.	n	Média	Mediana	DP	Mínimo	Máximo
1	5	1,0477	0,9901	0,2090	0,8705	1,3973
2	5	0,8915	0,8740	0,0458	0,8387	0,9518
3	5	0,8939	0,9116	0,0872	0,7955	1,0026
4	5	0,9814	0,9728	0,0526	0,9173	1,0466
5	5	0,6908	0,6838	0,0284	0,6692	0,7403
6	5	0,7262	0,7288	0,0259	0,6827	0,7486
7	5	0,6075	0,6099	0,0159	0,5826	0,6255
8	5	0,6502	0,6480	0,0469	0,5855	0,6968

DP: desvio-padrão amostral entre as cinco execuções. Maior HV indica melhor desempenho.

Na descrição dos dados, o Shapiro-Wilk (Tabela XXIX e Figura 13 do Apêndice E) rejeita a normalidade na configuração 5 ($p = 0,0390$) e Levene não detecta heterogeneidade ($p = 0,0639$). O Kruskal-Wallis identificou diferença significativa ($H = 33,97$; $p < 0,001$).

Foram identificados 11 pares significativos, conforme pode ser observado na Tabela XXX do Apêndice E. A configuração 1 superou 5, 7 e 8; as configurações 2 e 3 superaram 7 e 8; e a configuração 4 superou 5, 6, 7 e 8. Os valores de p ajustados variaram de 0,000874 a 0,0474. Todos esses efeitos foram grandes, com $A12 = 1$ na direção favorável (Tabela XXXI do Apêndice E).

A comparação entre 1 e 4 não foi significativa (p ajustado $= 0,9700$), e o efeito foi desprezível ($A12 = 0,52$), ou seja, as duas se alternam quase igualmente entre execuções. A maior média da configuração 1 não se traduz, assim, em vantagem sobre a configuração 4.

b) IGD+.: Pela Tabela XII e pela Figura 8, é possível observar que a configuração 1 apresentou a menor média (0,0966) e mediana (0,0929), com desvio-padrão de 0,0501. A configuração 4 apresentou média de 0,1095, mediana de 0,1127 e menor dispersão (0,0133).

Tabela XII
SPRING-PETCLINIC – IGD+ – ANÁLISE DESCRITIVA.

Config.	n	Média	Mediana	DP	Mínimo	Máximo
1	5	0,0966	0,0929	0,0501	0,0212	0,1589
2	5	0,1335	0,1345	0,0209	0,1109	0,1626
3	5	0,1255	0,1269	0,0255	0,0975	0,1618
4	5	0,1095	0,1127	0,0133	0,0871	0,1230
5	5	0,1929	0,1892	0,0227	0,1611	0,2153
6	5	0,1701	0,1658	0,0127	0,1610	0,1925
7	5	0,2465	0,2371	0,0201	0,2288	0,2776
8	5	0,2244	0,2332	0,0278	0,1943	0,2608

DP: desvio-padrão amostral entre as cinco execuções. Menores valores indicam melhor desempenho.

Na descrição dos dados, o Shapiro-Wilk rejeita a normalidade na configuração 6 ($p = 0,0125$), conforme a Tabela XXXII e a Figura 14 do Apêndice F, e Levene não detecta heterogeneidade ($p = 0,4250$). O Kruskal-Wallis foi significativo ($H = 33,01$; $p < 0,001$).

Dez pares apresentaram diferenças significativas (Tabela XXXIII do Apêndice F). As configurações 1 e 4 superaram 5, 7 e 8, enquanto 2 e 3 superaram 7 e 8. Os valores de p ajustados variaram de 0,00191 a 0,0308, com efeitos grandes e $A12 = 1$ nas direções favoráveis (Tabela XXXIV do Apêndice F).

Entre 1 e 4 não houve diferença significativa (p ajustado $= 0,9138$), e o $A12 = 0,56$ aponta uma leve predominância da configuração 1, insuficiente para separá-las.

c) ED média.: Como é mostrado na Tabela XIII e na Figura 8, a configuração 4 apresentou a menor média (0,6438) e mediana (0,6040), com desvio-padrão de 0,0847. A configuração 1 apresentou média de 0,6542, mediana de 0,6504 e menor dispersão (0,0635). É relevante destacar que as quatro configurações com Penalty (de 1 a 4) apresentaram médias inferiores às das configurações com Kill (5 a 8).

Tabela XIII
SPRING-PETCLINIC – ED MÉDIA – ANÁLISE DESCRITIVA.

Config.	n	Média	Mediana	DP	Mínimo	Máximo
1	5	0,6542	0,6504	0,0635	0,5772	0,7405
2	5	0,6961	0,6837	0,0372	0,6714	0,7619
3	5	0,6813	0,6443	0,0772	0,6064	0,7947
4	5	0,6438	0,6040	0,0847	0,5810	0,7879
5	5	0,8117	0,7923	0,0523	0,7563	0,8926
6	5	0,8005	0,7918	0,0468	0,7562	0,8631
7	5	0,8559	0,8609	0,0562	0,7728	0,9114
8	5	0,8612	0,8721	0,0328	0,8084	0,8874

DP: desvio-padrão amostral entre as cinco execuções. Menores valores indicam melhor desempenho.

Na descrição dos dados, o Shapiro-Wilk rejeita a normalidade na configuração 2 ($p = 0,0087$) e Levene não detecta heterogeneidade ($p = 0,8727$). O Kruskal-Wallis identificou

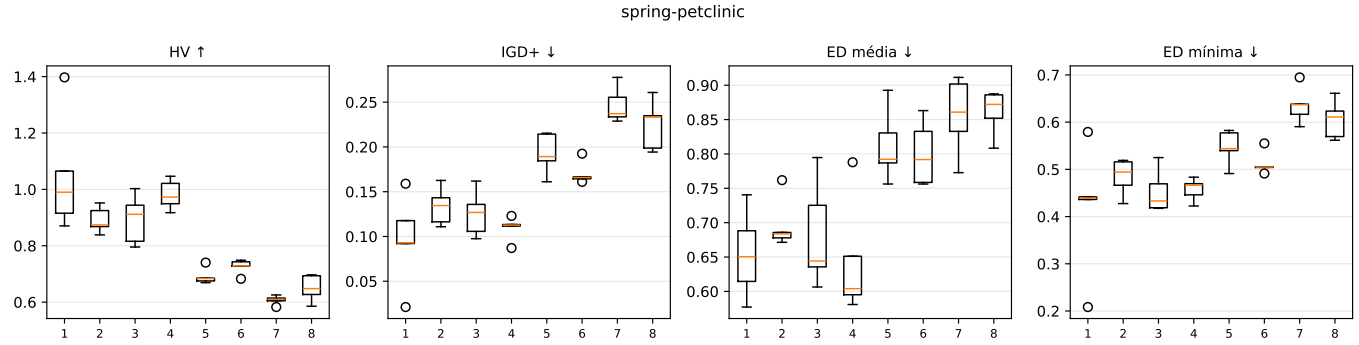


Figura 8. spring-petclinic: distribuição dos quatro indicadores nas cinco execuções de cada configuração. A seta ao lado do nome indica a direção de melhora.

diferença significativa ($H = 27,57$; $p < 0,001$). Para detalhamento ver a Tabela XXXV e a Figura 15 do Apêndice G

Nove pares permaneceram significativos (Tabela XXXVI do Apêndice G). As configurações 1, 2 e 3 superaram 7 e 8, enquanto a configuração 4 superou 5, 7 e 8. Os valores de p ajustados variaram de 0,0109 a 0,0399. Todos esses efeitos foram grandes, com A12 entre 0,92 e 1 quando orientados pela configuração favorecida (Tabela XXXVII do Apêndice G).

A comparação entre 1 e 4 não foi significativa (p ajustado $= 0,9138$). O $A12 = 0,44$, tomando a configuração 1 como primeira, indicou efeito desprezível favorável à configuração 4.

d) ED mínima.: Como é possível verificar na Tabela XIV e na Figura 8, a configuração 1 apresentou a menor média (0,4210), com mediana de 0,4393 e o maior desvio-padrão (0,1335). A configuração 3 apresentou a menor mediana (0,4331), média de 0,4527 e desvio-padrão de 0,0455. A configuração 4 apresentou média de 0,4576, mediana de 0,4665 e o menor desvio-padrão (0,0238).

Tabela XIV
SPRING-PETCLINIC – ED MÍNIMA – ANÁLISE DESCRITIVA.

Config.	n	Média	Mediana	DP	Mínimo	Máximo
1	5	0,4210	0,4393	0,1335	0,2084	0,5793
2	5	0,4846	0,4944	0,0382	0,4275	0,5190
3	5	0,4527	0,4331	0,0455	0,4175	0,5249
4	5	0,4576	0,4665	0,0238	0,4224	0,4834
5	5	0,5469	0,5438	0,0366	0,4911	0,5824
6	5	0,5121	0,5049	0,0247	0,4911	0,5550
7	5	0,6354	0,6369	0,0385	0,5904	0,6948
8	5	0,6053	0,6110	0,0408	0,5617	0,6611

DP: desvio-padrão amostral entre as cinco execuções. Menores valores indicam melhor desempenho.

Na descrição dos dados, o Shapiro-Wilk rejeita a normalidade na configuração 6 ($p = 0,0277$), conforme a Tabela XXXVIII e a Figura 16 do Apêndice H, e Levene não detecta heterogeneidade ($p = 0,4909$). O Kruskal-Wallis foi significativo ($H = 28,08$; $p < 0,001$).

Sete pares apresentaram diferenças significativas (Tabela XXXIX do Apêndice H). As configurações 1, 3 e 4 superaram 7 e 8, enquanto a configuração 2 superou 7. Os valores de p ajustados variaram de 0,00552 a 0,0196. Todos esses efeitos foram grandes: A12 de 0,92 na comparação favorável de 1 contra 8 e igual a 1 nas demais (Tabela XL do Apêndice H).

Nenhum par entre as configurações com Penalty foi significativo. O que se observa é uma divisão de méritos descritivos: a configuração 1 tem a melhor média, a 3 a melhor mediana e a 4 a maior regularidade, sem que os testes separem qualquer uma delas das outras.

e) Resumo do sistema.: Os quatro indicadores apresentaram um padrão favorável às configurações com Penalty. Todas as diferenças significativas ocorreram em favor de uma configuração com Penalty sobre uma configuração com Kill, embora nem todos os pares entre essas categorias tenham apresentado significância.

As configurações 1 e 4 destacaram-se por razões distintas. A configuração 1 apresentou as melhores médias de HV, IGD+ e ED mínima. A configuração 4 apresentou a melhor ED média e menor dispersão que a configuração 1 em três dos quatro indicadores. As comparações diretas não demonstraram superioridade estatística de uma sobre a outra.

f) Consolidação dos pós-hoc.: A Tabela XV reúne, em um só lugar, todos os pares significativos das oito combinações de sistema e indicador. Dois padrões ficam visíveis nela e sustentam a discussão da Seção IV-G. O primeiro é a direção: dos 69 pares significativos, nenhum aponta no sentido contrário ao descrito, isto é, não há um único caso em que uma das configurações 5, 6 ou 7 supere uma configuração com *penalty* ou a configuração 8. O segundo é quem perde: as configurações 7 e 8 concentram as derrotas no *spring-petclinic* e as configurações 5 e 7 no *jPetStore*, o que mostra que o conjunto das configurações com *kill* não se comporta de modo uniforme entre os dois sistemas.

F. Efeito de Cada Fator Isolado

A comparação entre as oito configurações, apresentada acima, sofre do tamanho de amostra discutido na Seção III-E: com cinco contra cinco e correção sobre 28 pares, o procedimento tem pouco poder. A análise por fator contorna parte dessa limitação ao agregar as execuções pelos dois níveis de um fator, deixando os outros dois variarem: 20 execuções

Tabela XV
PÓS-HOC DE DUNN COM CORREÇÃO DE BENJAMINI-HOCHBERG: PARES COM $p_{BH} < 0{,}05$. LÊ-SE $A > B$ COMO "A SUPEROU B". NENHUM PAR APONTOU NO SENTIDO CONTRÁRIO.

Sistema	Indicador	Pares significativos
spring-petclinic	HV	$1 > 5, 7, 8$; $2 > 7, 8$; $3 > 7, 8$; $4 > 5, 6, 7, 8$
spring-petclinic	IGD+	$1 > 5, 7, 8$; $2 > 7, 8$; $3 > 7, 8$; $4 > 5, 7, 8$
spring-petclinic	ED média	$1 > 7, 8$; $2 > 7, 8$; $3 > 7, 8$; $4 > 5, 7, 8$
spring-petclinic	ED mínima	$1 > 7, 8$; $2 > 7$; $3 > 7, 8$; $4 > 7, 8$
jpetstore	HV	$1 > 5, 7$; $2 > 5, 7$; $3 > 5, 7$; $4 > 5, 7$; $8 > 5, 6, 7$
jpetstore	IGD+	$1 > 5, 7$; $2 > 5, 7$; $3 > 5, 7$; $4 > 5, 7$; $8 > 5, 6, 7$
jpetstore	ED média	—
jpetstore	ED mínima	$1 > 5$; $2 > 5$; $3 > 5, 7$; $4 > 5, 6, 7$; $8 > 5, 6, 7$

contra 20, por sistema e por indicador. A Tabela XVI traz o resultado para os três fatores.

O quadro é nítido e se repete nas duas metades da tabela. O tratamento de restrições é o único fator que separa os resultados: a mediana das configurações com *penalty* é melhor nos quatro indicadores e nos dois sistemas, com diferença significativa em sete das oito combinações de sistema e indicador e tamanho de efeito grande em todas elas ($\hat{A}_{12}$ de 0,83 a 1,00). A única exceção é a ED média no *jPetStore*, em que a direção é a mesma ($\hat{A}_{12} = 0{,}66$, médio) mas o resultado não é significativo, e que é também a única combinação em que o teste global entre as oito configurações não rejeita a hipótese nula.

Algoritmo e elitismo, por outro lado, não são significativos em nenhuma das oito combinações. Os tamanhos de efeito do algoritmo ficam entre 0,29 e 0,61 e os do elitismo entre 0,33 e 0,50, isto é, em torno do valor neutro de 0,5. Vale notar que, no *jPetStore*, os dois fatores apresentam efeito médio e p_{Holm} entre 0,12 e 0,14 nos indicadores HV, IGD+ e ED mínima, sempre na direção de R-NSGA-III e de elitismo desligado: é um indício compatível com a posição da configuração 8 nesse sistema, não uma diferença estabelecida. Como discutido adiante, esse indício é exatamente aquele que o confundimento entre configuração e participante mais afeta.

Uma ressalva de leitura: esta é uma análise de efeito principal por fator, não um modelo fatorial com interações. Ela responde se, em média, trocar o nível de um fator muda o indicador, mas não detecta um efeito que exista apenas em combinação com outro fator. É por isso que ela coexiste com a comparação por configuração, e não a substitui.

G. Discussão dos Resultados

As duas análises apontam para a mesma direção, com granularidades diferentes. Por fator (Seção IV-F), o tratamento de restrições é o único dos três que separa os resultados, e Penalty leva vantagem nos quatro indicadores e nos dois sistemas. Por configuração, o padrão favorável a Penalty é mais consistente no spring-petclinic, enquanto no jPetStore a configuração 8 mostra que uma combinação específica com Kill também produz resultados competitivos. As duas leituras não se contradizem: a primeira descreve o efeito médio de trocar o nível de um fator, a segunda descreve combinações individuais, e é a configuração 8 que explica por que a vantagem média do Penalty no jPetStore é menor do que no spring-petclinic.

a) Comparação entre os algoritmos.: Para comparar NSGA-III e R-NSGA-III, foram examinados os pares que mantêm iguais o elitismo e o tratamento de restrições: 1 e 3, 2 e 4, 5 e 7, e 6 e 8.

No jPetStore, a configuração 8 superou a configuração 6 em HV e IGD+, com valores de p ajustados de 0,0380 e 0,0204, respectivamente, e $A12 = 1$ nas duas direções favoráveis. Ambas utilizam Kill e elitismo desligado e diferem apenas no algoritmo. Esse par, porém, não sustenta uma conclusão sobre o algoritmo: as execuções da configuração 8 no jPetStore foram conduzidas por um participante e as da configuração 6 por outro (Seção III-E), de modo que o efeito do algoritmo e o do estilo de interação são indistinguíveis nesse par. A análise por fator, que agrega os três participantes, não detecta diferença entre os algoritmos em nenhuma das oito combinações de sistema e indicador. Os demais pares que diferem somente no algoritmo também não apresentaram diferenças significativas.

No spring-petclinic, nenhum dos pares que diferem apenas no algoritmo apresentou diferença significativa nos quatro indicadores. O que falta é evidência, não diferença: nas condições avaliadas, nada distingue os dois algoritmos, mas isso está longe de demonstrar que sejam equivalentes.

b) Tratamento de restrições e elitismo.: O desempenho favorável de Penalty foi mais consistente no spring-petclinic. No jPetStore, a competitividade da configuração 8 impede uma recomendação universal contra Kill.

O elitismo apresenta o mesmo problema de atribuição. No jPetStore, a configuração 8 superou a configuração 7 em HV e IGD+; ambas utilizam R-NSGA-III e Kill e diferem apenas no elitismo, mas também foram conduzidas por participantes diferentes, o que torna o par descritivo e não conclusivo. No spring-petclinic, onde as configurações 1 e 2 e as configurações 7 e 8 formam pares de elitismo dentro de um mesmo participante, nenhuma dessas comparações é significativa. Somado à ausência de efeito do elitismo na análise por fator, o quadro é de ausência de evidência, não de evidência de equivalência.

Já a vantagem do Penalty não depende desse tipo de par frágil. No spring-petclinic, as configurações 1, 2, 7 e 8 foram conduzidas pelo mesmo participante, e os quatro pares que cruzam as estratégias nesse conjunto (1 contra 7, 1 contra 8, 2 contra 7 e 2 contra 8) são significativos e todos na mesma direção. É a única afirmação sobre fatores deste trabalho que se sustenta tanto na análise agregada quanto em comparações livres do confundimento entre configuração e participante.

c) Resposta à RQ1.: A RQ1 investiga qual configuração apresentou melhor desempenho em termos dos indicadores de

Tabela XVI
EFEITO DE CADA FATOR ISOLADO (20 EXECUÇÕES POR NÍVEL), COM WILCOXON RANK-SUM, p CORRIGIDO POR HOLM E $\hat{A}_{12}$ ORIENTADO (>0,5 FAVORECE O PRIMEIRO NÍVEL).

Sistema	Indicador	Fator	Níveis	p_{Holm}	$\hat{A}_{12}$
spring-petclinic	HV	Algoritmo	NSGA-III vs. R-NSGA-III	0,621	0,59 (pequeno)
spring-petclinic	HV	Elitismo	ligado vs. desligado	0,621	0,44 (pequeno)
spring-petclinic	HV	Restrição	penalty vs. kill	**<0,001**	1,00 (grande)
spring-petclinic	IGD+	Algoritmo	NSGA-III vs. R-NSGA-III	0,457	0,61 (pequeno)
spring-petclinic	IGD+	Elitismo	ligado vs. desligado	0,818	0,48 (desprezível)
spring-petclinic	IGD+	Restrição	penalty vs. kill	**<0,001**	0,99 (grande)
spring-petclinic	ED média	Algoritmo	NSGA-III vs. R-NSGA-III	0,914	0,57 (pequeno)
spring-petclinic	ED média	Elitismo	ligado vs. desligado	1,000	0,50 (desprezível)
spring-petclinic	ED média	Restrição	penalty vs. kill	**<0,001**	0,96 (grande)
spring-petclinic	ED mínima	Algoritmo	NSGA-III vs. R-NSGA-III	0,523	0,60 (pequeno)
spring-petclinic	ED mínima	Elitismo	ligado vs. desligado	0,871	0,48 (desprezível)
spring-petclinic	ED mínima	Restrição	penalty vs. kill	**<0,001**	0,93 (grande)
jpetstore	HV	Algoritmo	NSGA-III vs. R-NSGA-III	0,351	0,41 (pequeno)
jpetstore	HV	Elitismo	ligado vs. desligado	0,128	0,33 (médio)
jpetstore	HV	Restrição	penalty vs. kill	**<0,001**	0,85 (grande)
jpetstore	IGD+	Algoritmo	NSGA-III vs. R-NSGA-III	0,199	0,38 (pequeno)
jpetstore	IGD+	Elitismo	ligado vs. desligado	0,120	0,33 (médio)
jpetstore	IGD+	Restrição	penalty vs. kill	**<0,001**	0,84 (grande)
jpetstore	ED média	Algoritmo	NSGA-III vs. R-NSGA-III	0,077	0,29 (médio)
jpetstore	ED média	Elitismo	ligado vs. desligado	0,655	0,46 (desprezível)
jpetstore	ED média	Restrição	penalty vs. kill	0,182	0,66 (médio)
jpetstore	ED mínima	Algoritmo	NSGA-III vs. R-NSGA-III	0,136	0,33 (médio)
jpetstore	ED mínima	Elitismo	ligado vs. desligado	0,136	0,34 (médio)
jpetstore	ED mínima	Restrição	penalty vs. kill	**<0,001**	0,83 (grande)

qualidade. Os resultados não identificaram uma configuração estatisticamente superior em todos os cenários.

No jPetStore, as configurações 1, 2, 3, 4 e 8 destacaram-se em HV e IGD+, com vantagem descritiva da configuração 8 em vários indicadores. No spring-petclinic, o padrão favoreceu as configurações com Penalty, com destaque descritivo para 1 e 4. A primeira apresentou melhores médias em HV, IGD+ e ED mínima; a segunda apresentou menor ED média e maior regularidade em parte dos indicadores.

Assim, a resposta à RQ1 depende do sistema, do indicador e da importância atribuída à regularidade entre execuções. A escolha não deve se apoiar exclusivamente na maior média ou na contagem de comparações favoráveis.

A análise por fator (Seção IV-F) dá à RQ1 uma resposta mais estável do que a comparação entre configurações, ainda que em outro nível: nenhuma configuração é superior em todos os cenários, mas há um *fator* que importa e dois que não. Trocar a estratégia de tratamento de restrições de Kill para Penalty melhora a mediana dos quatro indicadores nos dois sistemas, com efeito grande; trocar o algoritmo ou o elitismo não produz diferença detectável em nenhuma das oito combinações de sistema e indicador. Para quem precisa configurar a ferramenta, essa é a recomendação acionável, e ela não depende de escolher uma entre oito combinações.

A isso soma-se o critério introduzido na Seção IV-C: entre 88% e 100% das arquiteturas devolvidas pelas configurações com *penalty* têm ao menos um microsserviço fora da faixa de tamanho do problema, contra 0% a 24% das configurações com *kill*. Como os indicadores são calculados sobre as fronteiras devolvidas, sem verificar a restrição, parte da vantagem observada nas configurações com *penalty* corresponde a soluções que o experimento define como inválidas. A resposta à RQ1, portanto, depende também de quanto peso se dá à validade das arquiteturas: considerando apenas os indicadores, as configurações com *penalty* se destacam; exigindo arquiteturas dentro da faixa, as configurações com *kill* são as que entregam esse resultado de forma consistente.

d) Resposta à RQ2.: A RQ2 investiga se as soluções retornadas estão condizentes com as preferências da persona. Para a P2, isso exige verificar a redução de acoplamento e overhead, considerando os compromissos em coesão, funcionalidade e reúso.

Os indicadores agregados apresentados não demonstram, isoladamente, esse atendimento. HV e IGD+ avaliam a qualidade da fronteira segundo as referências adotadas, enquanto a ED mede distância ao ideal matemático, sem representar explicitamente as prioridades da persona.

Os indicadores agregados, isoladamente, portanto não respondem à RQ2. Responder exige percorrer a cadeia completa: o que a persona declara preferir, o que ela de fato fez nas pausas e o que a ferramenta devolveu.

O que a persona fez.: A Tabela XVII registra as operações aplicadas nas 240 pausas (80 execuções $\times$ 3 pontos de interação). Duas conformidades e uma não conformidade se destacam. As operações usadas foram apenas mover componentes em lote (145 das 151 operações) e dividir um microsserviço (6); as operações de unir e congelar, proibidas para a P2, não ocorreram nenhuma vez, e o número inicial de quatro microsserviços nunca foi alterado. A seleção do candidato também variou como a persona prescreve: 83 índices distintos foram escolhidos ao longo das 240 pausas, e o primeiro candidato da lista foi escolhido apenas 7 vezes.

Tabela XVII
CONFORMIDADE DA INTERAÇÃO DA PERSONA, POR CONFIGURAÇÃO: EDIÇÕES APLICADAS SOBRE A SOLUÇÃO ESCOLHIDA EM CADA UM DOS 15 PONTOS DE INTERAÇÃO (5 EXECUÇÕES × 3 PAUSAS).

Config.	Pausas	Sem edição	Mover	Dividir
spring-petclinic				
1	15	7	13	0
2	15	6	9	0
3	15	10	5	0
4	15	11	4	0
5	15	4	15	0
6	15	3	19	0
7	15	5	14	0
8	15	7	8	0
jPetStore				
1	15	6	16	0
2	15	5	14	0
3	15	15	0	0
4	15	15	0	0
5	15	8	8	0
6	15	8	9	0
7	15	7	10	0
8	15	8	1	6

"Sem edição": pausas em que o decisor apenas selecionou um candidato e retomou a busca, sem aplicar nenhuma operação. "Mover" e "Dividir": número de operações *MOVE_COMPONENT* e *SPLIT_MICROSERVICE* registradas. As operações de unir e congelar, proibidas para a persona P2, não ocorreram em nenhuma das 240 pausas.

A não conformidade é mais séria: em 125 das 240 pausas (52%) o decisor apenas selecionou um candidato e retomou a busca, sem aplicar nenhuma edição, contrariando o protocolo da persona, para quem mover métodos em lote é a operação principal. E essa omissão não se distribui por igual: nas configurações 3 e 4 do *jPetStore* não houve *nenhuma* edição em nenhuma das 30 pausas, e o participante que conduziu essas duas configurações aplicou 16 operações em 75 pausas, contra 61 e 74 dos outros dois.

O que foi devolvido.: As Seções IV-A e IV-B mostram que os dois objetivos declarados como primários pela persona, acoplamento e *overhead* de rede, são os que mais melhoram ao longo da execução e os que mais separam as configurações ao final. Coesão e funcionalidade, objetivos secundários, melhoram menos e estacionam nas configurações com *kill*. O reúso, que a persona apenas mantém estável, é constante em 1,0 no *spring-petclinic* e varia em 2,7% das soluções finais do *jPetStore*, sem tendência, de modo que não houve compromisso real a negociar nesse eixo. Nesse sentido, o perfil do que é devolvido é compatível com o perfil declarado da persona.

O que não se pode concluir.: A compatibilidade acima não demonstra que ela decorra das escolhas da persona, e os dados de interação mostram por quê. As configurações 3 e 4 no *jPetStore*, que não receberam nenhuma edição humana, estão entre as de menor acoplamento mediano (133) e menor *overhead* do sistema. Ou seja, o perfil favorável aos objetivos primários da P2 aparece mesmo quando a interação se reduz a escolher um candidato e seguir. Isso tem duas leituras, e a mais defensável é a segunda: ou a simples seleção de um candidato já transmite preferência suficiente à busca, ou o que se observa é efeito da estratégia de tratamento de restrições e da própria evolução, e não da preferência expressa. Sem um braço de controle sem interação, o experimento não distingue as duas. A resposta à RQ2, portanto, é que as soluções devolvidas são *compatíveis* com as preferências da P2, mas o desenho não sustenta a afirmação de que sejam *consequência* delas.

e) Limitações e implicações.: As cinco execuções por configuração limitam a precisão das estimativas e a capacidade dos testes de detectar diferenças. Por isso, a ausência de significância não foi interpretada como equivalência, e os tamanhos de efeito foram utilizados como informação complementar.

O procedimento de correção também influencia as conclusões, e a distinção entre evidência global e evidência por par deve ser preservada na interpretação. Uma versão anterior desta análise selecionava o teste global por indicador, a partir de Shapiro-Wilk e Levene, e aplicava BH sobre valores-p já ajustados pelo Tukey; nessa configuração, a ED mínima do jPetStore apresentava evidência global de diferença sem nenhum par significativo. O procedimento único adotado aqui (Seção III-D) elimina esse duplo ajuste e identifica dez pares nesse indicador, o que mostra o quanto a escolha do procedimento, e não apenas o tamanho da amostra, condiciona o que se consegue detectar.

O ajuste BH foi realizado dentro de cada sistema e indicador, sem correção conjunta entre todos os indicadores. Além disso, as conclusões estão restritas aos dois sistemas e à persona avaliados. A atuação repetida do mesmo participante em uma mesma configuração pode introduzir aprendizagem, fadiga e influência da ordem das execuções; no caso deste experimento, a Tabela XVII mostra que isso não ficou no plano hipotético, já que a intensidade da interação variou sistematicamente entre configurações. Esse é o limite mais sério do desenho e a principal prioridade para uma replicação.

Como implicação prática, as configurações com Penalty constituem alternativas iniciais promissoras, mas sua escolha deve ser confirmada no sistema-alvo. A configuração 8 no jPetStore demonstra a importância de avaliar a combinação completa de parâmetros. A seleção final deve conciliar qualidade global, regularidade entre execuções e atendimento às preferências do DM.

V. SUGESTÕES DE MELHORIAS PARA A FERRAMENTA

As sugestões a seguir não são especulativas: cada uma vem de uma dificuldade concreta encontrada ao conduzir as 80 execuções ou de um comportamento observado nos artefatos que a ferramenta exportou.

a) Usabilidade e acompanhamento das decisões.: Conduzir 80 execuções sob a mesma persona exige saber, a cada tela, em que execução se está. A ferramenta não exibe essa informação, e o risco de lapso por fadiga é real quando a mesma sequência de decisões se repete dezenas de vezes. Sugerimos que o título da tela de edição dos microsserviços traga o sistema-alvo, a persona e o número da execução em curso. Na mesma linha, a tela deveria mostrar o que já foi

aplicado naquela pausa e nas anteriores: a Tabela XVII mostra que em 52% das pausas nenhuma edição foi registrada, e parte disso é plausivelmente omissão involuntária, não decisão deliberada. Um resumo visível das operações aplicadas, com confirmação explícita ao retomar a busca sem nenhuma edição, tornaria a diferença entre "não quis editar" e "esqueci de editar" observável tanto para o participante quanto para quem analisa os dados depois.

b) Configuração dos algoritmos.: A ferramenta não expõe controle da semente aleatória: o campo *seed* aparece nulo em todas as 80 execuções registradas, o que impede reexecutar uma execução e obter o mesmo resultado. Para um experimento controlado isso é uma limitação séria, e foi a razão de adotarmos cinco repetições por configuração apenas para absorver a variação. Expor a semente, e registrá-la no arquivo de parâmetros, permitiria reprodução exata e depuração de execuções anômalas. Sugerimos também tornar visível na interface o fator de escala da penalidade (*penaltyScalingFactor*, fixado em 10,0 nas execuções deste estudo), já que é ele que determina o quanto uma solução inválida é penalizada e, portanto, quanto do efeito observado na Seção IV-F depende dessa calibração.

c) Indicadores e visualizações.: A sugestão mais importante decorre do principal achado deste trabalho: a ferramenta devolve ao arquiteto, sem nenhuma marcação, soluções que violam a restrição de tamanho do próprio problema, e com a estratégia *penalty* isso acontece em 88% a 100% das arquiteturas devolvidas (Seção IV-C). Bastaria sinalizar na interface, em cada solução da fronteira, se ela respeita a faixa de tamanho, e informar qual é a faixa em número de elementos, para que o decisor não escolha uma arquitetura inválida sem saber. Dois acréscimos simples ajudariam na mesma direção: exibir o tamanho de cada microsserviço ao lado da solução e permitir filtrar a fronteira apenas pelas soluções válidas.

Ainda sobre o que é exibido, a fronteira devolvida contém duplicatas em proporção alta e variável: das 132 soluções da população final, o número de pontos distintos variou de 29 a 131 entre as execuções (Seção IV). Como os indicadores de qualidade de fronteira premiam cobertura, informar a cardinalidade efetiva e o número de duplicatas evitaria que o decisor interprete como diversidade o que é repetição.

d) Desempenho computacional e monitoramento.: Recomenda-se apresentar separadamente o tempo computacional ativo, o tempo de interação e o tempo total de execução. Hoje só o tempo decorrido é registrado, o que mistura o custo do algoritmo com o tempo de decisão do usuário e inviabiliza qualquer comparação de custo entre configurações, como discutido na Seção III-D.

e) Comportamentos que merecem verificação.: Dois pontos observados nos artefatos não são sugestões de interface, mas possíveis defeitos que vale verificar. O primeiro é o objetivo de reúso: ele assume um único valor (1,0) em todas as 40 execuções do *spring-petclinic* e varia em apenas 2,7% das soluções finais do *jPetStore*, o que significa que, nesses dois sistemas, a formulação opera na prática sobre quatro objetivos, e não cinco. Vale confirmar se isso decorre da natureza dos sistemas-alvo, do número de microsserviços fixado em quatro ou de um problema na métrica, pois o argumento para usar um algoritmo *many-objective* se apoia justamente na quantidade de objetivos.

O segundo é a base de cálculo da restrição de tamanho. Os limites aplicados pela ferramenta usam o grafo completo, incluindo o nó sintético de entrada, o que produz uma faixa de 1,4 a 20,4 elementos no *spring-petclinic*, enquanto o sistema tem 67 métodos reais (Seção III-B). A diferença é pequena, mas o nó sintético não é um método que possa ser alocado por critérios de projeto, e incluí-lo na base da restrição é no mínimo contraintuitivo para quem tenta reproduzir os limites a partir do tamanho do sistema.

VI. Considerações Finais

Este trabalho apresentou uma avaliação empírica de diferentes configurações de algoritmos evolutivos aplicados à modernização de sistemas legados para arquiteturas de microsserviços, utilizando a ferramenta interativa *i-toMicroservices*. O estudo teve como objetivo investigar o desempenho das configurações considerando indicadores de qualidade multiobjetivo, bem como analisar a relação entre as soluções obtidas e as preferências estabelecidas por uma persona durante o processo de otimização.

Para a realização do experimento, foram utilizados os sistemas *jPetStore* e *spring-petclinic*, considerando oito configurações resultantes da combinação dos algoritmos NSGA-III e R-NSGA-III, da ativação ou desativação do elitismo e das estratégias de tratamento de restrições *Penalty* e *Kill*. Cada configuração foi executada cinco vezes por sistema, totalizando 80 execuções independentes, com 1.000 gerações cada. A avaliação foi conduzida por meio de quatro indicadores de desempenho, o Hypervolume (HV), o Inverted Generational Distance Plus (IGD+) e a distância euclidiana ao ponto ideal nas versões média e mínima, complementados pela análise das arquiteturas devolvidas e por testes estatísticos não paramétricos para verificar a significância das diferenças observadas.

Os resultados demonstraram que o desempenho das configurações varia conforme as características do sistema analisado e o indicador de qualidade considerado. No sistema jPetStore, as configurações 1, 2, 3, 4 e 8 apresentaram resultados favoráveis nos indicadores HV e IGD+, com destaque para a configuração 8, composta pelo algoritmo R-NSGA-III, elitismo desativado e estratégia *Kill*. Entretanto, não foram identificadas diferenças estatisticamente significativas que comprovassem sua superioridade em relação às configurações que utilizaram *Penalty* nesses indicadores.

No sistema *spring-petclinic*, observou-se um comportamento mais consistente em favor das configurações que utilizaram a estratégia *Penalty*. A configuração 1, baseada no NSGA-III com elitismo ativado, apresentou as melhores médias de HV, IGD+ e distância euclidiana mínima, enquanto a configuração 4, baseada no R-NSGA-III com elitismo desativado, apresentou melhor desempenho médio na distância euclidiana

média e maior regularidade em parte dos indicadores. Apesar dessas diferenças, as análises estatísticas não permitiram estabelecer uma configuração universalmente superior.

Em relação à primeira questão de pesquisa (RQ1), conclui-se que nenhuma das oito configurações é estatisticamente superior em todos os cenários, mas que a comparação por fator isolado, com 20 execuções contra 20, identifica um fator que importa e dois que não. O tratamento de restrições é o único dos três que separa os resultados: a mediana das configurações com *Penalty* é melhor nos quatro indicadores e nos dois sistemas, com diferença significativa em sete das oito combinações de sistema e indicador e tamanho de efeito grande em todas elas. Algoritmo e elitismo não são significativos em nenhuma combinação, e as duas únicas comparações par a par que sugeriam vantagem do R-NSGA-III e do elitismo desligado opõem execuções de participantes diferentes, de modo que não sustentam conclusão sobre esses fatores.

Essa vantagem do *Penalty*, no entanto, vem acompanhada de uma ressalva que inverte a leitura prática do resultado: de 88% a 100% das arquiteturas devolvidas pelas configurações com *Penalty* têm ao menos um microsserviço fora da faixa de tamanho definida pelo próprio problema, contra 0% a 24% das configurações com *Kill*. Como os indicadores são calculados sobre as fronteiras devolvidas, sem verificar a restrição, parte da vantagem medida corresponde a soluções que o experimento define como inválidas e que um arquiteto dificilmente aceitaria. A resposta à RQ1 depende, portanto, do critério: pelos indicadores agregados, as configurações com *Penalty* se destacam; exigindo arquiteturas dentro da faixa, são as configurações com *Kill* que entregam esse resultado de forma consistente.

Quanto à segunda questão de pesquisa (RQ2), relacionada à correspondência entre as soluções produzidas e as preferências da persona P2-Systematic-Decoupler, os indicadores agregados não respondem isoladamente, porque não representam as prioridades estabelecidas pela persona, especialmente a redução do acoplamento e do *overhead* de comunicação. A análise complementar dos objetivos arquiteturais, da evolução do *fitness* e das decisões registradas em cada pausa mostra que o perfil do que é devolvido é compatível com o perfil declarado da persona: acoplamento e *overhead* são os objetivos que mais melhoram e os que mais separam as configurações, enquanto os secundários melhoram menos e o reúso praticamente não varia. A mesma análise, porém, impede afirmar causalidade. Em pouco mais da metade das 240 pausas nenhuma edição foi aplicada, e duas combinações de configuração e sistema não receberam nenhuma edição humana, ainda assim figurando entre as de menor acoplamento mediano. Sem um braço de controle sem interação, não é possível distinguir o efeito das preferências expressas do efeito da própria busca. A resposta à RQ2 é, portanto, que as soluções devolvidas são compatíveis com as preferências da P2, mas o desenho não sustenta que sejam consequência delas.

Entre as limitações do estudo, destacam-se a utilização de apenas dois sistemas de referência, o número reduzido de execuções por configuração, a participação de uma única persona no processo interativo e, sobretudo, o confundimento entre configuração e participante: cada combinação de configuração e sistema foi conduzida integralmente por um único autor, e a intensidade com que cada um aplicou as edições da persona variou de forma sistemática entre configurações. Esses fatores restringem a generalização dos resultados e indicam a necessidade de novas avaliações em diferentes contextos. Além disso, a natureza estocástica dos algoritmos evolutivos reforça a importância de considerar tanto o desempenho médio quanto a variabilidade das soluções produzidas.

Como trabalhos futuros, sugere-se, em primeiro lugar, uma replicação em que cada participante execute todas as configurações, de modo a separar o efeito da configuração do efeito de quem interage, acompanhada de um braço de controle sem interação, que permitiria atribuir à preferência expressa o que hoje só se pode chamar de compatibilidade. Sugere-se também ampliar a avaliação para outros sistemas legados, aumentar o número de execuções independentes e considerar diferentes perfis de arquitetos e estratégias de interação. Recomenda-se também investigar métricas capazes de relacionar diretamente as preferências dos usuários às características arquiteturais das soluções, além de aprimorar os mecanismos de visualização, configuração e acompanhamento do processo de otimização disponibilizados pela ferramenta.

Por fim, os resultados deste estudo evidenciam a importância de uma avaliação sistemática das configurações utilizadas na otimização interativa da decomposição de sistemas monolíticos. A principal contribuição não é eleger uma configuração, e sim mostrar que a comparação por indicadores agregados, tomada isoladamente, favorece de forma sistemática as configurações que admitem soluções inválidas. Assim, a escolha de uma estratégia de otimização deve considerar não apenas os indicadores de qualidade das fronteiras, mas também a validade e a composição das arquiteturas devolvidas, a estabilidade entre execuções e a adequação às preferências do responsável pela tomada de decisão.

Referências

[1] M. Harman, S. A. Mansouri, and Y. Zhang, "Search-based software engineering: Trends, techniques and applications," *ACM Comput. Surv.*, vol. 45, no. 1, Art. no. 11, Nov. 2012.

[2] O. Räihä, "A survey on search-based software design," *Comput. Sci. Rev.*, vol. 4, no. 4, pp. 203–249, 2010.

[3] W. K. G. Assunção, T. E. Colanzi, L. Carvalho, A. Garcia, J. A. Pereira, M. J. de Lima, and C. Lucena, "Analysis of a many-objective optimization approach for identifying microservices from legacy systems," *Empirical Software Engineering*, vol. 27, no. 2, Art. no. 51, 2022. doi: 10.1007/s10664-021-10049-7.

[4] J. Castanho, C. G. Britez, W. M. Freire, A. M. M. M. Amaral, T. E. Colanzi, and W. K. G. Assunção, "Human in the loop for microservice identification: An exploratory study," in *Anais do XX Simpósio Brasileiro de Componentes, Arquiteturas e Reutilização de Software (SBCARS)*, 2026.

[5] D. Blasco, A. Iglesias, J. Echeverría, F. Pérez, and C. Cetina, "Introducing phylogenetics in search-based software engineering: Phylogenetics-aware SBSE," *ACM Trans. Softw. Eng. Methodol.*, vol. 34, no. 7, Art. no. 193, Aug. 2025.

[6] E. Zitzler and L. Thiele, "Multiobjective evolutionary algorithms: a comparative case study and the strength Pareto approach," *IEEE Transactions on Evolutionary Computation*, vol. 3, no. 4, pp. 257–271, Nov. 1999.

[7] H. Ishibuchi, H. Masuda, Y. Tanigaki, and Y. Nojima, "Modified distance calculation in generational distance and inverted generational distance," in *Evolutionary Multi-Criterion Optimization (EMO 2015)*, Lecture Notes in Computer Science, vol. 9019, Guimarães, Portugal, 2015, pp. 110–125. doi: 10.1007/978-3-319-15892-1_8.

[8] A. Arcuri and L. Briand, "A Hitchhiker's guide to statistical tests for assessing randomized algorithms in software engineering," *Software Testing, Verification and Reliability*, vol. 24, no. 3, pp. 219–250, 2014.

[9] M. Harman and B. F. Jones, "Search-based software engineering," *Inf. Softw. Technol.*, vol. 43, no. 14, pp. 833–839, 2001.

[10] S. Mirjalili, P. Jangir, S. Z. Mirjalili, S. Saremi, and I. N. Trivedi, "Optimization of problems with multiple objectives using the multi-verse optimization algorithm," *Knowledge-Based Systems*, 2017. doi: 10.1016/j.knosys.2017.07.018.

[11] K. Deb and H. Jain, "An evolutionary many-objective optimization algorithm using reference-point-based nondominated sorting approach, Part I: Solving problems with box constraints," *IEEE Transactions on Evolutionary Computation*, vol. 18, no. 4, pp. 577–601, 2014.

[12] I. Das and J. E. Dennis, "Normal-boundary intersection: A new method for generating the Pareto surface in nonlinear multicriteria optimization problems," *SIAM Journal on Optimization*, vol. 8, no. 3, pp. 631–657, Aug. 1998. doi: 10.1137/S1052623496307510.

[13] Y. Vesikar, K. Deb, and J. Blank, "Reference Point Based NSGA-III for Preferred Solutions," in *2018 IEEE Symposium Series on Computational Intelligence (SSCI)*, Bangalore, India, 2018, pp. 1587–1594. doi: 10.1109/SSCI.2018.8628819.

[14] K. Bennett, "Legacy systems: coping with success," *IEEE Software*, vol. 12, no. 1, pp. 19–23, Jan. 1995. doi: 10.1109/52.363157.

[15] D. Taibi, V. Lenarduzzi, and C. Pahl, "Processes, motivations, and issues for migrating to microservices architectures: An empirical investigation," *IEEE Cloud Computing*, vol. 4, no. 5, pp. 22–32, Sep. 2017. doi: 10.1109/MCC.2017.4250931.

[16] F. Ponce, G. Márquez, and H. Astudillo, "Migrating from monolithic architecture to microservices: A Rapid Review," in *2019 38th International Conference of the Chilean Computer Science Society (SCCC)*, Concepción, Chile, 2019, pp. 1–7. doi: 10.1109/SCCC49216.2019.8966423.

[17] J. Fritzsch, J. Bogner, A. Zimmermann, and S. Wagner, "From monolith to microservices: A classification of refactoring approaches," in *Software Engineering Aspects of Continuous Development and New Paradigms of Software Production and Deployment (DEVOPS 2018)*, Lecture Notes in Computer Science, 2019, pp. 128–141. doi: 10.1007/978-3-030-06019-0_10.

[18] W. Jin, T. Liu, Y. Cai, R. Kazman, R. Mo, and Q. Zheng, "Service candidate identification from monolithic systems based on execution traces," *IEEE Transactions on Software Engineering*, vol. 47, no. 5, pp. 987–1007, May 2021. doi: 10.1109/TSE.2019.2910531.

[19] H. Jain and K. Deb, "An evolutionary many-objective optimization algorithm using reference-point based nondominated sorting approach, Part II: Handling constraints and extending to an adaptive approach," *IEEE Transactions on Evolutionary Computation*, vol. 18, no. 4, pp. 602–622, 2014.

[20] O. J. Dunn, "Multiple comparisons using rank sums," *Technometrics*, vol. 6, no. 3, pp. 241–252, Aug. 1964. doi: 10.1080/00401706.1964.10490181.

[21] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: A practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society, Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.

[22] S. Holm, "A simple sequentially rejective multiple test procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

[23] A. Vargha and H. D. Delaney, "A critique and improvement of the CL common language effect size statistics of McGraw and Wong," *Journal of Educational and Behavioral Statistics*, vol. 25, no. 2, pp. 101–132, 2000.

[24] W. H. Kruskal and W. A. Wallis, "Use of ranks in one-criterion variance analysis," *Journal of the American Statistical Association*, vol. 47, no. 260, pp. 583–621, 1952.

APÊNDICE A
JPETSTORE - INDICADOR: HV

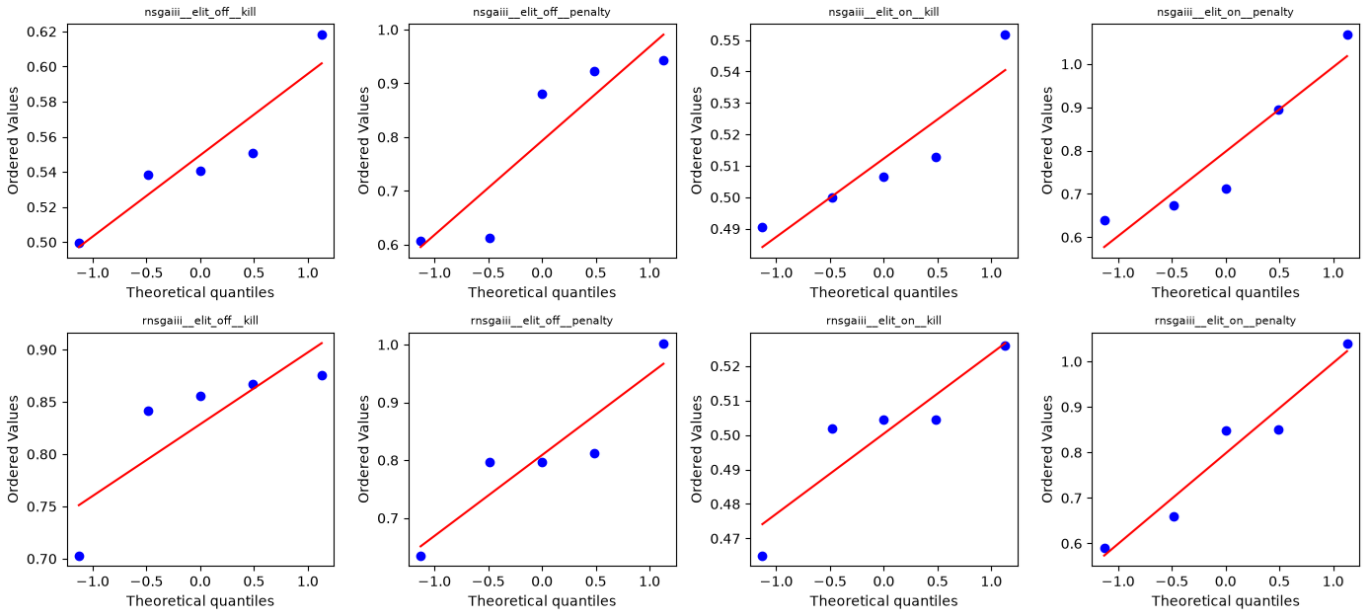


Figura 9. Análise descritiva - jPetStore - HV

Tabela XVIII
JPETSTORE – HV – TESTE DE SHAPIRO–WILK.

Config.	n	W	p	Rejeita normalidade?
1	5	0,876635	0,294341	Não
2	5	0,778114	0,053098	Não
3	5	0,942935	0,686754	Não
4	5	0,904857	0,437312	Não
5	5	0,865424	0,248386	Não
6	5	0,902612	0,424493	Não
7	5	0,874082	0,283350	Não
8	5	0,716795	0,014235	Sim

Decisão com $\alpha = 0{,}05$. Não rejeitar a hipótese de normalidade não comprova que a distribuição seja normal.

Tabela XIX
SISTEMA JPETSTORE - HV - PÓS-HOC E CORREÇÃO DE FDR-BH

A	B	z	p_{Dunn}	p_{BH}	Signif.?
1	2	0,0271	0,978420	0,978420	Não
1	3	0,1894	0,849818	0,961061	Não
1	4	0,1623	0,871069	0,961061	Não
1	5	2,8132	0,004905	0,018668	Sim
1	6	2,2722	0,023074	0,053325	Não
1	7	3,0296	0,002449	0,018668	Sim
1	8	−0,1623	0,871069	0,961061	Não
2	3	0,1623	0,871069	0,961061	Não
2	4	0,1353	0,892414	0,961061	Não
2	5	2,7862	0,005334	0,018668	Sim
2	6	2,2452	0,024758	0,053325	Não
2	7	3,0026	0,002677	0,018668	Sim
2	8	−0,1894	0,849818	0,961061	Não
3	4	−0,0271	0,978420	0,978420	Não
3	5	2,6239	0,008694	0,024343	Sim
3	6	2,0829	0,037264	0,069560	Não
3	7	2,8403	0,004508	0,018668	Sim
3	8	−0,3517	0,725100	0,961061	Não
4	5	2,6509	0,008028	0,024343	Sim
4	6	2,1099	0,034866	0,069560	Não
4	7	2,8673	0,004140	0,018668	Sim
4	8	−0,3246	0,745483	0,961061	Não
5	6	−0,5410	0,588506	0,961061	Não
5	7	0,2164	0,828675	0,961061	Não
5	8	−2,9755	0,002925	0,018668	Sim
6	7	0,7574	0,448809	0,785415	Não
6	8	−2,4345	0,014912	0,037958	Sim
7	8	−3,1919	0,001413	0,018668	Sim

z: estatística de Dunn, com sinal correspondente à ordem A–B. p_{Dunn}: valor antes do BH; p_{BH}: valor ajustado para os 28 pares. Significância definida por $p_{\mathrm{BH}} \leq 0{,}05$.

Tabela XX
SISTEMA JPETSTORE - HV - ANÁLISE DE GRANDEZA DE EFEITO (A12) ENTRE AS CONFIGURAÇÕES

A	B	A12(A,B)	Favorece config.	Magnitude
1	2	0,56	1	Desprezível
1	3	0,56	1	Desprezível
1	4	0,48	4	Desprezível
1	5	1,00	1	Grande
1	6	1,00	1	Grande
1	7	1,00	1	Grande
1	8	0,44	8	Desprezível
2	3	0,56	2	Desprezível
2	4	0,48	4	Desprezível
2	5	1,00	2	Grande
2	6	0,92	2	Grande
2	7	1,00	2	Grande
2	8	0,60	2	Pequena
3	4	0,56	3	Desprezível
3	5	1,00	3	Grande
3	6	0,96	3	Grande
3	7	1,00	3	Grande
3	8	0,36	8	Pequena
4	5	1,00	4	Grande
4	6	1,00	4	Grande
4	7	1,00	4	Grande
4	8	0,32	8	Média
5	6	0,28	6	Grande
5	7	0,60	5	Pequena
5	8	0,00	8	Grande
6	7	0,84	6	Grande
6	8	0,00	8	Grande
7	8	0,00	8	Grande

A12 orientado pela direção de melhoria: valores maiores que 0,5 favorecem A e menores que 0,5 favorecem B. Magnitude definida por $d = |A12 - 0{,}5|$: desprezível até 0,06; pequena até 0,14; média até 0,21; grande acima de 0,21. A12 não determina significância estatística.

APÊNDICE B
JPETSTORE - INDICADOR: IGD+

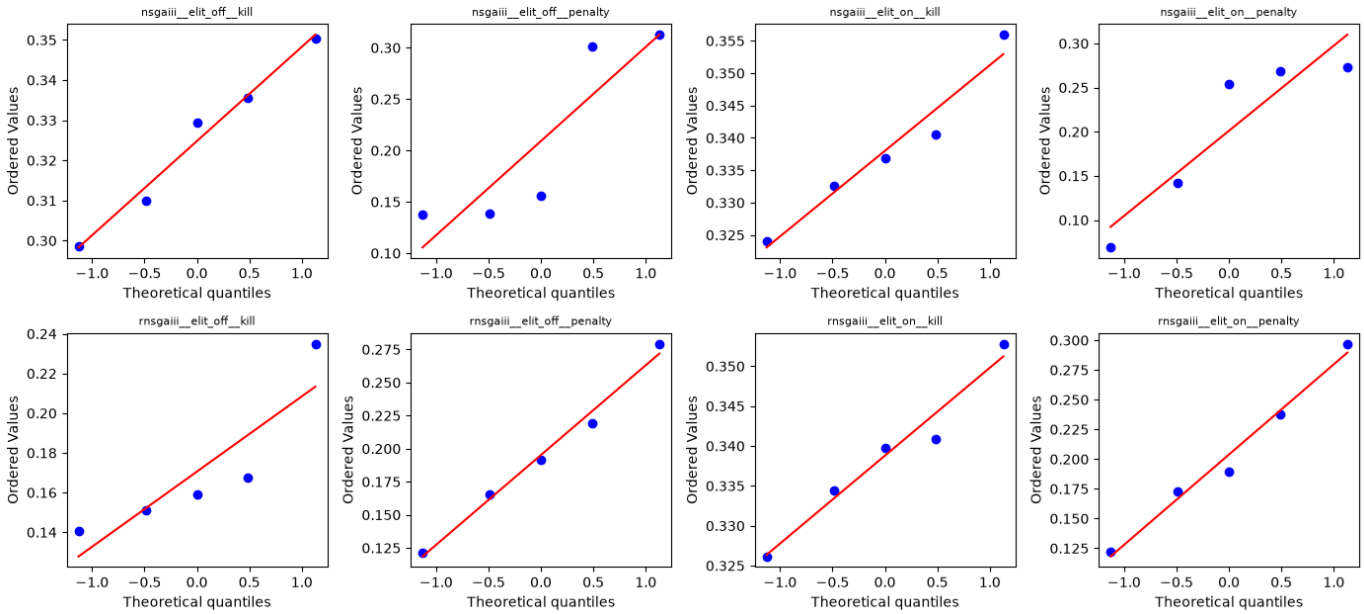


Figura 10. Análise descritiva - jPetStore - IGD+

Tabela XXI
SISTEMA JPETSTORE - IGD+ - PRESSUPOSTO DE NORMALIDADE - SHAPIRO-WILK

Config.	n	W	p	Rejeita normalidade?
1	5	0,824234	0,125834	Não
2	5	0,753422	0,032006	Sim
3	5	0,984655	0,957873	Não
4	5	0,993800	0,991164	Não
5	5	0,966295	0,850982	Não
6	5	0,970921	0,881130	Não
7	5	0,976543	0,915337	Não
8	5	0,796518	0,075885	Não

Decisão com $\alpha = 0{,}05$. Não rejeitar a hipótese de normalidade não comprova que a distribuição seja normal.

Tabela XXII
SISTEMA JPETSTORE - IGD+ - PÓS-HOC E CORREÇÃO DE FDR-BH

A	B	z	p_{Dunn}	p_{BH}	Signif.?
1	2	−0,0541	0,956855	0,978420	Não
1	3	−0,0812	0,935322	0,978420	Não
1	4	0,0541	0,956855	0,978420	Não
1	5	−2,7321	0,006294	0,020434	Sim
1	6	−2,2452	0,024758	0,053325	Não
1	7	−2,8132	0,004905	0,020434	Sim
1	8	0,4058	0,684925	0,958895	Não
2	3	−0,0271	0,978420	0,978420	Não
2	4	0,1082	0,913837	0,978420	Não
2	5	−2,6780	0,007407	0,020434	Sim
2	6	−2,1911	0,028448	0,056866	Não
2	7	−2,7591	0,005796	0,020434	Sim
2	8	0,4599	0,645623	0,951444	Não
3	4	0,1353	0,892414	0,978420	Não
3	5	−2,6509	0,008028	0,020434	Sim
3	6	−2,1640	0,030464	0,056866	Não
3	7	−2,7321	0,006294	0,020434	Sim
3	8	0,4869	0,626328	0,951444	Não
4	5	−2,7862	0,005334	0,020434	Sim
4	6	−2,2993	0,021490	0,050144	Não
4	7	−2,8673	0,004140	0,020434	Sim
4	8	0,3517	0,725100	0,966800	Não
5	6	0,4869	0,626328	0,951444	Não
5	7	−0,0812	0,935322	0,978420	Não
5	8	3,1378	0,001702	0,020434	Sim
6	7	−0,5681	0,570000	0,951444	Não
6	8	2,6509	0,008028	0,020434	Sim
7	8	3,2190	0,001287	0,020434	Sim

z: estatística de Dunn, com sinal correspondente à ordem A–B. p_{Dunn}: valor antes do BH; p_{BH}: valor ajustado para os 28 pares. Significância definida por $p_{\mathrm{BH}} \leq 0{,}05$.

Tabela XXIII
JPETSTORE - IGD+ - TAMANHO DO EFEITO DE VARGHA–DELANEY A12.

A	B	A12(A,B)	Favorece config.	Magnitude
1	2	0,56	1	Desprezível
1	3	0,48	3	Desprezível
1	4	0,48	4	Desprezível
1	5	1,00	1	Grande
1	6	1,00	1	Grande
1	7	1,00	1	Grande
1	8	0,36	8	Pequena
2	3	0,48	3	Desprezível
2	4	0,48	4	Desprezível
2	5	1,00	2	Grande
2	6	0,88	2	Grande
2	7	1,00	2	Grande
2	8	0,52	2	Desprezível
3	4	0,44	4	Desprezível
3	5	1,00	3	Grande
3	6	1,00	3	Grande
3	7	1,00	3	Grande
3	8	0,28	8	Grande
4	5	1,00	4	Grande
4	6	1,00	4	Grande
4	7	1,00	4	Grande
4	8	0,36	8	Pequena
5	6	0,28	6	Grande
5	7	0,56	5	Desprezível
5	8	0,00	8	Grande
6	7	0,72	6	Grande
6	8	0,00	8	Grande
7	8	0,00	8	Grande

A12 orientado pela direção de melhoria: valores maiores que 0,5 favorecem A e menores que 0,5 favorecem B. Magnitude definida por $d = |A12 - 0{,}5|$: desprezível até 0,06; pequena até 0,14; média até 0,21; grande acima de 0,21. A12 não determina significância estatística.

APÊNDICE C
JPETSTORE - INDICADOR: ED MÉDIA

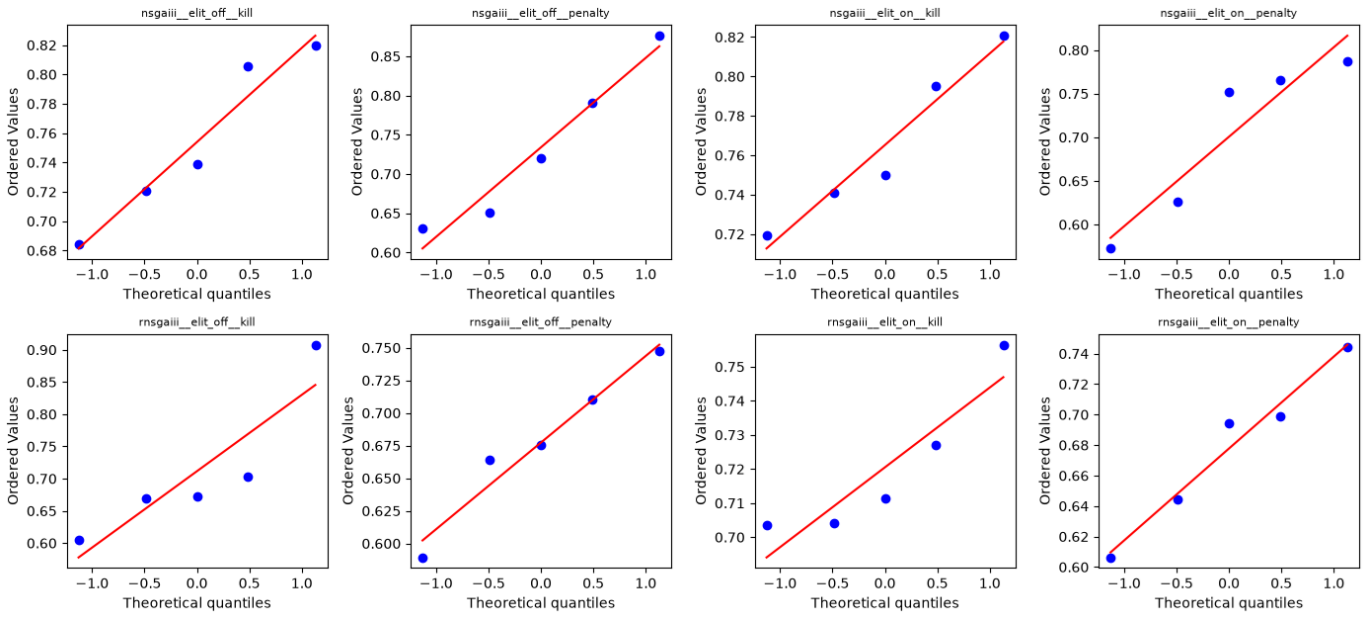


Figura 11. Análise descritiva - jPetStore - ED Média

Tabela XXIV
JPETSTORE - ED MÉDIA - TESTE DE SHAPIRO–WILK.

Config.	n	W	p	Rejeita normalidade?
1	5	0,857172	0,218270	Não
2	5	0,941239	0,674713	Não
3	5	0,967059	0,856066	Não
4	5	0,969694	0,873283	Não
5	5	0,938139	0,652809	Não
6	5	0,927272	0,577890	Não
7	5	0,837393	0,157845	Não
8	5	0,822631	0,122334	Não

Decisão com $\alpha = 0{,}05$. Não rejeitar a hipótese de normalidade não comprova que a distribuição seja normal.

Tabela XXV
JPETSTORE - ED MÉDIA - TAMANHO DO EFEITO DE VARGHA-DELANEY A12.

A	B	A12(A,B)	Favorece config.	Magnitude
1	2	0,64	1	Pequena
1	3	0,36	3	Pequena
1	4	0,36	4	Pequena
1	5	0,64	1	Pequena
1	6	0,64	1	Pequena
1	7	0,44	7	Desprezível
1	8	0,48	8	Desprezível
2	3	0,32	3	Média
2	4	0,36	4	Pequena
2	5	0,64	2	Pequena
2	6	0,64	2	Pequena
2	7	0,48	7	Desprezível
2	8	0,44	8	Desprezível
3	4	0,52	3	Desprezível
3	5	0,92	3	Grande
3	6	0,80	3	Grande
3	7	0,84	3	Grande
3	8	0,52	3	Desprezível
4	5	0,92	4	Grande
4	6	0,84	4	Grande
4	7	0,76	4	Grande
4	8	0,52	4	Desprezível
5	6	0,40	6	Pequena
5	7	0,16	7	Grande
5	8	0,20	8	Grande
6	7	0,32	7	Média
6	8	0,24	8	Grande
7	8	0,20	8	Grande

A12 orientado pela direção de melhoria: valores maiores que 0,5 favorecem A e menores que 0,5 favorecem B. Magnitude definida por $d = |A12 - 0{,}5|$: desprezível até 0,06; pequena até 0,14; média até 0,21; grande acima de 0,21. A12 não determina significância estatística.

APÊNDICE D
JPETSTORE - INDICADOR: ED MÍNIMA

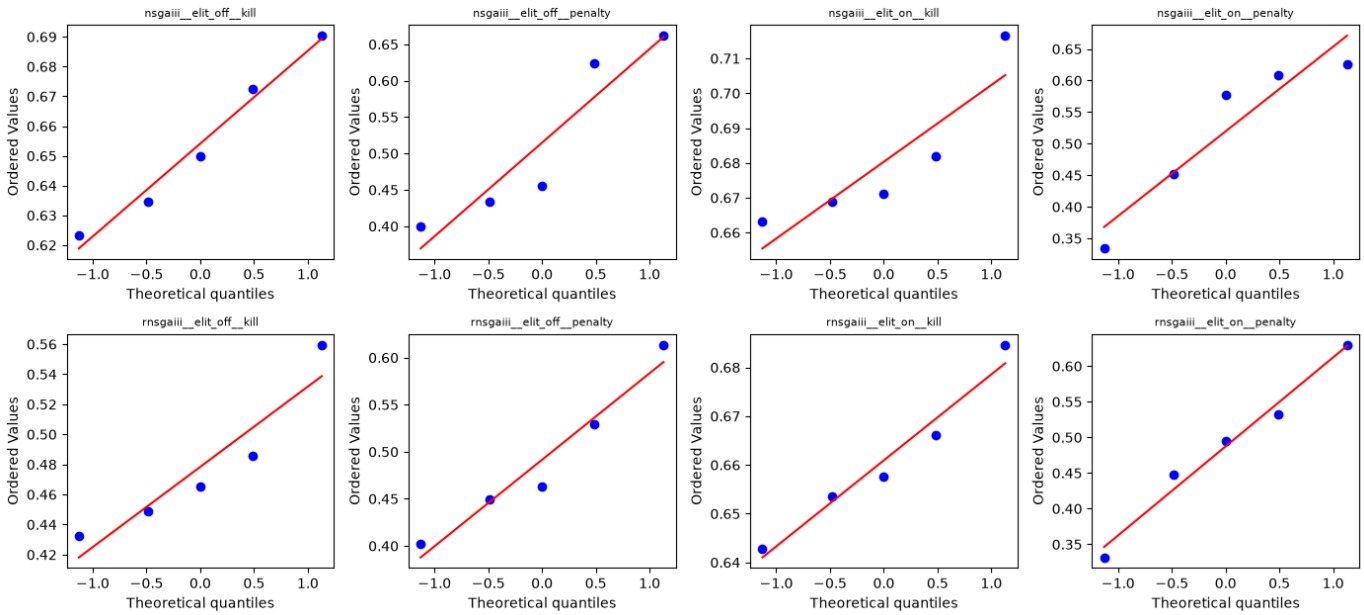


Figura 12. Análise descritiva - jPetStore - ED Mínima

Tabela XXVI
JPETSTORE - ED MÍNIMA - TESTE DE SHAPIRO–WILK.

Config.	n	W	p	Rejeita normalidade?
1	5	0,871224	0,271413	Não
2	5	0,851031	0,197799	Não
3	5	0,990858	0,982612	Não
4	5	0,948721	0,728050	Não
5	5	0,818226	0,113135	Não
6	5	0,961862	0,820885	Não
7	5	0,967169	0,856794	Não
8	5	0,889481	0,354502	Não

Decisão com $\alpha = 0{,}05$. Não rejeitar a hipótese de normalidade não comprova que a distribuição seja normal.

Tabela XXVII
JPETSTORE – ED MÍNIMA – PÓS-HOC DE DUNN COM CORREÇÃO DE BENJAMINI-HOCHBERG.

A	B	z	p_{Dunn}	p_{BH}	Signif.?
1	2	0,0271	0,978420	0,978420	Não
1	3	0,2705	0,786775	0,969964	Não
1	4	0,3517	0,725100	0,969964	Não
1	5	−2,7862	0,005334	0,029869	Sim
1	6	−2,0558	0,039801	0,074295	Não
1	7	−2,2181	0,026548	0,057179	Não
1	8	0,4599	0,645623	0,969964	Não
2	3	0,2435	0,807656	0,969964	Não
2	4	0,3246	0,745483	0,969964	Não
2	5	−2,8132	0,004905	0,029869	Sim
2	6	−2,0829	0,037264	0,074295	Não
2	7	−2,2452	0,024758	0,057179	Não
2	8	0,4328	0,665159	0,969964	Não
3	4	0,0812	0,935322	0,969964	Não
3	5	−3,0567	0,002238	0,020890	Sim
3	6	−2,3263	0,020002	0,050915	Não
3	7	−2,4886	0,012824	0,039898	Sim
3	8	0,1894	0,849818	0,969964	Não
4	5	−3,1378	0,001702	0,020890	Sim
4	6	−2,4075	0,016064	0,044979	Sim
4	7	−2,5698	0,010177	0,039898	Sim
4	8	0,1082	0,913837	0,969964	Não
5	6	0,7304	0,465175	0,814056	Não
5	7	0,5681	0,570000	0,938823	Não
5	8	3,2460	0,001170	0,020890	Sim
6	7	−0,1623	0,871069	0,969964	Não
6	8	2,5157	0,011881	0,039898	Sim
7	8	2,6780	0,007407	0,034567	Sim

z: estatística de Dunn, com sinal correspondente à ordem A–B. p_{Dunn}: valor antes do BH; p_{BH}: valor ajustado para os 28 pares. Significância definida por $p_{\mathrm{BH}} \leq 0{,}05$.

Tabela XXVIII
JPETSTORE - ED MÍNIMA - TAMANHO DO EFEITO DE VARGHA-DELANEY A12.

A	B	A12(A,B)	Favorece config.	Magnitude
1	2	0,52	1	Desprezível
1	3	0,40	3	Pequena
1	4	0,40	4	Pequena
1	5	1,00	1	Grande
1	6	0,96	1	Grande
1	7	1,00	1	Grande
1	8	0,32	8	Média
2	3	0,48	3	Desprezível
2	4	0,48	4	Desprezível
2	5	1,00	2	Grande
2	6	0,84	2	Grande
2	7	0,88	2	Grande
2	8	0,48	8	Desprezível
3	4	0,48	4	Desprezível
3	5	1,00	3	Grande
3	6	0,96	3	Grande
3	7	1,00	3	Grande
3	8	0,44	8	Desprezível
4	5	1,00	4	Grande
4	6	1,00	4	Grande
4	7	1,00	4	Grande
4	8	0,48	8	Desprezível
5	6	0,28	6	Grande
5	7	0,20	7	Grande
5	8	0,00	8	Grande
6	7	0,60	6	Pequena
6	8	0,00	8	Grande
7	8	0,00	8	Grande

A12 orientado pela direção de melhoria: valores maiores que 0,5 favorecem A e menores que 0,5 favorecem B. Magnitude definida por $d = |A12 - 0{,}5|$: desprezível até 0,06; pequena até 0,14; média até 0,21; grande acima de 0,21. A12 não determina significância estatística.

APÊNDICE E
SPRING-PETCLINIC- INDICADOR: HV

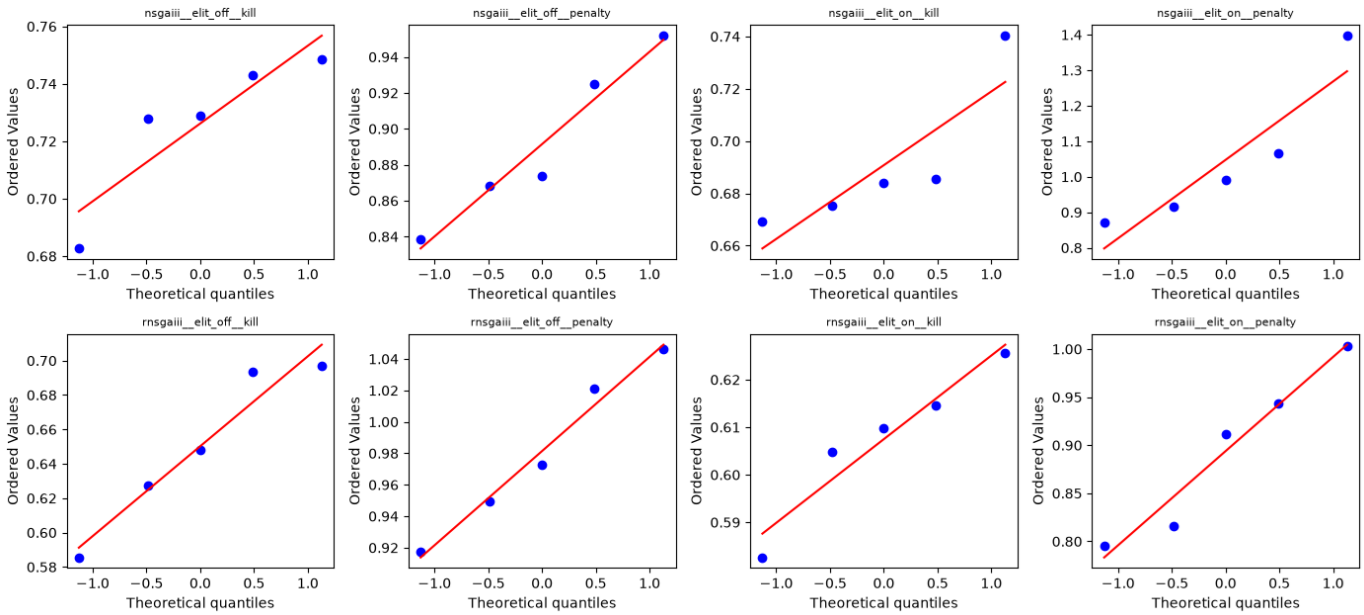


Figura 13. Análise descritiva - spring-PetClinic - HV

Tabela XXIX
SPRING-PETCLINIC – HV – TESTE DE SHAPIRO–WILK.

Config.	n	W	p	Rejeita normalidade?
1	5	0,853838	0,206956	Não
2	5	0,941368	0,675628	Não
3	5	0,934653	0,628425	Não
4	5	0,965121	0,843109	Não
5	5	0,762851	0,038976	Sim
6	5	0,838580	0,161036	Não
7	5	0,945935	0,708139	Não
8	5	0,922768	0,547952	Não

Decisão com $\alpha = 0{,}05$. Não rejeitar a hipótese de normalidade não comprova que a distribuição seja normal.

Tabela XXX
SPRING-PETCLINIC – HV – PÓS-HOC DE DUNN COM AJUSTE BH.

A	B	z	p_{Dunn}	p_{BH}	Signif.?
1	2	0,8386	0,401720	0,507746	Não
1	3	0,8115	0,417077	0,507746	Não
1	4	−0,0812	0,935322	0,969964	Não
1	5	2,8403	0,004508	0,015777	Sim
1	6	2,2722	0,023074	0,053839	Não
1	7	4,0034	$6{,}24351 \times 10^{-5}$	0,000874	Sim
1	8	3,2731	0,001064	0,007241	Sim
2	3	−0,0271	0,978420	0,978420	Não
2	4	−0,9197	0,357728	0,496057	Não
2	5	2,0017	0,045316	0,090633	Não
2	6	1,4337	0,151671	0,249811	Não
2	7	3,1649	0,001552	0,007241	Sim
2	8	2,4345	0,014912	0,041754	Sim
3	4	−0,8927	0,372043	0,496057	Não
3	5	2,0288	0,042483	0,090633	Não
3	6	1,4607	0,144096	0,249811	Não
3	7	3,1919	0,001413	0,007241	Sim
3	8	2,4616	0,013833	0,041754	Sim
4	5	2,9214	0,003485	0,013938	Sim
4	6	2,3534	0,018605	0,047357	Sim
4	7	4,0846	$4{,}41598 \times 10^{-5}$	0,000874	Sim
4	8	3,3542	0,000796	0,007241	Sim
5	6	−0,5681	0,570000	0,638400	Não
5	7	1,1632	0,244767	0,380749	Não
5	8	0,4328	0,665159	0,716325	Não
6	7	1,7312	0,083415	0,155708	Não
6	8	1,0009	0,316898	0,467007	Não
7	8	−0,7304	0,465175	0,542704	Não

z: estatística de Dunn, com sinal correspondente à ordem A–B. p_{Dunn}: valor antes do BH; p_{BH}: valor ajustado para os 28 pares. Significância definida por $p_{\mathrm{BH}} \leq 0{,}05$.

Tabela XXXI
SPRING-PETCLINIC – HV – TAMANHO DO EFEITO DE VARGHA–DELANEY A12.

A	B	A12(A,B)	Favorece config.	Magnitude
1	2	0,80	1	Grande
1	3	0,76	1	Grande
1	4	0,52	1	Desprezível
1	5	1,00	1	Grande
1	6	1,00	1	Grande
1	7	1,00	1	Grande
1	8	1,00	1	Grande
2	3	0,52	2	Desprezível
2	4	0,12	4	Grande
2	5	1,00	2	Grande
2	6	1,00	2	Grande
2	7	1,00	2	Grande
2	8	1,00	2	Grande
3	4	0,16	4	Grande
3	5	1,00	3	Grande
3	6	1,00	3	Grande
3	7	1,00	3	Grande
3	8	1,00	3	Grande
4	5	1,00	4	Grande
4	6	1,00	4	Grande
4	7	1,00	4	Grande
4	8	1,00	4	Grande
5	6	0,20	6	Grande
5	7	1,00	5	Grande
5	8	0,68	5	Média
6	7	1,00	6	Grande
6	8	0,92	6	Grande
7	8	0,16	8	Grande

A12 orientado pela direção de melhoria: valores maiores que 0,5 favorecem A e menores que 0,5 favorecem B. Magnitude definida por $d = |A12 - 0{,}5|$: desprezível até 0,06; pequena até 0,14; média até 0,21; grande acima de 0,21. A12 não determina significância estatística.

APÊNDICE F
SPRING-PETCLINIC- INDICADOR: IGD+

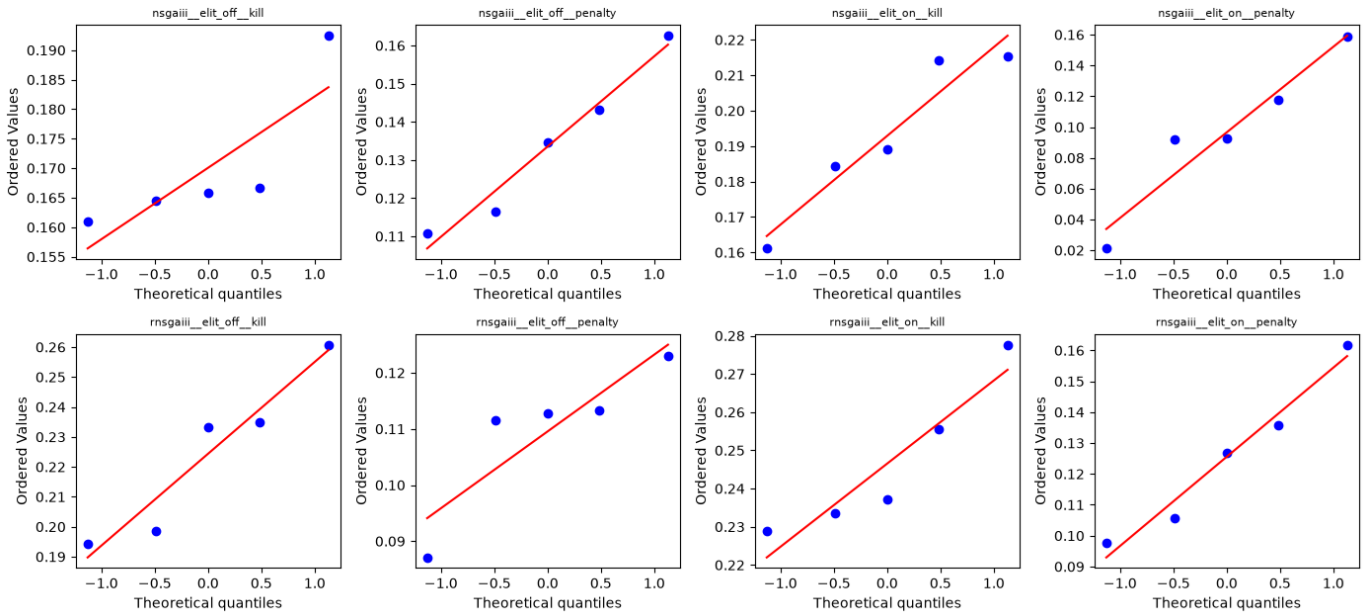


Figura 14. Análise descritiva - spring-PetClinic - IGD+

Tabela XXXII
SPRING-PETCLINIC – IGD+ – TESTE DE SHAPIRO–WILK.

Config.	n	W	p	Rejeita normalidade?
1	5	0,950128	0,738102	Não
2	5	0,955202	0,774245	Não
3	5	0,960795	0,813507	Não
4	5	0,825718	0,129147	Não
5	5	0,908459	0,458383	Não
6	5	0,711111	0,012470	Sim
7	5	0,879363	0,306433	Não
8	5	0,909626	0,465345	Não

Decisão com $\alpha = 0{,}05$. Não rejeitar a hipótese de normalidade não comprova que a distribuição seja normal.

Tabela XXXIII
SPRING-PETCLINIC – IGD+ – PÓS-HOC DE DUNN COM AJUSTE BH.

A	B	z	p_{Dunn}	p_{BH}	Signif.?
1	2	−0,9197	0,357728	0,500819	Não
1	3	−0,6492	0,516208	0,628427	Não
1	4	−0,1082	0,913837	0,913837	Não
1	5	−2,6509	0,008028	0,028096	Sim
1	6	−2,1911	0,028448	0,072412	Não
1	7	−3,9223	$8{,}77212 \times 10^{-5}$	0,001914	Sim
1	8	−3,5165	0,000437	0,004081	Sim
2	3	0,2705	0,786775	0,815915	Não
2	4	0,8115	0,417077	0,530825	Não
2	5	−1,7312	0,083415	0,155708	Não
2	6	−1,2714	0,203603	0,300046	Não
2	7	−3,0026	0,002677	0,012494	Sim
2	8	−2,5968	0,009409	0,029274	Sim
3	4	0,5410	0,588506	0,686591	Não
3	5	−2,0017	0,045316	0,097604	Não
3	6	−1,5419	0,123109	0,215440	Não
3	7	−3,2731	0,001064	0,005958	Sim
3	8	−2,8673	0,004140	0,016559	Sim
4	5	−2,5427	0,011000	0,030799	Sim
4	6	−2,0829	0,037264	0,086950	Não
4	7	−3,8141	0,000137	0,001914	Sim
4	8	−3,4083	0,000654	0,004576	Sim
5	6	0,4599	0,645623	0,723098	Não
5	7	−1,2714	0,203603	0,300046	Não
5	8	−0,8656	0,386708	0,515611	Não
6	7	−1,7312	0,083415	0,155708	Não
6	8	−1,3255	0,185020	0,300046	Não
7	8	0,4058	0,684925	0,737612	Não

z: estatística de Dunn, com sinal correspondente à ordem A–B. p_{Dunn}: valor antes do BH; p_{BH}: valor ajustado para os 28 pares. Significância definida por $p_{\mathrm{BH}} \leq 0{,}05$.

Tabela XXXIV
SPRING-PETCLINIC – IGD+ – TAMANHO DO EFEITO DE VARGHA–DELANEY A12.

A	B	A12(A,B)	Favorece config.	Magnitude
1	2	0,76	1	Grande
1	3	0,76	1	Grande
1	4	0,56	1	Desprezível
1	5	1,00	1	Grande
1	6	1,00	1	Grande
1	7	1,00	1	Grande
1	8	1,00	1	Grande
2	3	0,36	3	Pequena
2	4	0,20	4	Grande
2	5	0,96	2	Grande
2	6	0,96	2	Grande
2	7	1,00	2	Grande
2	8	1,00	2	Grande
3	4	0,32	4	Média
3	5	0,96	3	Grande
3	6	0,96	3	Grande
3	7	1,00	3	Grande
3	8	1,00	3	Grande
4	5	1,00	4	Grande
4	6	1,00	4	Grande
4	7	1,00	4	Grande
4	8	1,00	4	Grande
5	6	0,24	6	Grande
5	7	1,00	5	Grande
5	8	0,84	5	Grande
6	7	1,00	6	Grande
6	8	1,00	6	Grande
7	8	0,28	8	Grande

A12 orientado pela direção de melhoria: valores maiores que 0,5 favorecem A e menores que 0,5 favorecem B. Magnitude definida por $d = |A12 - 0{,}5|$: desprezível até 0,06; pequena até 0,14; média até 0,21; grande acima de 0,21. A12 não determina significância estatística.

APÊNDICE G
SPRING-PETCLINIC- INDICADOR: ED MÉDIA

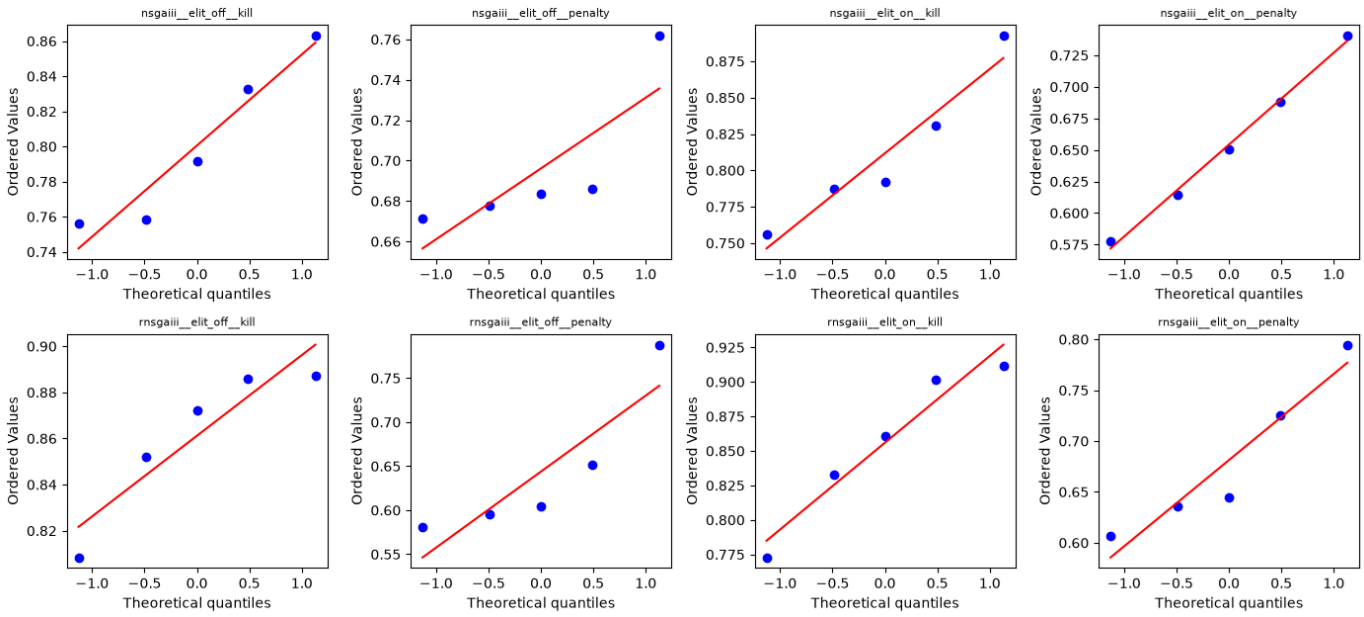


Figura 15. Análise descritiva - spring-PetClinic - ED Média

Tabela XXXV
SPRING-PETCLINIC – ED MÉDIA – TESTE DE SHAPIRO–WILK.

Config.	n	W	p	Rejeita normalidade?
1	5	0,989719	0,978700	Não
2	5	0,696014	0,008696	Sim
3	5	0,903150	0,427538	Não
4	5	0,794556	0,073110	Não
5	5	0,933241	0,618630	Não
6	5	0,903516	0,429625	Não
7	5	0,935177	0,632074	Não
8	5	0,858826	0,224064	Não

Decisão com $\alpha = 0{,}05$. Não rejeitar a hipótese de normalidade não comprova que a distribuição seja normal.

Tabela XXXVI
SPRING-PETCLINIC – ED MÉDIA – PÓS-HOC DE DUNN COM AJUSTE BH.

A	B	z	p_{Dunn}	p_{BH}	Signif.?
1	2	−0,6222	0,533842	0,679435	Não
1	3	−0,4058	0,684925	0,799080	Não
1	4	0,1353	0,892414	0,913837	Não
1	5	−2,3534	0,018605	0,052093	Não
1	6	−2,1640	0,030464	0,071082	Não
1	7	−3,1378	0,001702	0,011915	Sim
1	8	−3,2460	0,001170	0,010923	Sim
2	3	0,2164	0,828675	0,913837	Não
2	4	0,7574	0,448809	0,598412	Não
2	5	−1,7312	0,083415	0,155708	Não
2	6	−1,5419	0,123109	0,215440	Não
2	7	−2,5157	0,011881	0,039898	Sim
2	8	−2,6239	0,008694	0,034776	Sim
3	4	0,5410	0,588506	0,716443	Não
3	5	−1,9476	0,051462	0,110841	Não
3	6	−1,7583	0,078704	0,155708	Não
3	7	−2,7321	0,006294	0,029372	Sim
3	8	−2,8403	0,004508	0,025243	Sim
4	5	−2,4886	0,012824	0,039898	Sim
4	6	−2,2993	0,021490	0,054703	Não
4	7	−3,2731	0,001064	0,010923	Sim
4	8	−3,3813	0,000722	0,010923	Sim
5	6	0,1894	0,849818	0,913837	Não
5	7	−0,7845	0,432775	0,598412	Não
5	8	−0,8927	0,372043	0,548274	Não
6	7	−0,9738	0,330154	0,513573	Não
6	8	−1,0820	0,279251	0,459943	Não
7	8	−0,1082	0,913837	0,913837	Não

z: estatística de Dunn, com sinal correspondente à ordem A–B. p_{Dunn}: valor antes do BH; p_{BH}: valor ajustado para os 28 pares. Significância definida por $p_{\mathrm{BH}} \leq 0{,}05$.

Tabela XXXVII
SPRING-PETCLINIC – ED MÉDIA – TAMANHO DO EFEITO DE VARGHA–DELANEY A12.

A	B	A12(A,B)	Favorece config.	Magnitude
1	2	0,68	1	Média
1	3	0,56	1	Desprezível
1	4	0,44	4	Desprezível
1	5	1,00	1	Grande
1	6	1,00	1	Grande
1	7	1,00	1	Grande
1	8	1,00	1	Grande
2	3	0,36	3	Pequena
2	4	0,20	4	Grande
2	5	0,96	2	Grande
2	6	0,92	2	Grande
2	7	1,00	2	Grande
2	8	1,00	2	Grande
3	4	0,28	4	Grande
3	5	0,88	3	Grande
3	6	0,88	3	Grande
3	7	0,96	3	Grande
3	8	1,00	3	Grande
4	5	0,92	4	Grande
4	6	0,92	4	Grande
4	7	0,96	4	Grande
4	8	1,00	4	Grande
5	6	0,44	6	Desprezível
5	7	0,76	5	Grande
5	8	0,76	5	Grande
6	7	0,76	6	Grande
6	8	0,88	6	Grande
7	8	0,48	8	Desprezível

A12 orientado pela direção de melhoria: valores maiores que 0,5 favorecem A e menores que 0,5 favorecem B. Magnitude definida por $d = |A12 - 0{,}5|$: desprezível até 0,06; pequena até 0,14; média até 0,21; grande acima de 0,21. A12 não determina significância estatística.

APÊNDICE H
SPRING-PETCLINIC- INDICADOR: ED MÍNIMA

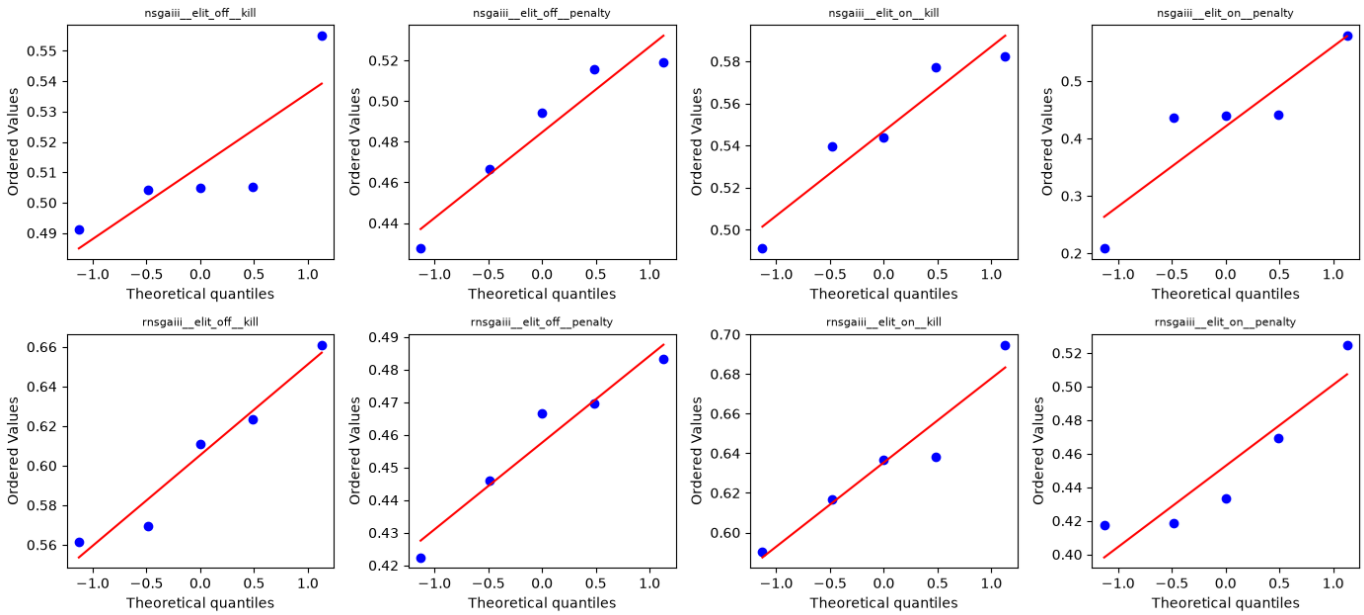


Figura 16. Análise descritiva - spring-PetClinic - ED Mínima

Tabela XXXVIII
SPRING-PETCLINIC – ED MÍNIMA – TESTE DE SHAPIRO–WILK.

Config.	n	W	p	Rejeita normalidade?
1	5	0,862058	0,235730	Não
2	5	0,904957	0,437888	Não
3	5	0,845771	0,181518	Não
4	5	0,945386	0,704223	Não
5	5	0,908560	0,458985	Não
6	5	0,746580	0,027662	Sim
7	5	0,940045	0,666256	Não
8	5	0,939391	0,661634	Não

Decisão com $\alpha = 0{,}05$. Não rejeitar a hipótese de normalidade não comprova que a distribuição seja normal.

Tabela XXXIX
SPRING-PETCLINIC – ED MÍNIMA – PÓS-HOC DE DUNN COM AJUSTE BH.

A	B	z	p_{Dunn}	p_{BH}	Signif.?
1	2	−0,6222	0,533823	0,622793	Não
1	3	0,2164	0,828667	0,881286	Não
1	4	0,0271	0,978419	0,978419	Não
1	5	−1,9883	0,046781	0,109156	Não
1	6	−1,2849	0,198813	0,309265	Não
1	7	−3,4355	0,000591	0,005520	Sim
1	8	−2,9756	0,002924	0,013644	Sim
2	3	0,8386	0,401698	0,562378	Não
2	4	0,6492	0,516188	0,622793	Não
2	5	−1,3661	0,171910	0,300842	Não
2	6	−0,6628	0,507485	0,622793	Não
2	7	−2,8133	0,004903	0,019612	Sim
2	8	−2,3535	0,018599	0,065097	Não
3	4	−0,1894	0,849811	0,881286	Não
3	5	−2,2047	0,027476	0,085481	Não
3	6	−1,5014	0,133265	0,266530	Não
3	7	−3,6519	0,000260	0,005520	Sim
3	8	−3,1921	0,001413	0,009888	Sim
4	5	−2,0153	0,043870	0,109156	Não
4	6	−1,3120	0,189523	0,309265	Não
4	7	−3,4626	0,000535	0,005520	Sim
4	8	−3,0027	0,002676	0,013644	Sim
5	6	0,7033	0,481847	0,622793	Não
5	7	−1,4472	0,147828	0,275945	Não
5	8	−0,9874	0,323459	0,476676	Não
6	7	−2,1506	0,031509	0,088226	Não
6	8	−1,6907	0,090892	0,195768	Não
7	8	0,4599	0,645607	0,723080	Não

z: estatística de Dunn, com sinal correspondente à ordem A–B. p_{Dunn}: valor antes do BH; p_{BH}: valor ajustado para os 28 pares. Significância definida por $p_{\mathrm{BH}} \leq 0{,}05$.

Tabela XL
SPRING-PETCLINIC – ED MÍNIMA – TAMANHO DO EFEITO DE VARGHA–DELANEY A12.

A	B	A12(A,B)	Favorece config.	Magnitude
1	2	0,68	1	Média
1	3	0,44	3	Desprezível
1	4	0,68	1	Média
1	5	0,84	1	Grande
1	6	0,80	1	Grande
1	7	1,00	1	Grande
1	8	0,92	1	Grande
2	3	0,32	3	Média
2	4	0,28	4	Grande
2	5	0,88	2	Grande
2	6	0,64	2	Pequena
2	7	1,00	2	Grande
2	8	1,00	2	Grande
3	4	0,64	3	Pequena
3	5	0,96	3	Grande
3	6	0,84	3	Grande
3	7	1,00	3	Grande
3	8	1,00	3	Grande
4	5	1,00	4	Grande
4	6	1,00	4	Grande
4	7	1,00	4	Grande
4	8	1,00	4	Grande
5	6	0,26	6	Grande
5	7	1,00	5	Grande
5	8	0,84	5	Grande
6	7	1,00	6	Grande
6	8	1,00	6	Grande
7	8	0,28	8	Grande

A12 orientado pela direção de melhoria: valores maiores que 0,5 favorecem A e menores que 0,5 favorecem B. Magnitude definida por $d = |A12 - 0{,}5|$: desprezível até 0,06; pequena até 0,14; média até 0,21; grande acima de 0,21. A12 não determina significância estatística.