Análise dos Resultados — Experimento i-toMicroservices

Documento metodológico (SBSE) de como deve ser feita a análise dos resultados obtidos a partir da execução da ferramenta.

1. Objetivo e perguntas de pesquisa

O experimento avalia se as mudanças recentes da ferramenta, elitismo, tratamento de restrição (PENALTY/KILL) e o algoritmo R-NSGA-III, são benéficas ou prejudiciais no uso interativo com um Decision Maker (DM) humano.

2. Insumos: os ZIPs e seus arquivos

O nome do zip exportado após uma execução da ferramenta segue o seguinte formato:
study_{ra}__{identificador da persona}__config_{x}__{sistema}__execution_{y}.zip

Cada arquivo do ZIP tem um papel diferente na análise. Abaixo os arquivos são agrupados por bloco funcional e classificados pelo uso na análise: **ESSENCIAL** (necessário para a comparação das 5 execuções por configuração), **ANÁLISE** (usado, mas em granularidade por interação), **DM** (insumo para a análise comportamental das decisões), **APOIO** (contexto, caracterização e auditoria), **DIAGNÓSTICO** (só para depurar uma execução) e **DESCARTAR** (não utilizado na comparação principal).

2.1 Bloco A: Contexto e rastreabilidade da execução

Reúne os metadados usados para agrupar, filtrar e auditar as execuções. Não são objeto de análise estatística, mas são indispensáveis para montar os grupos.

O **‘manifest.json’** é a identificação geral da execução: o bloco ‘study’ (participante, persona e configId), o bloco ‘run’ (sourceId e repetição), a configuração, a versão do app, o ‘timing’, os ‘anomalies’ e a lista de arquivos do pacote. Ele é a chave de agrupamento da análise (study.configId × run.sourceId × study.repetition); os campos individuais, por si só, têm baixo valor analítico. Uso: **ESSENCIAL** para agrupar.
O **‘parameters.json’** apresenta os parâmetros de início da execução (tamanho da população, algoritmo, constraint, etc.). Uso: **APOIO**, para caracterizar a configuração.

O **‘timing.json’** traz o resumo de tempo do run (tempo ativo, pausado e wall, orçamento, stopReason e gerações por minuto). Uso: **APOIO**, como medida de esforço.
O **‘anomalies.json’** reúne o resumo das recuperações de geração (fallbacks por degeneração do jMetal) e os registros correspondentes. Uso: **APOIO**, como flag de qualidade, permitindo marcar execuções cuja trajetória de busca precisou ser reparada.

2.2 Bloco B: Processo de decisão do DM

Reúne os insumos da análise comportamental e qualitativa das decisões (personas, operações e engajamento). Não entra no cálculo do indicador de qualidade.

O **‘decisions.json’** registra a decisão do DM em cada interação: geração, índice da solução escolhida. Uso: **DM**.
O **‘interactions.json’** é o registro bruto das interações: a pilha de modificações (modificationStack, com as operações), o escopo de propagação (targetSolutionIndices), o cluster (clusterId) e o timestamp. Uso: **DM**.
O **‘behavioral_events.json’** é a trilha de eventos de UI/DM (inspeção de solução, operações, solução exibida, execução concluída ou abandonada), presente apenas em sessões de estudo. Uso: **DM**, para engajamento e tempo por decisão.
O **‘intent_diffusion.json’** é a telemetria, por geração, da difusão da intenção/freeze do DM (contagem de carriers). Uso: **DM**, para observar como a intenção se espalhou pela população.

2.3 Bloco C: População e fronteira (qualidade da solução)

Reúne os dados da população e da fronteira final, onde está a matéria-prima da análise de qualidade e convergência.

O **‘candidates.json’** é a foto leve da população que o DM viu em cada interação: por candidato, o índice, o número de microsserviços, os 5 objetivos, o indicador bestTradeoff e o hasDmInteraction; além do mapa bestCandidates (melhor por objetivo). Uso: **ANÁLISE**, para distribuição de soluções e melhores por objetivo nos pontos de interação.
O **‘bestSolutions.json’** traz a melhor solução por objetivo, por geração de interação (não é um único melhor indivíduo). Uso: **ANÁLISE**, para a evolução pontual nos gens de interação.
O **‘frontiers.json’** contém a fronteira não-dominada da geração final: os vetores crus. Uso: **ESSENCIAL**, pois é a entrada dos cálculos das metricas.

2.4 Bloco D: Medidas pré-calculadas (descartar na comparação principal)

O **‘indicators.json’** traz os indicadores da fronteira final (HV, ED-ao-ideal, coverage-ε, spacing e distâncias à aspiração) em espaço de referência fixo por instância, sem IGD+. Uso: **DESCARTAR** na comparação entre as 5 execuções, pois a escala absoluta é fixa e pré-definida, e não é a métrica escolhida para o estudo.
A parte normalizada dentro do **‘frontiers.json’** é a cópia da fronteira final no mesmo espaço de referência fixo. Uso: **DESCARTAR** para a comparação entre as 5 execuções; usar os vetores crus.

Justificativa do descarte: os valores são calculados desta execução; o que vem de uma calibração prévia são apenas os bounds (mínimo, máximo e aspiração por instância). O descarte é uma escolha analítica (comparar as execuções em escala própria), e não porque os números sejam externos. A comparação vai partir das 5 execuções da mesma configuração, um script a parte que vai ser executado.

3. Testes estatísticos

Para realizar os testes e comparar as diferentes configurações vai ser necessário organizar e padronizar as fronteiras finais exportadas por cada execução e, em seguida, calcular os indicadores de qualidade sobre um espaço de comparação comum.

3.1 Processo inicial para a análise

O processo é feito separadamente para cada sistema. Esse processo é utilizando um script em python (disponível no repositório: script-analise-resultado-i-toMicroservices) e segue os passos abaixo. **A execução do algoritmo não será responsabilidade sua, vamos disponibilizar os valores resultante para que seja realizada a análise.**

1. Reunir as entradas. Para um dado sistema (por exemplo, spring-petclinic ou jpetstore), são coletadas as fronteiras finais de todas as configurações e de todas as execuções (pasta no drive que já organiza isso tudo). São 8 configurações, com 5 execuções cada, totalizando 40 fronteiras por sistema. Cada fronteira é lida do arquivo frontiers.json do ZIP da sessão, no campo "frontier", que contém os vetores crus dos 5 objetivos. A ordem das colunas é dada pelo campo "metricNames" do mesmo arquivo. O grupo a que cada fronteira pertence (configuração e número da execução) é obtido do manifest.json, nos campos study.configId e study.repetition.

2. Descartar o que não será usado. Não são utilizados o arquivo indicators.json nem o campo "normalizedFrontier" dentro do frontiers.json, pois a normalização deles usa uma referência fixa e pré-definida, diferente da comparação proposta. A análise usa apenas os vetores crus do campo "frontier".
3. Definir a convenção de direção dos objetivos. Os 5 objetivos são exportados em convenção de minimização (menor é melhor). Três deles, Coesão, Funcionalidade e Reúso, estão armazenados invertidos (1/valor), de modo que continuam sendo minimizados. Essa convenção é mantida em toda a análise para evitar erro de sinal, ficando registrado que esses três objetivos estão na forma invertida.
4. Normalizar em um espaço comum. Como os objetivos têm escalas muito diferentes, antes de calcular qualquer indicador todos os valores são normalizados. Para isso, reúnem-se todas as fronteiras de todas as configurações e execuções daquele sistema, obtém-se o mínimo e o máximo de cada objetivo (limites conjuntos) e normaliza-se cada fronteira com esses mesmos limites, pela fórmula (valor − mínimo) / (máximo − mínimo). O resultado é um espaço comum em [0,1] para os 5 objetivos, idêntico para todas as configurações e execuções do sistema.
5. Construir a fronteira de referência. A partir de todos os pontos normalizados de todas as configurações e execuções do sistema, mantém-se apenas o conjunto não-dominado. Essa é a fronteira de referência (a "fronteira real de Pareto" do sistema), usada como padrão comum de comparação.
6. Calcular os indicadores por execução. Para cada uma das 40 fronteiras normalizadas (5 execuções × 8 configurações), calcula-se, sempre contra a fronteira de referência e no espaço normalizado:
    a. Hypervolume (HV), com ponto de referência fixo (1.1 em cada objetivo), o mesmo para todas as execuções e configurações;
    b. IGD+, medindo a distância da fronteira de referência até a fronteira da execução;
    c. ED (distância ao ideal), com ideal em (0, 0, 0, 0, 0) no espaço normalizado, como distância euclidiana média (e, opcionalmente, mínima) da fronteira ao ideal. Opcionalmente, também pode ser calculado o spacing, para medir a uniformidade da fronteira.
7. Agregar por configuração. Para cada configuração, reúnem-se os 5 valores de cada indicador (um por execução) e calcula-se a estatística descritiva (média ou mediana e desvio).
8. Comparar as configurações. Dentro de cada sistema, as 8 configurações são comparadas a partir dos 5 valores por indicador, com teste estatístico adequado a

amostras pequenas (n = 5), respeitando o pareamento, e reportando os valores por configuração e os respectivos p-valores.

9. Registrar a saída. O resultado é uma tabela em que cada linha corresponde a uma execução, com as colunas: sistema, configuração, repetição e os valores de HV, IGD+, ED e spacing. A partir dela, os dados são agrupados por sistema e configuração para as médias, desvios e testes.

Observação: o frontiers.json contém apenas a fronteira da última geração de cada execução. Portanto, a análise mede a qualidade da solução final, e não a convergência ao longo das gerações.

3.2 Fluxo estatístico para a análise

O fluxo é aplicado separadamente a cada sistema e a cada indicador de qualidade (HV, IGD+ e ED). Como cada execução exige a interação de um Decision Maker (DM) humano, cada configuração tem 5 execuções independentes, ou seja, 8 grupos independentes com n = 5 cada. Para auxiliar nesse processo estou disponibilizando um conjunto de arquivos em R e um notebook python, ambos fazem a mesma coisa, você pode utilizar de base esses arquivos para realizar as análises.

3.2.1. Verificação dos pressupostos

- **Normalidade (Shapiro-Wilk):** aplicado aos valores do indicador em cada configuração. A hipótese nula (H_0) é que os dados seguem uma distribuição normal. Se $p > 0,05$, não rejeitamos H_0 e a normalidade é plausível. Se $p \leq 0,05$, há evidência de não normalidade. Com apenas 5 observações por grupo, o teste tem baixo poder: ele raramente rejeita H_0, mesmo quando os dados não são normais. Por isso, o resultado é interpretado com cautela e complementado por histogramas e Q-Q plots, ciente de que, com n = 5, esses gráficos também são pouco conclusivos.
- **Homogeneidade das variâncias (Levene):** verifica se os 8 grupos têm variâncias semelhantes, outro pressuposto da ANOVA.

3.2.2. Escolha do teste global

- Se os dois pressupostos forem atendidos, usa-se a **ANOVA de uma via** (8 grupos independentes).
- Caso contrário, usa-se o **Kruskal-Wallis** (8 grupos independentes).

Se o p-valor for > 0,05, não há diferença estatisticamente significativa entre as configurações e a análise se encerra. Se for ≤ 0,05, ao menos uma configuração difere das demais, e o teste global não indica qual.

Nota metodológica: como n = 5 limita a verificação da normalidade, é razoável adotar o Kruskal-Wallis como escolha conservadora, justificando a decisão no texto. Seguindo o fluxo da aula, o critério formal continua sendo o resultado dos pressupostos.

3.2.3. Testes pós-hoc

Quando o teste global é significativo, as configurações são comparadas par a par (8 configurações geram 28 pares):

- após a **ANOVA**, usa-se o **Tukey HSD**;
- após o **Kruskal-Wallis**, usa-se o **teste de Dunn**.

3.2.4. Correção para múltiplas comparações (FDR-BH)

Os p-valores do pós-hoc são ajustados pelo procedimento **FDR de Benjamini-Hochberg**, que controla a taxa de falsas descobertas. A significância é avaliada sobre os p-valores ajustados (p ajustado ≤ 0,05). Com n = 5 e 28 comparações, é esperado que poucos pares sobrevivam à correção, e isso deve ser registrado como limitação do estudo.

3.2.5. Tamanho do efeito (Vargha-Delaney A_{12})

A significância estatística não informa a magnitude da diferença entre configurações. O termo "tamanho do efeito" refere-se à magnitude ou intensidade de uma diferença observada entre dois grupos, ou seja, é uma medida quantitativa da força dessa diferença. Para medi-lo, usa-se o **A_{12} de Vargha-Delaney**, medida não paramétrica que estima a probabilidade de uma execução da configuração A produzir um resultado melhor que uma execução da configuração B:

$$A_{12} = P(A > B) + 0{,}5 \cdot P(A = B)$$

Com n = 5, são apenas 25 pares de comparação (5 × 5) por par de configurações, então o A_{12} assume valores discretos (múltiplos de 0,04) e deve ser interpretado como estimativa aproximada.

Interpretação:

- A_{12} = 0,5: configurações equivalentes.
- A_{12} > 0,5: A tende a superar B. A_{12} < 0,5: B tende a superar A.

Magnitude	A_{12} (A melhor que B)	A_{12} (B melhor que A)
Desprezível	0,50 a 0,56	0,44 a 0,50
Pequena	0,56 a 0,64	0,36 a 0,44
Média	0,64 a 0,71	0,29 a 0,36
Grande	acima de 0,71	abaixo de 0,29

Atenção à direção do indicador: no **HV**, maior é melhor ("A melhor que B" significa A > B). No **IGD+** e no **ED**, menor é melhor (A < B).

Como o tamanho de efeito não depende do p-valor, ele é especialmente útil com amostras pequenas. Por isso, recomenda-se calcular o A_{12} para todos os pares de interesse, e não apenas para os significativos, destacando os de efeito grande mesmo quando o p ajustado não atingir 0,05.

3.3 Convergência do fitness

Exemplos de imagem para análise de **convergência do fitness** (cada grafico é para uma função objetivo e as linhas são para as configurações. No eixo x temos o número da geração, apresentando a cada 30 gerações), no caso do experimento vão ser para cada ponto de interação e na geração inicial.

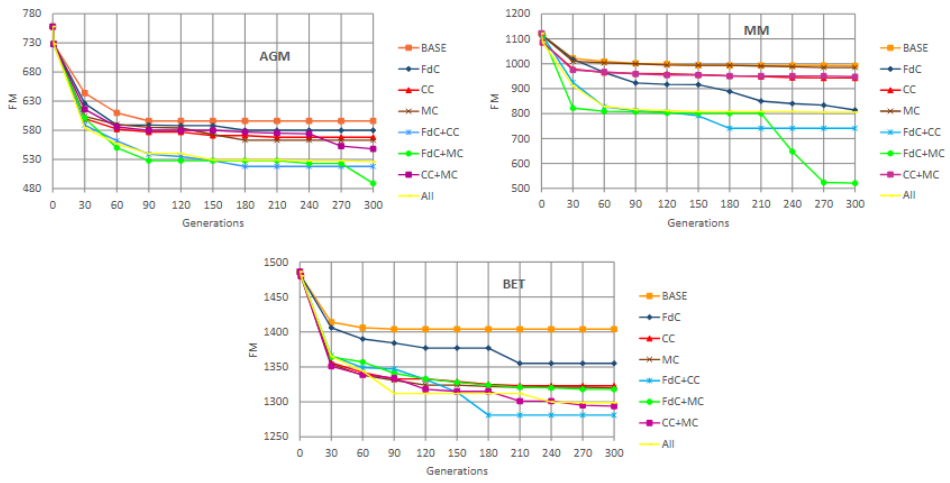


Fig. 7 FM values over generations (the lower value, the better result).

Gráfico de coordenadas paralelas para mostrar graficamente o **fitness da fronteira de Pareto** de cada configuração. Cada gráfico AGM, MM e BET mostram o resultado de um algoritmo. Cada curva representa a curva de pareto real referente a cada execução.

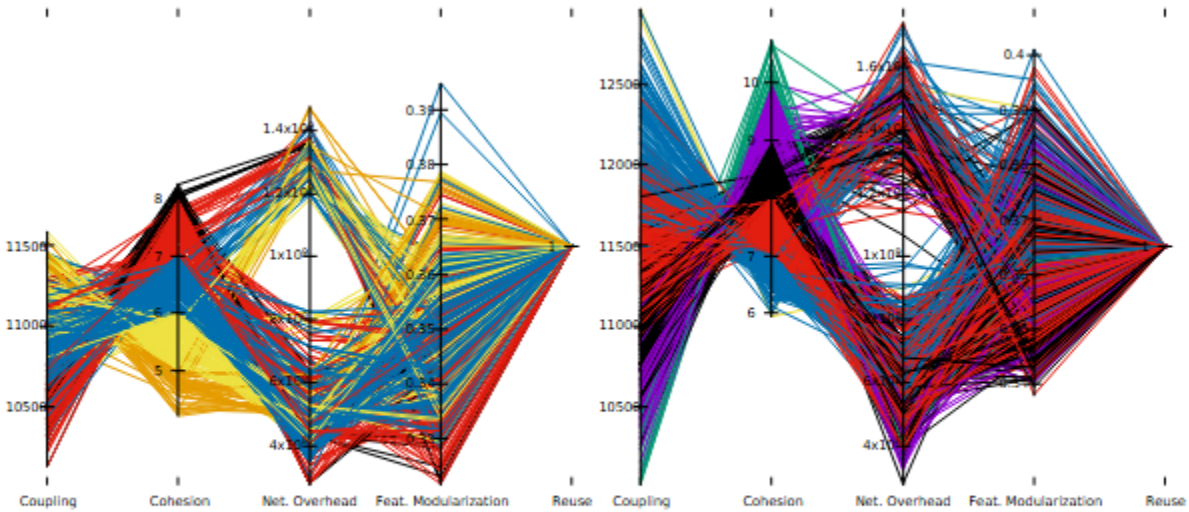


Fig. 4 Solutions' trade-off among the five criteria of PF_{known} sets.