Elitismo, tratamento de restrição e R-NSGA-III na decomposição interativa de monólitos em microsserviços: um experimento com decisores simulados por personas

1st Domini da Silva Acco
DIN
UEM
Maringá, Brasil

2nd Lucas Sarri de Mello
DIN
UEM
Maringá, Brasil

3rd Lucas Garcia
DIN
UEM
Maringá, Brasil

***Resumo*—A decomposição de aplicações monolíticas em microsserviços pode ser tratada como um problema de otimização com muitos objetivos conflitantes. Ferramentas de busca interativa incluem o engenheiro de software (*Decision Maker*, DM) no processo, mas ainda é pouco claro se mudanças recentes na busca, como elitismo, tratamento de restrição (PENALTY/KILL) e o algoritmo R-NSGA-III, ajudam ou atrapalham nesse uso interativo. Este trabalho apresenta um experimento com a ferramenta i-toMicroservices, em que decisores simulados por personas conduzem execuções em dois sistemas (Spring Petclinic e JPetStore) sob oito configurações, com cinco execuções cada. As fronteiras finais são comparadas por Hypervolume, IGD+ e distância ao ideal, com testes estatísticos para amostras pequenas.**

***Index Terms*—microsserviços, SBSE, otimização com muitos objetivos, NSGA-III, busca interativa**

I. Introdução

Migrar uma aplicação monolítica para microsserviços exige decidir quais partes do código formam cada serviço. Essa decisão envolve critérios que entram em conflito, como acoplamento, coesão e sobrecarga de comunicação, e por isso tem sido tratada por abordagens de Engenharia de Software Baseada em Busca (SBSE) que otimizam vários objetivos ao mesmo tempo [1]. Estudos com mantenedores de sistemas reais indicam que o perfil de quem decide, especialmente a granularidade preferida, influencia fortemente a escolha dos candidatos, o que motiva abordagens interativas ou customizáveis [2].

A ferramenta i-toMicroservices inclui o DM no ciclo de busca: em momentos pré-definidos, a evolução é pausada, o DM escolhe uma solução candidata e pode aplicar operações de modificação (dividir, mover, unir e congelar microsserviços). Recentemente, a ferramenta passou a oferecer elitismo, dois tratamentos de restrição (PENALTY e KILL) e o algoritmo R-NSGA-III.

Este trabalho avalia se essas mudanças são benéficas ou prejudiciais no uso interativo com um DM humano. Para reduzir a variabilidade entre participantes, cada DM segue uma persona com regras de decisão predefinidas. Com base nisso, formulam-se as seguintes questões de pesquisa:

- **QP1:** o uso de elitismo altera a qualidade das fronteiras finais?
- **QP2:** o tratamento de restrição (PENALTY ou KILL) altera a qualidade das fronteiras finais?
- **QP3:** o R-NSGA-III produz fronteiras de qualidade diferente da obtida com o NSGA-III?

O restante do artigo está organizado assim: a Seção II apresenta a fundamentação, a Seção III discute trabalhos relacionados, a Seção IV descreve o experimento, a Seção V traz os resultados, a Seção VI discute os resultados e as ameaças à validade, e a Seção VII conclui.

II. Fundamentação Teórica

A. Decomposição de monólitos em microsserviços

Uma arquitetura de microsserviços decompõe o sistema em serviços pequenos e autônomos, cada um com escopo limitado a funções de negócio bem definidas [3]. A migração de um sistema monolítico legado para esse estilo é complexa, costuma ser feita de forma manual e depende da intuição dos arquitetos de software [3]. Para apoiar essa tarefa, diversas abordagens tratam a decomposição como um problema de otimização, usando métricas para guiar a busca por partições do sistema [1], [3].

B. Engenharia de Software Baseada em Busca e otimização com muitos objetivos

A Engenharia de Software Baseada em Busca (SBSE) reformula atividades de engenharia de software, como projeto arquitetural e refatoração, em problemas de busca. Define-se um espaço de soluções, uma representação para elas e uma função de aptidão (*fitness*) que quantifica a qualidade de cada candidata, consolidando métricas que muitas vezes são conflitantes [3], [7]. Em vez de calcular uma única solução por métodos exaustivos, a SBSE emprega meta-heurísticas que exploram o espaço de busca dentro de limites computacionais viáveis.

Quando há mais de um objetivo, o resultado da busca é um conjunto de soluções não dominadas, chamado de fronteira de Pareto. Problemas com mais de três objetivos são classificados como de muitos objetivos [4]. O NSGA-III é um algoritmo evolutivo projetado para esse cenário. Ele evolui uma população de soluções por meio de seleção, cruzamento e mutação, e sua principal inovação é um mecanismo de seleção baseado em pontos de referência bem distribuídos e em normalização adaptativa, que preserva a diversidade da população e favorece a convergência uniforme para a fronteira [3], [8].

Dois mecanismos avaliados neste trabalho merecem definição. O **elitismo** consiste em preservar as melhores soluções de uma geração na geração seguinte, evitando que sejam perdidas por mutação e cruzamento [9]. O **R-NSGA-III** é uma variante do NSGA-III que incorpora preferências do decisor por meio de pontos de referência, concentrando a busca em regiões de interesse do espaço de objetivos.

Por fim, o **tratamento de restrição** define o que acontece com soluções inviáveis. Na estratégia PENALTY, a solução inviável é penalizada, mas permanece na busca. Na estratégia KILL, ela é descartada. Na ferramenta, a restrição se aplica a decomposições desbalanceadas.

C. A abordagem toMicroservices

O toMicroservices é uma abordagem semiautomática, baseada em busca, para identificar microsserviços em sistemas legados [1]. A análise é feita no nível de método, o que permite uma granularidade fina e gera arquiteturas que podem servir de ponto de partida para a modernização. O sistema é modelado como um grafo em que cada vértice é um método associado a uma funcionalidade e cada aresta representa a comunicação entre métodos, caracterizada por chamadas estáticas, chamadas dinâmicas e volume de dados transferido [3], [4].

A abordagem otimiza cinco objetivos simultaneamente [3], [4]:

- **Coesão**: mede a relação interna entre os métodos de um microsserviço pela frequência de chamadas internas, e deve ser maximizada;
- **Acoplamento**: soma as chamadas estáticas de métodos do serviço para métodos externos a ele, e deve ser minimizado;
- **Sobrecarga de rede** (*overhead*): estima o custo de comunicação entre serviços, considerando o volume de dados e metadados de protocolo, e deve ser minimizada;
- **Modularização de funcionalidade**: avalia se cada serviço possui uma funcionalidade dominante, alinhando a decomposição aos domínios do sistema (exibida como "Funcionalidade" na ferramenta), e deve ser maximizada;
- **Reúso**: avalia se um serviço é invocado por vários componentes ou usuários finais, e deve ser maximizado.

Assunção et al. [1] mostram que esses critérios são interdependentes e conflitantes. Em sistemas pequenos, o reúso pode assumir um valor constante, o que o impede de diferenciar as soluções [4].

D. Otimização interativa e a ferramenta i-toMicroservices

O decisor (*Decision Maker*, DM) é o agente que escolhe uma solução dentro do conjunto de compromissos gerado pela busca. Segundo a literatura, as preferências do decisor podem ser incorporadas de três formas: *a priori*, antes da busca; *a posteriori*, quando ele escolhe entre as soluções não dominadas ao final; e de forma *interativa*, inserindo o decisor no ciclo da busca, de modo que as preferências possam ser refinadas durante a execução [3]. A otimização interativa é especialmente útil em problemas que dependem de critérios subjetivos e conhecimento tácito. Entretanto, avaliações manuais repetidas podem causar fadiga e reduzir a consistência das decisões [4].

O toMicroservices original opera de forma estática, com interação apenas antes e depois da busca [3]. A ferramenta i-toMicroservices o estende para um processo interativo: a evolução é pausada em gerações pré-definidas, e o decisor inspeciona a população, escolhe uma solução e aplica operadores de modificação [3], [4]. Os operadores são:

- **Dividir** (*Split*): separa métodos de um microsserviço para formar um novo;
- **Mover** (*Move*): realoca métodos entre microsserviços existentes;
- **Unir** (*Join* ou *Merge*): funde dois microsserviços em um;
- **Congelar** (*Freeze*): protege um microsserviço contra mutações.

Para reduzir o esforço do decisor, as alterações feitas em uma solução são propagadas, por meio de agrupamento (*K-means++*), para soluções semelhantes da população [3], [4].

Um estudo exploratório com três participantes e dois sistemas (JPetStore e Spring PetClinic) indicou que o perfil do decisor, como a experiência profissional e a familiaridade com refatoração, está associado a diferentes estratégias de uso dos operadores. O Mover foi o operador mais bem avaliado, e o Unir foi o menos utilizado. O estudo também relatou *algorithmic drift*: o algoritmo reintroduz dependências que o decisor havia removido e, na substituição evolutiva, soluções congeladas eram às vezes descartadas [4]. Por causa do tamanho da amostra, os autores tratam os achados como preliminares. Isso motiva a investigar se mecanismos como o elitismo, o tratamento de restrição e o R-NSGA-III influenciam o uso interativo, e justifica o uso de personas para reduzir a variabilidade entre decisores.

E. Indicadores de qualidade de fronteiras de Pareto

Um único indicador não fornece uma medida completa do desempenho de algoritmos com muitos objetivos, por isso é usual combinar indicadores com propósitos distintos [1]. Neste trabalho, adotam-se:

- o **Hypervolume** (HV), que mede a região do espaço de objetivos entre a fronteira e um ponto de referência, considerando proximidade e diversidade ao mesmo tempo. Quanto maior, melhor. As fronteiras são normalizadas em $[0, 1]$, com ponto de referência 1,1 em todos os objetivos [1];

- o **IGD+**, uma variante do IGD (*Inverted Generational Distance*) que mede a distância da fronteira de referência até a fronteira obtida. Quanto menor, melhor [1];
- a **distância euclidiana ao ideal** (ED), que mede a proximidade da fronteira à solução ideal, com valor 0 em todos os objetivos no espaço normalizado, e indica o melhor compromisso entre os objetivos. Quanto menor, melhor [1].

F. Testes estatísticos em SBSE

Algoritmos de busca são estocásticos, então a comparação entre configurações exige análise estatística sobre várias execuções. Estudos de SBSE, incluindo o de Assunção et al. [1], usam o teste de normalidade de Shapiro-Wilk, testes de hipótese paramétricos e não paramétricos e o tamanho de efeito $\hat{A}_{12}$ de Vargha-Delaney [10], que estima a probabilidade de uma configuração produzir resultado melhor que outra. Como cada execução interativa exige um decisor humano, o número de execuções por configuração é pequeno ($n = 5$). Isso limita o poder dos testes e justifica o uso de métodos não paramétricos, da correção de múltiplas comparações pelo procedimento de Benjamini-Hochberg [11] e do tamanho de efeito como complemento ao valor-p.

III. Trabalhos Relacionados

Assunção et al. [1] analisam em profundidade a abordagem toMicroservices, de busca com muitos objetivos, e mostram que os critérios otimizados são interdependentes e conflitantes e que as soluções candidatas superam a busca aleatória nos indicadores de desempenho. Carvalho et al. [2] investigam, em um estudo de caso com mantenedores de um sistema legado industrial, a utilidade das arquiteturas geradas automaticamente, e apontam a necessidade de abordagens interativas ou customizáveis. Freire et al. [5] validam um operador de ranking interativo para o NSGA-II, que incorpora a preferência do tomador de decisão. Wolschick et al. [6] comparam NSGA-II e NSGA-III no projeto de arquitetura de linhas de produto de software.

Castanho et al. [4] apresentam em seu estudo a utilização de técnicas automatizadas de SBSE combinadas a uma abordagem interativa em nível de método, que permite a intervenção dos DMs por meio dos operadores congelar, dividir, mesclar e mover. Trata-se de um estudo exploratório realizado com engenheiros de software, cujos resultados indicam que a intervenção humana no loop pode auxiliar na correção das arquiteturas de referência em até 23,7%. Além disso, a análise qualitativa sugere que a qualidade da decomposição pode ser influenciada pelo perfil do DM.

Por fim, o presente estudo utiliza a ferramenta apresentada por Castanho et al. [4] e aplica as configurações descritas na tabela I para investigar como diferentes configurações produzem resultados distintos, bem como de que forma essas configurações interagem com as intervenções realizadas pelos DMs.

Tabela I
Configurações do experimento

Config.	Algoritmo	Elitismo	Restrição
C1	NSGA-III	ON	PENALTY
C2	NSGA-III	OFF	PENALTY
C3	R-NSGA-III	ON	PENALTY
C4	R-NSGA-III	OFF	PENALTY
C5	NSGA-III	ON	KILL
C6	NSGA-III	OFF	KILL
C7	R-NSGA-III	ON	KILL
C8	R-NSGA-III	OFF	KILL

IV. Experimento

A. Ferramenta e sistemas-alvo

O experimento usa a ferramenta i-toMicroservices, executada localmente em contêineres. Os sistemas-alvo são o Spring Petclinic e o JPetStore. Cada execução parte de 6 microsserviços, tem população de 132 indivíduos e 1000 gerações. A busca é pausada nas gerações 150, 300 e 450, quando o DM interage.

B. Configurações e execuções

As oito configurações combinam algoritmo (NSGA-III ou R-NSGA-III), elitismo (ligado ou desligado) e tratamento de restrição (PENALTY ou KILL). Para cada sistema, cada configuração tem 5 execuções independentes, totalizando 40 fronteiras por sistema.

C. Decisores simulados por personas

Cada execução é conduzida por um DM que segue uma persona. Neste trabalho, utilizou-se a persona P3 (*Extrator de Domínio Veloz*), que decide cedo e rapidamente: nas pausas, escolhe soluções com boa coesão e baixa sobrecarga de rede, e não necessariamente a primeira da lista, extrai domínios com a operação Dividir (por exemplo, *owner*, *vet* e *visit* no Petclinic) e usa poucos movimentos de ajuste. A persona evita as operações Unir e Congelar.

D. Coleta e indicadores de qualidade

Cada execução exporta um pacote com a fronteira final, o registro das interações e metadados. A análise de qualidade usa apenas os vetores crus da fronteira final. Para cada sistema, os valores são normalizados com os limites mínimo e máximo calculados sobre todas as fronteiras, e a fronteira de referência é o conjunto não dominado de todos os pontos normalizados. Para cada execução, calculam-se, contra essa referência: o Hypervolume (HV), com ponto de referência 1,1 em cada objetivo; o IGD+; e a distância euclidiana ao ideal (ED), com ideal em $(0, 0, 0, 0, 0)$. O *spacing* é calculado opcionalmente. No HV, valores maiores são melhores; no IGD+ e no ED, menores.

E. Análise estatística

A análise é feita por sistema e por indicador, com 8 grupos independentes de $n = 5$. Verifica-se a normalidade (Shapiro-Wilk) e a homogeneidade das variâncias (Levene). Se ambos

os pressupostos forem atendidos, usa-se ANOVA de uma via; caso contrário, Kruskal-Wallis. Quando o teste global é significativo, as 28 comparações par a par são feitas por Tukey HSD (após ANOVA) ou teste de Dunn (após Kruskal-Wallis), com correção FDR de Benjamini-Hochberg [11]. O tamanho de efeito é medido pelo A_{12} de Vargha-Delaney [10], calculado para todos os pares.

V. Resultados

A. Estatística descritiva

A tabela II resume os indicadores no JPetStore da persona 3, as configurações com PENALTY (C1-C4) apresentaram de forma geral maiores valores de HV e menores valores de IGD+ e ED média do que as configurações com KILL (C5-C8). As melhores médias de HV ocorreram em C4 e C2, e as piores em C8. Para IGD+ e ED média C2 e C4 também ficaram entre as melhores, enquanto C5-C8 concentraram os piores valores. No Spring PetClinic com os resultados apresentados na tabela III C3 apresentou as melhores médias descritivas de HV, IGD+ e ED média, mas a variabilidade é alta.

Tabela II
JPetStore: média dos indicadores por configuração

Configuração	HV	IGD+	ED média
C1-NSGA-III,elit. ON, PENALTY	0,988	0,102	0,502
C2-NSGA-III,elit. OFF, PENALTY	1,009	0,089	0,491
C3-R-NSGA-III,elit. ON, PENALTY	0,848	0,162	0,648
C4-R-NSGA-III,elit. OFF, PENALTY	1,028	0,095	0,442
C5-NSGA-III,elit. ON, KILL	0,655	0,316	0,816
C6-NSGA-III,elit. OFF, KILL	0,724	0,301	0,807
C7-R-NSGA-III,elit. ON, KILL	0,664	0,271	0,707
C8-R-NSGA-III,elit. OFF, KILL	0,531	0,420	0,895

Tabela III
Spring PetClinic: média dos indicadores por configuração

Configuração	HV	IGD+	ED média
C1-NSGA-III,elit. ON, PENALTY	0,798	0,210	0,739
C2-NSGA-III,elit. OFF, PENALTY	0,791	0,224	0,789
C3-R-NSGA-III,elit. ON, PENALTY	0,856	0,130	0,643
C4-R-NSGA-III,elit. OFF, PENALTY	0,759	0,258	0,803
C5-NSGA-III,elit. ON, KILL	0,702	0,273	0,763
C6-NSGA-III,elit. OFF, KILL	0,747	0,227	0,748
C7-R-NSGA-III,elit. ON, KILL	0,677	0,252	0,740
C8-R-NSGA-III,elit. OFF, KILL	0,726	0,229	0,679

B. Testes estatísticos

No JPetStore, os testes globais indicam diferença significativa entre as configurações em todos os indicadores, após a correção de Benjamini-Hochberg, restaram 12, 13, 9 e 10 pares significativos. A maioria dos contrastes opõe configurações com PENALTY a configurações com KILL, com tamanhos de efeito grandes em favor de PENALTY, por exemplo no HV C2 supera C5, C7 e C8 com A12 = 1,00. No IGD+ C2 também apresenta A12 = 1,00 contra C8. No Spring PetClinic, nenhum teste global foi siginificativo, com isso o pós-hoc foi encerrado e os valores A12 devem ser lidos apenas como exploratórios

Tabela IV
Pressupostos e teste global por sistema e indicador

Sistema	Indicador	Normalidade plausível?	Levene p	Teste global	p	Pares significativos após BH
JPetStore	HV	Sim	0,269	ANOVA	$1{,}38\times10^{-7}$	12
JPetStore	IGD+	Sim	0,081	ANOVA	$8{,}29\times10^{-9}$	13
JPetStore	ED média	Não	0,615	Kruskal-Wallis	$9{,}09\times10^{-5}$	9
JPetStore	ED mínima	Sim	0,189	ANOVA	$5{,}18\times10^{-7}$	10
Spring PetClinic	HV	Não	0,839	Kruskal-Wallis	0,1437	0
Spring PetClinic	IGD+	Não	0,974	Kruskal-Wallis	0,1510	0
Spring PetClinic	ED média	Não	0,972	Kruskal-Wallis	0,1574	0
Spring PetClinic	ED mínima	Não	0,932	Kruskal-Wallis	0,4361	0

Na tabela IV mostra que no Spring PetClinic a normalidade não foi plausível em pelo menos uma configuração para todos os indicadores, o que motivou o uso de Kruskal-Wallis. No JPetStore, apenas a ED média teve a normalidade rejeitada em uma configuração, nos demais indicadores a ANOVA foi utilizada, em geral as variâncias foram homogêneas em todos os casos (Levene p > 0,05).

VI. Discussão e Ameaças à Validade

Algumas limitações já são conhecidas. Primeiro, com $n = 5$ por grupo e 28 comparações por indicador, espera-se que poucos pares permaneçam significativos após a correção por múltiplas comparações. Segundo, a análise de qualidade avalia apenas a fronteira final, e não a convergência ao longo das gerações. Terceiro, a mesma persona foi executada por mais de uma pessoa, e pequenas diferenças de critério (como o número de divisões por pausa e o tempo de decisão) podem introduzir variabilidade. Quarto, o registro de justificativas das decisões não foi preenchido nas execuções. Por fim, os resultados valem para dois sistemas e uma persona, e não se generalizam diretamente a outros contextos.

A. QP1 - Elitismo altera a qualidade das fronteiras finais?

Não há evidência estatística de ue o elitismo altere a qualidade final das fronteiras, no JPetStore as médias com elitismo desligado são ligeiramente melhores em alguns casos, mas os contrastes diretos não sobrevivem à correção por múltiplas comparações, e os tamanhos de efeito são pequenos ou desprezíveis. No Spring PetClinic não há diferença global significativa, dessa forma a resposta para esta questão é inconclusiva, com uma tendência fraca e não significativa de que elitismo desligado seja ligeiramente melhor no JPetStore.

B. QP2 - PENALTY ou KILL altera a qualidade?

Sim, no JPetStore as configurações com PENALTY apresentam HV maior e IGD+/ED menores que as com KILL, com vários pares significativos após BH e tamanhos de efeito grandes. Por exemplo, C2 tem A12 = 1,00 contra C5, C7 e C8 no HV, e C2 também supera C8 no IGD+ com A12 = 1,00. No Spring PetClinic não há diferença global significativa e as médias não são consistentes. Portanto, PENALTY é a estratégia mais adequada no JPetStore, mas o resultado não se generaliza automaticamente ao Spring PetClinic.

C. QP3 - R-NSGA-III produz fronteiras diferentes do NSGA-III?

O R-NSGA-III não apresentou ganho consistente, no JPetStore C4 tem a melhor média HV e ED média, mas é estatisticamente equivalente a C2 A12 próximo de 0,52 no HV e

p ajustado não significativo. Além disso C3, C7 e C8 ficam entre as piores, no Spring PetClinic C3 tem as melhores médias descritivas, mas sem significância global. Assim não há evidência de superioridade geral do R-NSGA-III, ele pode ser competitivo em configurações em configurações específicas como C4 no JPetStore e C3 no Spring PetClinic, mas também degrada o desempenho quando combinado com KILL ou com elitismo ON em alguns casos.

VII. Conclusão

Avaliando os resultados com as configurações diferentes, no JPetStore PENALTY foi claramente superior a KILL, elitismo e R-NSGA-III não mostraram efeitos consistentes. No Spring PetClinic nenhuma configuração se destacou estatisticamente, os resultados sugerem que a escolha do tratamento de restrição é o fator mais crítico no contexto avaliado, enquanto elitismo e R-NSGA-III exigem mais investigação com outras personas, sistemas e um número maior de execuções.

Referências

[1] W. K. G. Assunção, T. E. Colanzi, L. Carvalho, A. Garcia, J. A. Pereira, M. J. de Lima, and C. Lucena, "Analysis of a many-objective optimization approach for identifying microservices from legacy systems," *Empirical Software Engineering*, vol. 27, no. 2, art. 51, 2022. doi: 10.1007/s10664-021-10049-7.

[2] L. Carvalho, T. E. Colanzi, W. K. G. Assunção, A. Garcia, J. A. Pereira, M. Kalinowski, R. M. de Mello, M. J. de Lima, and C. Lucena, "On the usefulness of automatically generated microservice architectures," *IEEE Trans. Softw. Eng.*, vol. 50, no. 3, pp. 651–667, 2024. doi: 10.1109/TSE.2024.3361209.

[3] J. Castanho, J. Gomes, T. E. Colanzi, A. M. M. M. Amaral, W. K. G. Assunção, and A. Garcia, "i-toMicroservices: Empowering architects in the interactive modernization of monolithic systems," in *Proc. Brazilian Symposium on Software Engineering (SBES)*, São Paulo, Brazil, 2026.

[4] J. Castanho, C. G. Britez, W. M. Freire, A. M. M. M. Amaral, T. E. Colanzi, and W. K. G. Assunção, "Human in the loop for microservice identification: An exploratory study," in *Proc. Brazilian Symposium on Software Components, Architectures, and Reuse (SBCARS)*, São Paulo, Brazil, 2026.

[5] W. M. Freire, C. Rosa, A. M. M. M. Amaral, and T. Colanzi, "Validating an interactive ranking operator for NSGA-II to support the optimization of software engineering problems," in *Proc. Brazilian Symposium on Software Engineering (SBES)*, 2022, pp. 337–346. doi: 10.1145/3555228.3555232.

[6] L. Wolschick, P. C. Gonçalves, J. Choma Neto, W. M. Freire, A. M. M. M. Amaral, and T. E. Colanzi, "Evaluating the performance of NSGA-II and NSGA-III on product line architecture design," in *Proc. Brazilian Symposium on Software Components, Architectures, and Reuse (SBCARS)*, 2024, pp. 11–20.

[7] M. Harman, S. A. Mansouri, and Y. Zhang, "Search-based software engineering: Trends, techniques and applications," *ACM Comput. Surv.*, vol. 45, no. 1, art. 11, 2012. doi: 10.1145/2379776.2379787.

[8] K. Deb and H. Jain, "An evolutionary many-objective optimization algorithm using reference-point-based nondominated sorting approach, part I: Solving problems with box constraints," *IEEE Trans. Evol. Comput.*, vol. 18, no. 4, pp. 577–601, 2014. doi: 10.1109/TEVC.2013.2281535.

[9] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, "A fast and elitist multiobjective genetic algorithm: NSGA-II," *IEEE Trans. Evol. Comput.*, vol. 6, no. 2, pp. 182–197, 2002. doi: 10.1109/4235.996017.

[10] A. Vargha and H. D. Delaney, "A critique and improvement of the CL common language effect size statistics of McGraw and Wong," *Journal of Educational and Behavioral Statistics*, vol. 25, no. 2, pp. 101–132, 2000.

[11] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B*, vol. 57, no. 1, pp. 289–300, 1995.