Elitismo, tratamento de restrição e R-NSGA-III na decomposição interativa de monólitos em microsserviços: um experimento com decisores simulados por personas

1st Domini da Silva Acco
DIN
UEM
Maringá, Brasil
pg2026009935@uem.br

2nd Lucas Sarri de Mello
DIN
UEM
Maringá, Brasil
pg407439@uem.br

3rd Lucas Garcia
DIN
UEM
Maringá, Brasil
pg407593@uem.br

***Resumo*—A decomposição de aplicações monolíticas em microsserviços pode ser tratada como um problema de otimização com muitos objetivos conflitantes. Ferramentas de busca interativa incluem o engenheiro de software (*Decision Maker*, DM) no processo, mas ainda não está estabelecido se mudanças recentes na busca, como elitismo, tratamento de restrição (PENALTY/KILL) e o algoritmo R-NSGA-III, favorecem ou prejudicam esse uso interativo. Este trabalho apresenta um experimento com a ferramenta i-toMicroservices, em que decisores seguem a persona P3 (Extrator de Domínio Veloz) e conduzem execuções em dois sistemas (Spring PetClinic e JPetStore) sob oito configurações, com cinco execuções por configuração em cada sistema. As fronteiras finais são comparadas por Hypervolume (HV), IGD+ e distância euclidiana média ao ideal (ED), com testes estatísticos para amostras pequenas. No Spring PetClinic, os testes globais não identificaram diferenças estatisticamente significativas entre as configurações nos três indicadores. No JPetStore, foram identificadas diferenças globais significativas, com destaque para o tratamento de restrição: PENALTY obteve tamanhos de efeito favoráveis em relação a KILL nos quatro contrastes que isolam esse fator, e três deles apresentaram diferenças significativas nos três indicadores após a correção para múltiplas comparações. Como cada bloco de configurações foi conduzido por um participante diferente, essa diferença não pode ser atribuída apenas ao tratamento de restrição. Os contrastes que isolam o elitismo e o algoritmo não apresentaram diferenças significativas após a correção. Os resultados indicam que o efeito das configurações pode variar conforme o sistema analisado, dentro das condições avaliadas neste experimento.**

***Index Terms*—microsserviços, SBSE, otimização com muitos objetivos, NSGA-III, busca interativa**

I. Introdução

A migração de uma aplicação monolítica para microsserviços exige definir quais partes do código compõem cada serviço. Essa definição envolve critérios conflitantes, como acoplamento, coesão e sobrecarga de comunicação, e por isso tem sido tratada por abordagens de Engenharia de Software Baseada em Busca (SBSE) que otimizam vários objetivos ao mesmo tempo [1]. Estudos com mantenedores de sistemas reais indicam que o perfil do decisor, especialmente a granularidade preferida, influencia a escolha dos candidatos, o que motiva abordagens interativas ou customizáveis [2].

A ferramenta i-toMicroservices inclui o DM no ciclo de busca: em momentos pré-definidos, a evolução é pausada, o DM escolhe uma solução candidata e pode aplicar operações de modificação (dividir, mover, unir e congelar microsserviços). Recentemente, a ferramenta passou a oferecer elitismo, dois tratamentos de restrição (PENALTY e KILL) e o algoritmo R-NSGA-III.

Este trabalho avalia se essas mudanças são benéficas ou prejudiciais no uso interativo com um DM humano. Para reduzir a variabilidade entre participantes, cada DM segue uma persona com regras de decisão predefinidas. Com base nisso, formulam-se as seguintes questões de pesquisa:

- **QP1:** o uso de elitismo altera a qualidade das fronteiras finais?
- **QP2:** o tratamento de restrição (PENALTY ou KILL) altera a qualidade das fronteiras finais?
- **QP3:** o R-NSGA-III produz fronteiras de qualidade diferente da obtida com o NSGA-III?

O restante do artigo está organizado da seguinte forma: a Seção II apresenta a fundamentação, a Seção III discute trabalhos relacionados, a Seção IV descreve o experimento, a Seção V traz os resultados, a Seção VI discute os resultados e as ameaças à validade, e a Seção VII conclui.

II. Fundamentação Teórica

A. Decomposição de monólitos em microsserviços

Uma arquitetura de microsserviços decompõe o sistema em serviços pequenos e autônomos, cada um com escopo limitado a funções de negócio bem definidas [3]. A migração de um sistema monolítico legado para esse estilo é complexa, costuma ser feita de forma manual e depende da intuição dos arquitetos de software [3]. Para apoiar essa tarefa, diversas abordagens tratam a decomposição como um problema de otimização, usando métricas para guiar a busca por partições do sistema [1], [3].

B. Engenharia de Software Baseada em Busca e otimização com muitos objetivos

A Engenharia de Software Baseada em Busca (SBSE) reformula atividades de engenharia de software, como projeto arquitetural e refatoração, em problemas de busca. Define-se um espaço de soluções, uma representação para elas e uma função de aptidão (*fitness*) que quantifica a qualidade de cada candidata, consolidando métricas que muitas vezes são conflitantes [3], [7]. Em vez de calcular uma única solução por métodos exaustivos, a SBSE emprega meta-heurísticas que exploram o espaço de busca dentro de limites computacionais viáveis.

Quando há mais de um objetivo, o resultado da busca é um conjunto de soluções não dominadas, chamado de fronteira de Pareto. Problemas com mais de três objetivos são classificados como de muitos objetivos [4]. O NSGA-III é um algoritmo evolutivo projetado para esse cenário. Ele evolui uma população de soluções por meio de seleção, cruzamento e mutação, e sua principal inovação é um mecanismo de seleção baseado em pontos de referência bem distribuídos e em normalização adaptativa, que preserva a diversidade da população e favorece a convergência uniforme para a fronteira [3], [8].

Dois mecanismos avaliados neste trabalho requerem definição. O elitismo consiste em preservar as soluções de maior aptidão de uma geração na geração seguinte, evitando que sejam perdidas por mutação e cruzamento [9]. O R-NSGA-III é uma variante do NSGA-III que incorpora preferências do decisor por meio de pontos de referência, concentrando a busca em regiões de interesse do espaço de objetivos.

Por fim, o tratamento de restrição define o que acontece com soluções inviáveis. Na estratégia PENALTY, a solução inviável é penalizada, mas permanece na busca. Na estratégia KILL, ela é descartada. Na ferramenta, a restrição se aplica a decomposições desbalanceadas.

C. A abordagem toMicroservices

O toMicroservices é uma abordagem semiautomática, baseada em busca, para identificar microsserviços em sistemas legados [1]. A análise é feita no nível de método, o que permite uma granularidade fina e gera arquiteturas que podem servir de ponto de partida para a modernização. O sistema é modelado como um grafo em que cada vértice é um método associado a uma funcionalidade e cada aresta representa a comunicação entre métodos, caracterizada por chamadas estáticas, chamadas dinâmicas e volume de dados transferido [3], [4].

A abordagem otimiza cinco objetivos simultaneamente [3], [4]:

- **Coesão:** mede a relação interna entre os métodos de um microsserviço pela frequência de chamadas internas, e deve ser maximizada;
- **Acoplamento:** soma as chamadas estáticas de métodos do serviço para métodos externos a ele, e deve ser minimizado;
- **Sobrecarga de rede (*overhead*):** estima o custo de comunicação entre serviços, considerando o volume de dados e metadados de protocolo, e deve ser minimizada;
- **Modularização de funcionalidade:** avalia se cada serviço possui uma funcionalidade dominante, alinhando a decomposição aos domínios do sistema (exibida como "Funcionalidade" na ferramenta), e deve ser maximizada;
- **Reúso:** avalia se um serviço é invocado por vários componentes ou usuários finais, e deve ser maximizado.

Assunção et al. [1] indicam que esses critérios são interdependentes e conflitantes. Em sistemas pequenos, o reúso pode assumir um valor constante, o que o impede de diferenciar as soluções [4].

D. Otimização interativa e a ferramenta i-toMicroservices

O decisor (*Decision Maker*, DM) é o agente que escolhe uma solução dentro do conjunto de compromissos gerado pela busca. Segundo a literatura, as preferências do decisor podem ser incorporadas de três formas: *a priori*, antes da busca; *a posteriori*, quando ele escolhe entre as soluções não dominadas ao final; e de forma interativa, inserindo o decisor no ciclo da busca, de modo que as preferências possam ser refinadas durante a execução [3]. A otimização interativa é indicada sobretudo para problemas que dependem de critérios subjetivos e conhecimento tácito. Entretanto, avaliações manuais repetidas podem causar fadiga e reduzir a consistência das decisões [4].

O toMicroservices original opera de forma estática, com interação apenas antes e depois da busca [3]. A ferramenta i-toMicroservices o estende para um processo interativo: a evolução é pausada em gerações pré-definidas, e o decisor inspeciona a população, escolhe uma solução e aplica operadores de modificação [3], [4]. Os operadores são:

- **Dividir (*Split*):** separa métodos de um microsserviço para formar um novo;
- **Mover (*Move*):** realoca métodos entre microsserviços existentes;
- **Unir (*Join* ou *Merge*):** funde dois microsserviços em um;
- **Congelar (*Freeze*):** protege um microsserviço contra mutações.

Para reduzir o esforço do decisor, as alterações feitas em uma solução são propagadas, por meio de agrupamento (K-means++), para soluções semelhantes da população [3], [4]. Um estudo exploratório com três participantes e dois sistemas (JPetStore e Spring PetClinic) indicou que o perfil do decisor, como a experiência profissional e a familiaridade com refatoração, está associado a diferentes estratégias de uso dos operadores. O Mover foi o operador mais bem avaliado, e o Unir foi o menos utilizado. O estudo também relatou *algorithmic drift*: o algoritmo reintroduz dependências que o decisor havia removido e, na substituição evolutiva, soluções congeladas eram às vezes descartadas [4]. Em razão do tamanho da amostra, os autores tratam os achados como preliminares. Esse cenário motiva a investigação sobre se mecanismos como o elitismo, o tratamento de restrição e o R-NSGA-III influenciam o uso interativo, e justifica o uso de personas para reduzir a variabilidade entre decisores.

E. Indicadores de qualidade de fronteiras de Pareto

Um único indicador não fornece uma medida completa do desempenho de algoritmos com muitos objetivos, por isso é usual combinar indicadores com propósitos distintos [1]. Neste trabalho, adotam-se:

- o **Hypervolume (HV)**, que mede a região do espaço de objetivos entre a fronteira e um ponto de referência, considerando proximidade e diversidade ao mesmo tempo. Valores maiores indicam maior qualidade. As fronteiras são normalizadas em $[0, 1]$, com ponto de referência 1,1 em todos os objetivos [1];
- o **IGD+**, uma variante do IGD (*Inverted Generational Distance*) que mede a distância da fronteira de referência até a fronteira obtida. Valores menores indicam maior qualidade [1];
- a **distância euclidiana ao ideal (ED)**, que mede a proximidade da fronteira à solução ideal, com valor 0 em todos os objetivos no espaço normalizado, e indica o grau de compromisso entre os objetivos. Valores menores indicam maior qualidade [1].

F. Testes estatísticos em SBSE

Como os algoritmos de busca são estocásticos, a comparação entre configurações exige análise estatística sobre várias execuções. Estudos de SBSE, incluindo o de Assunção et al. [1], usam o teste de normalidade de Shapiro-Wilk, testes de hipótese paramétricos e não paramétricos e o tamanho de efeito $\hat{A}_{12}$ de Vargha-Delaney [10], que estima a probabilidade de uma configuração produzir resultado mais favorável que outra. Como cada execução interativa exige um decisor humano, o número de execuções por configuração é pequeno ($n = 5$). Isso limita o poder dos testes e justifica o uso de métodos não paramétricos, da correção de múltiplas comparações pelo procedimento de Benjamini-Hochberg [11] e do tamanho de efeito como complemento ao valor-p.

III. Trabalhos Relacionados

Assunção et al. [1] analisam a abordagem toMicroservices, de busca com muitos objetivos, e indicam que os critérios otimizados são interdependentes e conflitantes e que as soluções candidatas superam a busca aleatória nos indicadores de desempenho. Carvalho et al. [2] investigam, em um estudo de caso com mantenedores de um sistema legado industrial, a utilidade das arquiteturas geradas automaticamente, e apontam a necessidade de abordagens interativas ou customizáveis. Freire et al. [5] validam um operador de *ranking* interativo para o NSGA-II, que incorpora a preferência do tomador de decisão. Wolschick et al. [6] comparam NSGA-II e NSGA-III no projeto de arquitetura de linhas de produto de software.

Castanho et al. [4] apresentam a utilização de técnicas automatizadas de SBSE combinadas a uma abordagem interativa em nível de método, que permite a intervenção dos DMs por meio dos operadores congelar, dividir, mesclar e mover. Trata-se de um estudo exploratório realizado com engenheiros de software, cujos resultados sugerem que a intervenção humana no *loop* pode auxiliar na correção das arquiteturas de referência em até 23,7%. Além disso, a análise qualitativa sugere que a qualidade da decomposição pode ser influenciada pelo perfil do DM.

Por fim, o presente estudo utiliza a ferramenta apresentada por Castanho et al. [4] e aplica as configurações descritas na Tabela I para investigar como diferentes configurações produzem resultados distintos, bem como de que forma essas configurações interagem com as intervenções realizadas pelos DMs.

Tabela I
Configurações do experimento

Config.	Algoritmo	Elitismo	Restrição
C1	NSGA-III	ON	PENALTY
C2	NSGA-III	OFF	PENALTY
C3	R-NSGA-III	ON	PENALTY
C4	R-NSGA-III	OFF	PENALTY
C5	NSGA-III	ON	KILL
C6	NSGA-III	OFF	KILL
C7	R-NSGA-III	ON	KILL
C8	R-NSGA-III	OFF	KILL

IV. Experimento

A. Ferramenta e sistemas-alvo

O experimento usa a ferramenta i-toMicroservices, executada localmente em contêineres. Os sistemas-alvo são o Spring Petclinic e o JPetStore. Cada execução parte de 6 microsserviços, tem população de 132 indivíduos e 1000 gerações. A busca é pausada nas gerações 150, 300 e 450, quando o DM interage.

B. Configurações e execuções

As oito configurações combinam algoritmo (NSGA-III ou R-NSGA-III), elitismo (ligado ou desligado) e tratamento de restrição (PENALTY ou KILL). Para cada sistema, cada configuração tem 5 execuções independentes, totalizando 40 fronteiras por sistema.

C. Decisores simulados por personas

Cada execução é conduzida por um DM que segue uma persona. Neste trabalho, utilizou-se a persona P3 (Extrator de Domínio Veloz), que decide cedo e rapidamente: nas pausas, escolhe soluções com boa coesão e baixa sobrecarga de rede, e não necessariamente a primeira da lista, extrai domínios com a operação Dividir (por exemplo, *owner*, *vet* e *visit* no Petclinic) e usa poucos movimentos de ajuste. A persona evita as operações Unir e Congelar.

D. Coleta e indicadores de qualidade

Cada execução exporta um pacote com a fronteira final, o registro das interações e metadados. A análise de qualidade usa apenas os vetores crus da fronteira final. Para cada sistema, os valores são normalizados com os limites mínimo e máximo calculados sobre todas as fronteiras, e a fronteira de referência é o conjunto não dominado de todos os pontos normalizados.

Para cada execução, calculam-se, contra essa referência: o Hypervolume (HV), com ponto de referência 1,1 em cada objetivo; o IGD+; e a distância euclidiana ao ideal (ED), com ideal em $(0, 0, 0, 0, 0)$. O *spacing* é calculado opcionalmente. No HV, valores maiores indicam maior qualidade; no IGD+ e na ED, valores menores. Como o ponto de referência é 1,1 em cada um dos cinco objetivos, o HV pode variar de 0 a $1{,}1^5 \approx 1{,}61$, o que explica valores de HV superiores a 1 nas tabelas.

E. Análise estatística

A análise é feita por sistema e por indicador, com 8 grupos independentes de $n = 5$. Verifica-se a normalidade (Shapiro-Wilk) e a homogeneidade das variâncias (Levene). Se ambos os pressupostos forem atendidos, usa-se ANOVA de uma via; caso contrário, Kruskal-Wallis. Quando o teste global é significativo, as 28 comparações par a par são feitas por Tukey HSD (após ANOVA) ou teste de Dunn (após Kruskal-Wallis), com correção FDR de Benjamini-Hochberg [11]. O tamanho de efeito é medido pelo $\hat{A}_{12}$ de Vargha-Delaney [10], calculado para todos os pares.

V. Resultados

Esta seção apresenta os resultados das oito configurações avaliadas nos sistemas Spring PetClinic e JPetStore. Inicialmente, são apresentados os indicadores descritivos das fronteiras finais, seguidos pelos testes estatísticos e pelas análises de convergência, distribuição das soluções e comportamento do decisor durante as interações.

A. Estatística descritiva

Entre C1, C2 e C3 (Tabela II e Fig. 1), C3 apresenta, no Spring PetClinic, os valores médios mais favoráveis nos três indicadores (HV de 0,856; IGD+ de 0,130; ED de 0,643), enquanto C1 e C2 apresentam médias próximas entre si. Em C1, uma das execuções tem HV de 1,07, acima do intervalo das demais (0,67 a 0,78), o que contribui para o maior desvio-padrão desse grupo. No JPetStore, a ordenação se inverte. C1 e C2 apresentam médias próximas (HV de 0,988 e 1,009; ED de 0,502 e 0,491), e C3 apresenta os valores médios menos favoráveis nos três indicadores (HV de 0,848; IGD+ de 0,162; ED de 0,648).

Considerando as configurações C4 a C8, no Spring PetClinic, observa-se que C4 apresentou o maior HV médio ($0{,}759$) entre essas cinco configurações, enquanto C8 obteve a menor ED média ($0{,}679$). Para o IGD+, C6 apresentou o menor valor médio ($0{,}227$), seguido de C8 ($0{,}229$). C7 apresentou o menor HV médio ($0{,}677$), enquanto C5 registrou o maior IGD+ médio ($0{,}273$). As distribuições ilustradas na Fig. 1 e os desvios-padrão da Tabela II também indicam variabilidade entre as execuções, especialmente em C4, cujo HV apresentou desvio-padrão de $0{,}228$.

No JPetStore, C4 apresentou os resultados médios mais favoráveis entre C4 e C8 nos três indicadores, com HV de $1{,}028$, IGD+ de $0{,}095$ e ED média de $0{,}442$. Em contrapartida, C8 apresentou os valores menos favoráveis, com HV de $0{,}531$, IGD+ de $0{,}420$ e ED média de $0{,}895$. C5, C6 e C7 ocuparam posições intermediárias, com diferenças na ordenação conforme o indicador considerado. Os dados sugerem maior separação descritiva entre algumas configurações no JPetStore do que no Spring PetClinic. Entretanto, essas observações não estabelecem, isoladamente, significância estatística, que é avaliada na subseção seguinte.

B. Testes estatísticos

A Tabela III apresenta os resultados dos testes de pressupostos e dos testes globais para as oito configurações, considerando cinco execuções por configuração. No Spring PetClinic, pelo menos uma configuração não atendeu ao pressuposto de normalidade em cada indicador, sendo utilizado o teste de Kruskal-Wallis. Nenhum dos indicadores apresentou diferença global estatisticamente significativa: HV ($H = 10{,}88$; $p = 0{,}144$), IGD+ ($H = 10{,}73$; $p = 0{,}151$) e ED média ($H = 10{,}59$; $p = 0{,}157$). No JPetStore, os pressupostos permitiram a aplicação da ANOVA para HV e IGD+, enquanto a ED média foi analisada pelo teste de Kruskal-Wallis. Os três indicadores apresentaram diferenças globais estatisticamente significativas ($p < 0{,}001$), indicando que pelo menos algumas configurações diferem entre si, sem identificar quais pares apresentam essas diferenças.

A Tabela IV apresenta os tamanhos de efeito ($\hat{A}_{12}$) dos contrastes selecionados entre as configurações, organizados de acordo com as três questões de pesquisa (QP1, QP2 e QP3). Foram incluídos apenas os pares que diferem em um único fator, mantendo os demais constantes, permitindo avaliar isoladamente os efeitos do elitismo, do tratamento de restrições e do algoritmo utilizado. Valores de $\hat{A}_{12}$ superiores a $0{,}5$ favorecem a primeira configuração do par, enquanto valores inferiores a $0{,}5$ favorecem a segunda, considerando a direção de qualidade de cada indicador. Além da magnitude e da direção dos efeitos, a tabela destaca as comparações que apresentaram significância estatística após o ajuste dos valores de p pelo procedimento FDR-BH, considerando as 28 comparações possíveis entre as oito configurações. Os resultados completos das comparações, incluindo os respectivos valores de p ajustados, são disponibilizados nos arquivos da análise estatística.

No Spring PetClinic, como os testes globais não apresentaram significância estatística, a análise de significância foi encerrada no teste global, sem comparações par a par. Os valores de $\hat{A}_{12}$ desse sistema são apresentados apenas como tamanhos de efeito e não permitem concluir que as configurações sejam diferentes ou equivalentes.

Na Tabela IV, os pares compostos apenas por C1 a C3 são C1 $\times$ C2 (QP1) e C1 $\times$ C3 (QP3).

C1 $\times$ C2 (elitismo). No JPetStore, nenhuma diferença foi significativa ($p_{BH} \geq 0{,}97$); no Spring PetClinic, os testes globais não foram significativos. Os tamanhos de efeito são desprezíveis ou pequenos, exceto no IGD+ do JPetStore, em que o efeito é médio ($\hat{A}_{12} = 0{,}32$, a favor de C2). A direção do efeito varia entre indicadores e sistemas. A ausência de

Tabela II

INDICADORES DE QUALIDADE POR CONFIGURAÇÃO (MÉDIA ± DESVIO-PADRÃO E MEDIANA; $n = 5$ POR CÉLULA). NO HV, VALORES MAIORES INDICAM MAIOR QUALIDADE; NO IGD+ E NA ED, VALORES MENORES

	HV ↑		IGD+ ↓		ED (média) ↓	
Config.	média ± dp	mediana	média ± dp	mediana	média ± dp	mediana
Spring PetClinic						
C1	0,798 ± 0,159	0,741	0,210 ± 0,085	0,234	0,739 ± 0,136	0,793
C2	0,790 ± 0,102	0,782	0,224 ± 0,061	0,229	0,789 ± 0,063	0,792
C3	0,856 ± 0,078	0,863	0,130 ± 0,050	0,114	0,643 ± 0,062	0,615
C4	0,759 ± 0,228	0,704	0,258 ± 0,090	0,262	0,803 ± 0,144	0,831
C5	0,702 ± 0,190	0,621	0,273 ± 0,093	0,316	0,763 ± 0,143	0,830
C6	0,747 ± 0,058	0,763	0,227 ± 0,049	0,216	0,748 ± 0,058	0,714
C7	0,677 ± 0,064	0,671	0,252 ± 0,061	0,277	0,740 ± 0,080	0,729
C8	0,726 ± 0,085	0,769	0,229 ± 0,059	0,203	0,679 ± 0,085	0,655
JPetStore						
C1	0,988 ± 0,055	0,983	0,102 ± 0,019	0,096	0,502 ± 0,047	0,483
C2	1,009 ± 0,069	0,984	0,089 ± 0,021	0,094	0,491 ± 0,065	0,488
C3	0,848 ± 0,104	0,849	0,162 ± 0,054	0,159	0,648 ± 0,074	0,636
C4	1,028 ± 0,203	0,972	0,095 ± 0,052	0,112	0,442 ± 0,123	0,486
C5	0,655 ± 0,092	0,664	0,316 ± 0,068	0,299	0,816 ± 0,154	0,713
C6	0,724 ± 0,165	0,648	0,301 ± 0,094	0,304	0,807 ± 0,165	0,841
C7	0,664 ± 0,089	0,629	0,271 ± 0,061	0,265	0,707 ± 0,110	0,710
C8	0,531 ± 0,106	0,528	0,420 ± 0,123	0,466	0,895 ± 0,114	0,887

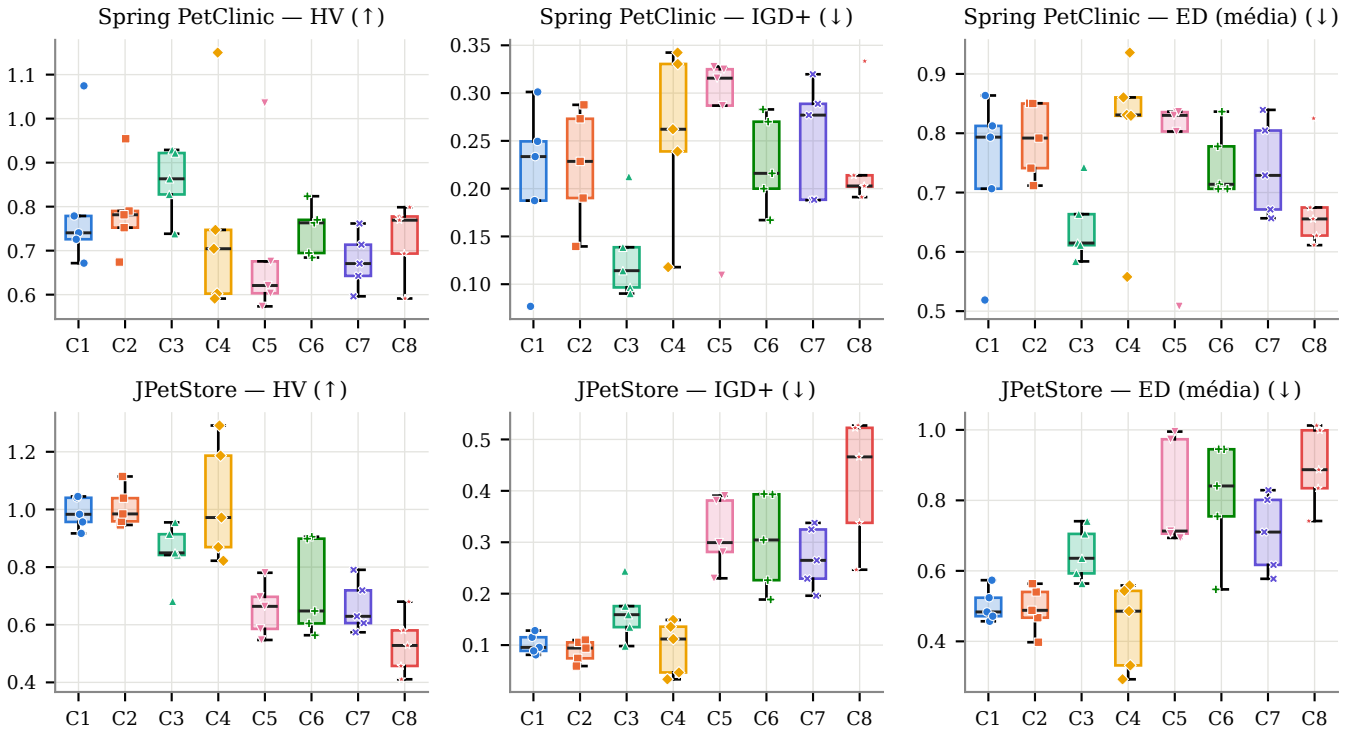


Figura 1. Distribuição de HV, IGD+ e ED (média) nas cinco execuções de cada configuração. Cada marcador representa uma execução; a linha preta indica a mediana.

Tabela III
PRESSUPOSTOS E TESTE GLOBAL (8 GRUPOS, $n = 5$). SW: MENOR p DE SHAPIRO-WILK E A CONFIGURAÇÃO CORRESPONDENTE; LEV.: p DE LEVENE CENTRADO NA MEDIANA. VALORES EM NEGRITO INDICAM $p \leq 0{,}05$

Ind.	SW (config.)	Lev.	Teste	p
Spring PetClinic				
HV	0,018 (C5)	0,839	KW: H=10,88	0,144
IGD+	0,006 (C8)	0,974	KW: H=10,73	0,151
ED	0,001 (C5)	0,972	KW: H=10,59	0,157
JPetStore				
HV	0,104 (C6)	0,269	ANOVA: F=12,48	**<0,001**
IGD+	0,291 (C8)	0,081	ANOVA: F=15,93	**<0,001**
ED	0,025 (C5)	0,615	KW: H=30,10	**<0,001**

significância estatística não demonstra equivalência entre as configurações.

C1 × C3 (algoritmo). No JPetStore, o efeito é grande e favorece C1 nos três indicadores ($\hat{A}_{12}$ de 0,96 no HV, 0,92 no IGD+ e 0,96 na ED), o que indica que o NSGA-III obteve valores mais favoráveis na maioria das 25 comparações entre execuções. Após a correção para as 28 comparações, porém, nenhum desses pares é significativo; o menor p ajustado corresponde à ED ($p_{BH} = 0{,}164$). No Spring PetClinic, o efeito também é grande, mas favorece C3 ($\hat{A}_{12}$ de 0,28 no HV e de 0,24 no IGD+ e na ED), sem significância estatística. O contraste C2 × C3, que difere em dois fatores, apresenta o mesmo padrão ($\hat{A}_{12}$ entre 0,96 e 1,00 a favor de C2 no JPetStore e entre 0,08 e 0,32 a favor de C3 no Spring PetClinic), também sem pares significativos.

No JPetStore, nenhuma das comparações entre C1, C2 e C3 apresentou significância estatística após a correção para múltiplas comparações; no Spring PetClinic, os testes globais não foram significativos.

Demais contrastes de QP1 (elitismo). No contraste C3 × C4, o Spring PetClinic apresentou efeitos grandes favoráveis a C3 nos três indicadores ($\hat{A}_{12}$ entre $0{,}76$ e $0{,}92$). No JPetStore, a direção foi oposta, favorecendo C4 ($\hat{A}_{12}$ entre $0{,}00$ e $0{,}24$). Em C5 × C6, o Spring PetClinic favoreceu C6 nos três indicadores, enquanto o JPetStore apresentou efeitos pequenos ou desprezíveis, com direção variável. No contraste C7 × C8, o Spring PetClinic favoreceu C8 em HV e ED, com efeito desprezível em IGD+. No JPetStore, C7 foi favorecida nos três indicadores, com efeitos grandes ($\hat{A}_{12}$ entre $0{,}84$ e $0{,}92$). Nenhum desses três contrastes apresentou significância estatística no JPetStore após a correção para múltiplas comparações.

QP2 (tratamento de restrição). No Spring PetClinic, os contrastes C1 × C5 e C3 × C7 favoreceram PENALTY nos três indicadores. Em C2 × C6, a direção variou entre os indicadores, enquanto C4 × C8 favoreceu KILL nos três indicadores. Esses resultados devem ser interpretados apenas como tendências indicadas pelos tamanhos de efeito, considerando a ausência de significância nos testes globais.

No JPetStore, PENALTY foi favorecida nos quatro contrastes. Os pares C1 × C5, C2 × C6 e C4 × C8 apresentaram diferenças estatisticamente significativas nos três indicadores após a correção FDR-BH, com efeitos grandes ($\hat{A}_{12}$ entre $0{,}96$ e $1{,}00$). O contraste C3 × C7 também favoreceu PENALTY, com efeitos médios ou grandes, mas não apresentou significância estatística após a correção.

Demais contrastes de QP3 (algoritmo). Em C2 × C4, o Spring PetClinic favoreceu o NSGA-III nos três indicadores, enquanto o JPetStore apresentou efeitos pequenos ou desprezíveis, com direção variável. No contraste C5 × C7, o R-NSGA-III foi favorecido nos dois sistemas, embora com magnitudes distintas. Por fim, C6 × C8 apresentou efeitos de direção variável no Spring PetClinic, enquanto o JPetStore favoreceu o NSGA-III nos três indicadores, com efeitos grandes para HV e IGD+ e pequeno para ED. Nenhum desses três contrastes apresentou significância estatística no JPetStore após a correção para múltiplas comparações.

Demais comparações significativas. Considerando todas as 28 comparações possíveis entre as oito configurações, o JPetStore apresentou 12 pares significativos para HV, 13 para IGD+ e 9 para ED média, após a correção para múltiplas comparações.

Além dos três contrastes significativos de QP2 destacados na Tabela IV, os pares C2 × C5, C2 × C8, C4 × C5, C4 × C6 e C1 × C8 apresentaram diferenças significativas nos três indicadores. Os pares C2 × C7, C1 × C7, C3 × C8 e C4 × C7 apresentaram diferenças significativas em HV e IGD+. Já C1 × C6 apresentou diferenças significativas em IGD+ e ED média.

Em todos esses contrastes adicionais, a configuração com resultados mais favoráveis foi, respectivamente, C2, C2, C4, C4, C1, C2, C1, C3, C4 e C1. Como essas comparações modificam mais de um fator simultaneamente, seus resultados não permitem atribuir as diferenças observadas a um único mecanismo.

C. Fronteiras e convergência

A Fig. 2 apresenta a evolução dos valores dos objetivos ao longo das gerações, considerando a mediana das cinco execuções de cada configuração. A geração inicial apresenta valores iguais entre as configurações, devido à população inicial determinística. O objetivo Reúso foi omitido da figura porque seu menor valor na população foi 1,0 em todas as gerações. Em ambos os sistemas, observa-se uma redução mais pronunciada dos valores dos objetivos até a geração 150, seguida de mudanças menores e trajetórias distintas entre as configurações.

Em C1 a C3, a maior parte da redução dos valores dos objetivos ocorre até a geração 150, antes da primeira interação. A partir desse ponto, acoplamento e *overhead* variam pouco, enquanto os objetivos de coesão e funcionalidade, na forma invertida, continuam a diminuir até a geração 450. As trajetórias das três configurações são próximas, com diferenças pontuais. No JPetStore, C3 termina com o maior acoplamento mediano entre as três (223, contra 190 em C1 e 198 em C2) e apresenta o maior *overhead* na geração 300. No Spring

Tabela IV

TAMANHO DE EFEITO $\hat{A}_{12}$ NOS PARES DE INTERESSE (CONTRASTES DE UM FATOR), COM A MAGNITUDE INDICADA POR D (DESPREZÍVEL), P (PEQUENA), M (MÉDIA) E G (GRANDE). VALORES DE $\hat{A}_{12} > 0{,}5$ FAVORECEM A PRIMEIRA CONFIGURAÇÃO DO PAR, CONSIDERANDO A DIREÇÃO DE CADA INDICADOR. VALORES EM NEGRITO COM * INDICAM p AJUSTADO POR FDR-BH (28 COMPARAÇÕES) $\leq 0{,}05$, COM TESTE GLOBAL SIGNIFICATIVO

	Spring PetClinic			JPetStore		
Par	HV	IGD+	ED	HV	IGD+	ED
QP1 (elitismo ON × OFF)						
C1 × C2	0,36P	0,52D	0,56P	0,44D	0,32M	0,48D
C3 × C4	0,76G	0,92G	0,80G	0,24G	0,20G	0,00G
C5 × C6	0,20G	0,20G	0,36P	0,40P	0,52D	0,48D
C7 × C8	0,28G	0,52D	0,24G	0,84G	0,88G	0,92G
QP2 (PENALTY × KILL)						
C1 × C5	0,80G	0,80G	0,60P	**1,00G***	**1,00G***	**1,00G***
C2 × C6	0,60P	0,48D	0,24G	**1,00G***	**1,00G***	**0,96G***
C3 × C7	0,96G	0,92G	0,84G	0,92G	0,92G	0,68M
C4 × C8	0,40P	0,32M	0,20G	**1,00G***	**1,00G***	**1,00G***
QP3 (NSGA-III × R-NSGA-III)						
C1 × C3	0,28G	0,24G	0,24G	0,96G	0,92G	0,96G
C2 × C4	0,72G	0,64P	0,64P	0,52D	0,60P	0,40P
C5 × C7	0,40P	0,32M	0,40P	0,44D	0,28G	0,32M
C6 × C8	0,52D	0,48D	0,16G	0,84G	0,80G	0,64P

PetClinic, C3 termina com os menores valores de 1/Coesão e 1/Funcionalidade entre as três.

Nas configurações C4 a C8, as trajetórias também apresentam diferenças entre os sistemas. No Spring PetClinic, C4 apresenta redução do acoplamento e do overhead nas gerações finais, enquanto C5 e C6 mantêm valores de overhead relativamente estáveis após a geração 300. C7 apresenta valores de overhead superiores aos das demais configurações nas gerações finais, enquanto C8 apresenta uma redução acentuada desse objetivo entre as gerações 300 e 999. Quanto à coesão e à funcionalidade, as trajetórias apresentam variações de menor amplitude, com diferenças entre as configurações ao final da evolução.

No JPetStore, C4 apresenta valores relativamente baixos de 1/Coesão e 1/Funcionalidade após a geração 300. C6 apresenta redução do acoplamento nas gerações finais, alcançando o menor valor mediano desse objetivo entre C4 e C8 na geração 999. Em contraste, C7 mantém os maiores valores medianos de acoplamento e 1/Coesão entre essas cinco configurações na geração final. C8 apresenta oscilações no overhead, com elevação na geração 450 e redução até a geração 999. De modo geral, as trajetórias indicam que as configurações apresentam comportamentos distintos durante a evolução, sem uma melhoria uniforme em todos os objetivos analisados.

Nas coordenadas paralelas (Figs. 3 e 4), as fronteiras de C3 no JPetStore apresentam acoplamento mais alto que as de C1 e C2 (linhas entre 0,4 e 0,9 no primeiro eixo), o que é consistente com os valores menos favoráveis de HV, IGD+ e ED. No Spring PetClinic, as fronteiras de C3 são mais concentradas que as de C1 e C2, com valores de 1/Coesão e 1/Funcionalidade próximos de 0 e menor dispersão entre execuções.

Nas configurações C4 a C8, as fronteiras finais apresentam diferentes padrões de distribuição dos valores normalizados. No JPetStore (Fig. 4), C4 apresenta maior dispersão em alguns objetivos, especialmente no overhead. Em C5 e C6, também se observa variabilidade entre as soluções, com valores elevados de 1/Funcionalidade em parte das fronteiras. As configurações C7 e C8 apresentam concentração de soluções nas faixas intermediárias dos objetivos, embora existam diferenças entre execuções e valores extremos em alguns eixos.

No Spring PetClinic (Fig. 3), C4 e C5 apresentam soluções com valores relativamente elevados de overhead, enquanto C6 e C7 exibem sobreposição entre as execuções em diferentes objetivos. Em C8, observa-se maior concentração visual de soluções em faixas baixas e intermediárias, embora também ocorram valores elevados em determinados objetivos. De modo geral, as figuras sugerem heterogeneidade das fronteiras finais e os diferentes compromissos entre objetivos. Essas observações visuais complementam os indicadores de qualidade, mas não permitem, isoladamente, estabelecer diferenças estatisticamente significativas entre as configurações.

D. Comportamento do DM

Em C1 a C3 (Tabela V), o número de divisões é semelhante (19 a 23 por sistema e configuração), mas o modo de divisão variou. No Spring PetClinic, C1 e C2 utilizaram principalmente a divisão por conteúdo (busca textual no nome dos métodos), enquanto C3 utilizou apenas a divisão por seleção de métodos. No JPetStore, C3 apresenta o maior tempo ativo mediano entre as três (21 min, contra cerca de 9 min em C1 e C2) e concentra 16 renomeações, operação que não altera o *fitness*. No Spring PetClinic, a população final de C3 contém uma proporção maior de soluções marcadas pela ferramenta como influenciadas pelo DM (93%, contra 43% a 50% em C1 e C2) e mediana de 10 microsserviços, contra 6 em C1 e C2. No JPetStore, essa proporção é de 98% a 99% em C1 a C3.

Nas configurações C4 a C8 (Tabela V), o comportamento do DM apresentou diferenças entre os sistemas e as configurações. No Spring PetClinic, C4, C5 e C6 registraram,

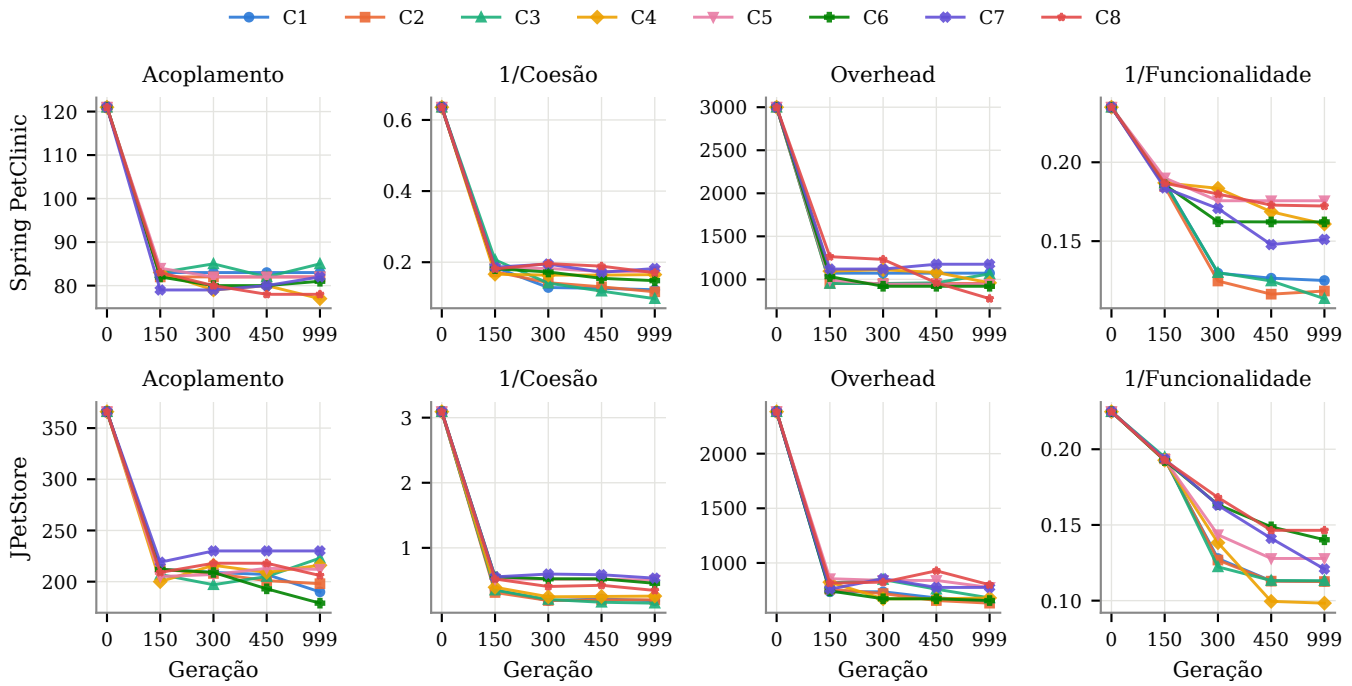


Figura 2. Menor valor de cada objetivo na população (mediana das cinco execuções) na geração inicial, nos pontos de interação e na geração final. Todos os objetivos estão em convenção de minimização; Coesão e Funcionalidade aparecem na forma invertida ($1/\text{valor}$). O Reúso, constante (valor mínimo de 1,0 em todas as gerações), foi omitido.

respectivamente, 12, 17 e 23 divisões, com predominância variável da divisão por conteúdo. O tempo ativo mediano variou de 6,2 minutos em C5 a 13,2 minutos em C4. A proporção média de soluções da população final marcadas como influenciadas pelo DM foi de 68% em C4, 31% em C5 e 33% em C6.

Ainda no Spring PetClinic, C7 e C8 registraram menos divisões, respectivamente 10 e 4, e os menores tempos ativos medianos entre essas configurações, de 3,4 e 2,6 minutos. As proporções médias de soluções marcadas como influenciadas pelo DM foram de 87% e 77%, respectivamente.

No JPetStore, C4, C5 e C6 registraram 19, 25 e 16 divisões, respectivamente, enquanto C7 e C8 apresentaram apenas 3 divisões cada. O tempo ativo mediano foi maior em C6 (23,9 minutos) e menor em C7 (6,8 minutos). A proporção média de soluções da população final marcadas como influenciadas pelo DM variou de 77% em C5 a 100% em C4. Nenhuma das configurações C4 a C8 registrou operações Unir nos dois sistemas.

Tabela V
INTERVENÇÕES DO DM POR CONFIGURAÇÃO (SOMA DAS 5 EXECUÇÕES). DIV.: DIVISÕES (ENTRE PARÊNTESES, AS DIVISÕES POR CONTEÚDO); MOV.: MOVER; UNIR: UNIR; T: TEMPO ATIVO MEDIANO (MIN); MS: MEDIANA DO NÚMERO DE MICROSSERVIÇOS NA POPULAÇÃO FINAL; DM: FRAÇÃO MÉDIA DA POPULAÇÃO FINAL MARCADA COM HASDMINTERACTION

Config.	Div.	Mov.	Unir	T	MS	DM
Spring PetClinic						
C1	19 (19)	1	0	7,1	6	50%
C2	19 (16)	6	0	4,5	6	43%
C3	19 (0)	0	0	12,1	10	93%
C4	12 (7)	4	0	13,2	7	68%
C5	17 (11)	0	0	6,2	6	31%
C6	23 (8)	2	0	9,9	6	33%
C7	10 (0)	0	0	3,4	7	87%
C8	4 (0)	1	0	2,6	7	77%
JPetStore						
C1	20 (16)	0	0	9,2	10	98%
C2	20 (20)	0	0	9,0	10	98%
C3	23 (8)	1	0	21,0	10	99%
C4	19 (2)	2	0	14,4	11	100%
C5	25 (3)	2	0	15,1	8	77%
C6	16 (3)	4	0	23,9	8	82%
C7	3 (0)	0	0	6,8	9	97%
C8	3 (0)	0	0	10,0	8	87%

VI. DISCUSSÃO E AMEAÇAS À VALIDADE

QP1 (elitismo). No par C1 × C2 (NSGA-III com PENALTY), desligar o elitismo não produziu diferença significativa na qualidade das fronteiras finais em nenhum dos sistemas, e os tamanhos de efeito foram desprezíveis ou pequenos, com exceção do IGD+ no JPetStore, em que o efeito foi médio ($\hat{A}_{12} = 0{,}32$, a favor de C2). A direção do efeito variou entre indicadores e sistemas. Uma explicação possível é que a seleção ambiental do NSGA-III já preserva soluções não dominadas entre gerações [8], o que pode reduzir o efeito do elitismo explícito sobre a fronteira final. Com $n = 5$, contudo, a ausência de diferença significativa não demonstra

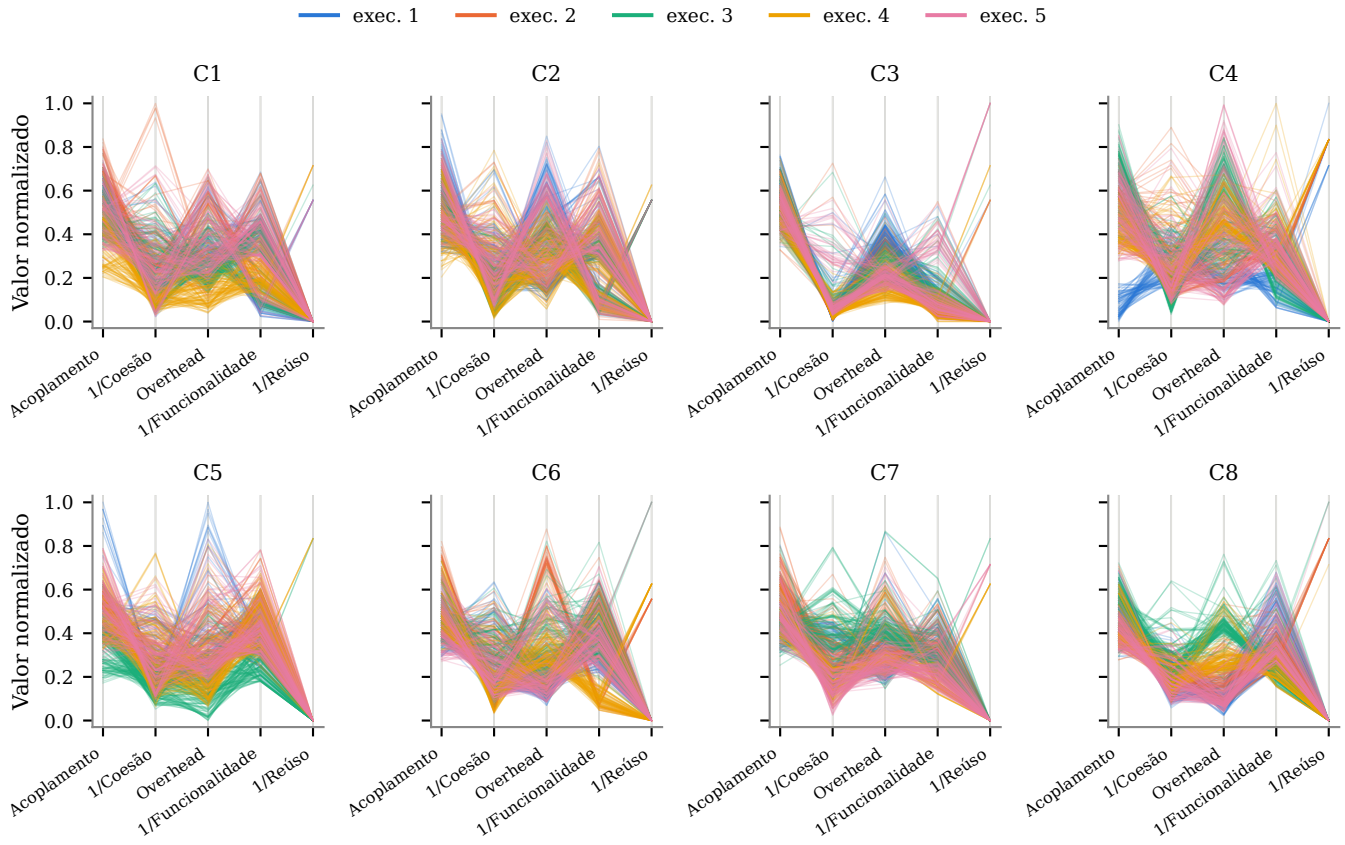


Figura 3. Fronteiras finais no Spring PetClinic em coordenadas paralelas (valores normalizados, em convenção de minimização). Cada linha representa uma solução; a cor indica a execução.

equivalência; indica apenas que, com o tamanho amostral disponível, um eventual efeito não foi detectado.

Nos demais contrastes de QP1, o efeito associado ao elitismo apresentou direções distintas conforme o sistema e a combinação dos demais fatores. Em C3 × C4 (R-NSGA-III com PENALTY), os tamanhos de efeito favoreceram o elitismo ligado no Spring PetClinic, mas o elitismo desligado no JPetStore, com efeitos grandes nos três indicadores. Em C5 × C6 (NSGA-III com KILL), os efeitos favoreceram predominantemente o elitismo desligado no Spring PetClinic, enquanto no JPetStore foram pequenos ou desprezíveis, com direção variável. Já em C7 × C8 (R-NSGA-III com KILL), o elitismo desligado foi favorecido em HV e ED no Spring PetClinic, enquanto o elitismo ligado foi favorecido nos três indicadores no JPetStore.

Esses resultados sugerem que o efeito associado ao elitismo pode depender do algoritmo, do tratamento de restrição e do sistema analisado. Entretanto, nenhum dos contrastes de QP1 apresentou significância estatística após a correção para múltiplas comparações no JPetStore, e os testes globais do Spring PetClinic não foram significativos. Portanto, não há evidências estatísticas suficientes para afirmar que habilitar ou desabilitar o elitismo produz uma melhoria consistente na qualidade das fronteiras finais.

QP2 (tratamento de restrição). Os resultados indicam que a estratégia de tratamento de restrição apresentou diferenças mais consistentes no JPetStore. Nos contrastes C1 × C5, C2 × C6 e C4 × C8, a estratégia PENALTY apresentou resultados mais favoráveis que KILL nos três indicadores, com efeitos grandes e diferenças estatisticamente significativas após a correção FDR-BH. No contraste C3 × C7, PENALTY também foi favorecida pelos tamanhos de efeito, embora sem significância estatística após a correção.

No Spring PetClinic, os resultados foram menos consistentes. PENALTY foi favorecida nos três indicadores em C1 × C5 e C3 × C7, mas os contrastes C2 × C6 e C4 × C8 apresentaram direções diferentes, com vantagem de KILL em alguns indicadores. Além disso, os testes globais não indicaram diferenças estatisticamente significativas nesse sistema.

Assim, para a QP2, os resultados fornecem evidências de que o tratamento PENALTY pode produzir fronteiras finais com indicadores de qualidade mais favoráveis que os de KILL em determinadas combinações no JPetStore. Essa vantagem, entretanto, não foi observada de forma consistente no Spring PetClinic, e os quatro contrastes de QP2 comparam execuções conduzidas por participantes diferentes, aspecto discutido nas ameaças à validade. Portanto, os resultados não sustentam

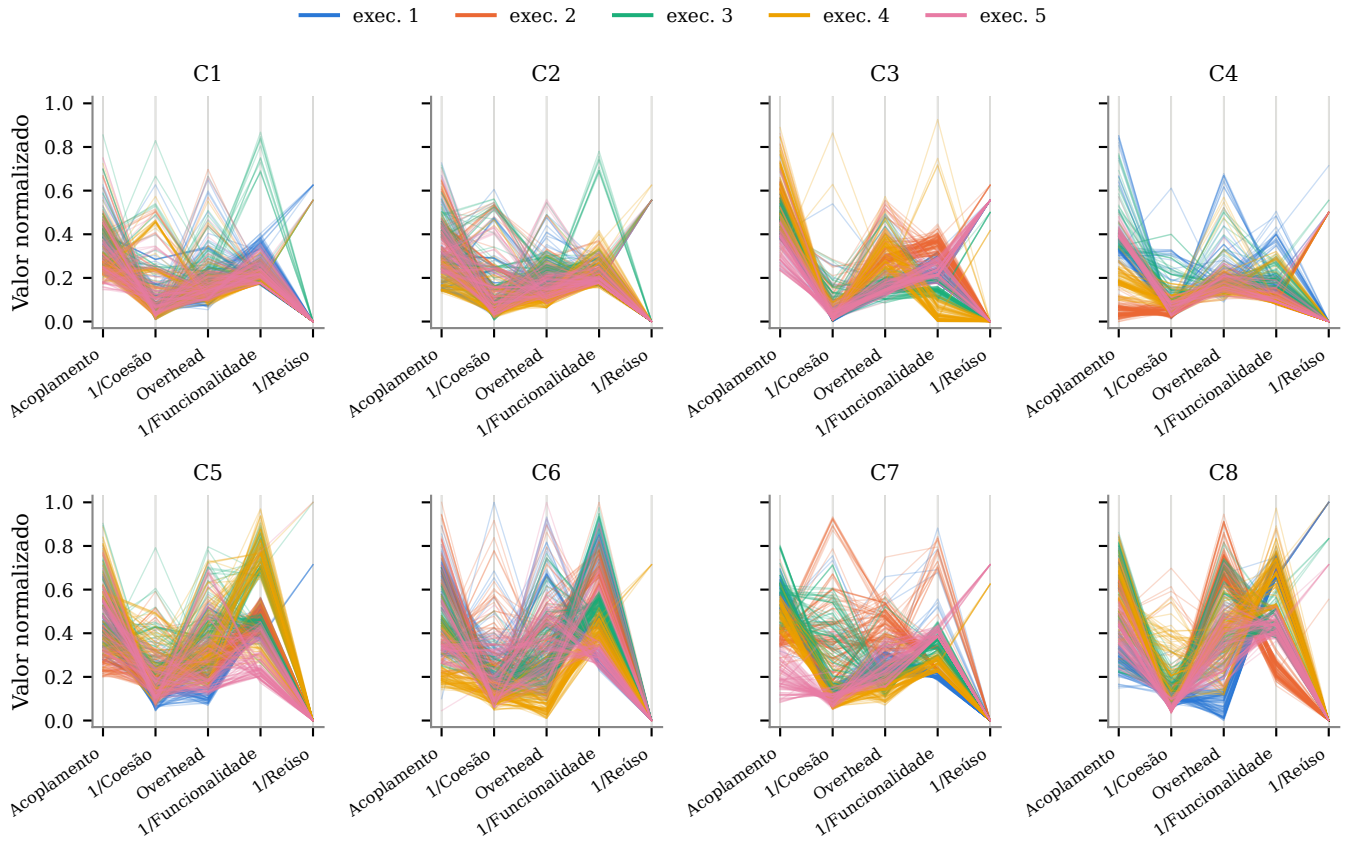


Figura 4. Fronteiras finais no JPetStore em coordenadas paralelas (valores normalizados, em convenção de minimização). Cada linha representa uma solução; a cor indica a execução.

a generalização de que PENALTY seja superior a KILL independentemente do sistema e dos demais fatores.

QP3 (R-NSGA-III). No par C1 × C3 (elitismo ligado, PENALTY), o efeito do R-NSGA-III variou conforme o sistema. No JPetStore, o R-NSGA-III apresentou valores menos favoráveis que o NSGA-III, com efeito grande nos três indicadores; as coordenadas paralelas sugerem que a diferença está associada principalmente ao acoplamento. No Spring PetClinic, o efeito também foi grande, porém a favor do R-NSGA-III. No JPetStore, a diferença não foi significativa após a correção para as 28 comparações e, no Spring PetClinic, o teste global não foi significativo, de modo que esses resultados devem ser interpretados como tendências indicadas pelo tamanho de efeito. Uma hipótese compatível com o funcionamento do algoritmo é que o R-NSGA-III concentra a busca em torno da preferência expressa pelo DM. Nesse caso, a qualidade da fronteira dependeria da região do espaço de objetivos em que se encontra a solução escolhida e modificada pelo DM. A maior proporção de soluções influenciadas pelo DM na população final de C3 no Spring PetClinic (93%, contra 43% a 50% em C1 e C2) é compatível com essa hipótese, mas o desenho do experimento não permite separar o efeito do algoritmo do efeito das decisões do DM.

Nos demais contrastes de QP3, os resultados também apresentaram variações entre os sistemas e as combinações dos fatores. Em C2 × C4 (elitismo desligado, PENALTY), o NSGA-III foi favorecido nos três indicadores do Spring PetClinic, com efeito grande para HV e pequeno para IGD+ e ED. No JPetStore, os efeitos foram pequenos ou desprezíveis, com direção variável entre os indicadores, não evidenciando uma vantagem consistente de um algoritmo.

No contraste C5 × C7 (elitismo ligado, KILL), os tamanhos de efeito favoreceram o R-NSGA-III nos dois sistemas. Entretanto, a magnitude variou entre os indicadores, com efeitos pequenos ou médios no Spring PetClinic e efeitos de desprezíveis a grandes no JPetStore.

Por fim, em C6 × C8 (elitismo desligado, KILL), os resultados do Spring PetClinic apresentaram efeitos desprezíveis para HV e IGD+, mas efeito grande favorável ao R-NSGA-III na ED. No JPetStore, o NSGA-III foi favorecido nos três indicadores, com efeitos grandes em HV e IGD+ e pequeno em ED.

Nenhum desses três contrastes apresentou significância estatística após a correção para múltiplas comparações no JPetStore. No Spring PetClinic, os testes globais não foram significativos. Assim, embora a direção do efeito varie em diferentes cenários, não foram identificadas evidências estatísticas suficientes para afirmar que o R-NSGA-III apresenta

qualidade de fronteira consistentemente superior ou inferior à do NSGA-III.

Ameaças à validade. Identificam-se as seguintes limitações. Primeiro, com $n = 5$ por grupo e 28 comparações por indicador, espera-se que poucos pares permaneçam significativos após a correção por múltiplas comparações. Segundo, a análise de qualidade avalia apenas a fronteira final, e não a convergência ao longo das gerações. Terceiro, a mesma persona foi executada por mais de uma pessoa, e as diferenças de critério entre os participantes, detalhadas a seguir, podem introduzir variabilidade. Quarto, o registro de justificativas das decisões não foi preenchido nas execuções. Por fim, os resultados valem para dois sistemas e uma persona, e não se generalizam diretamente a outros contextos.

As execuções de C1 a C3 acrescentam uma ameaça específica, relacionada ao modo de interação. No Spring PetClinic, C3 utilizou apenas divisões por seleção de métodos, enquanto C1 e C2 utilizaram sobretudo a divisão por conteúdo, que seleciona métodos por busca textual em toda a solução e pode incluir métodos de outros domínios pelo nome do pacote. Assim, parte da diferença entre C3 e as demais configurações nesse sistema pode estar associada à estratégia do DM, e não ao algoritmo. Além disso, em C1 $\times$ C3 no JPetStore, um efeito grande ($\hat{A}_{12} = 0{,}96$) não atingiu significância após a correção para 28 comparações, o que ilustra a primeira limitação.

Parte das execuções de C1 e C2 foi refeita após a realização das execuções de C3, devido à identificação de desvios em relação às regras estabelecidas para a persona e à adoção de um procedimento de interação mais rápido. Essa mudança pode introduzir diferenças na condução das execuções e afetar a comparabilidade entre configurações. Além disso, as sessões substituídas não foram preservadas, limitando a rastreabilidade e a possibilidade de auditoria desse procedimento.

Nas configurações C4 a C6, uma possível ameaça à validade interna está relacionada à condução das interações pelo DM. Embora as decisões tenham sido orientadas pela persona P3, a seleção das soluções candidatas e a aplicação dos operadores envolvem escolhas que podem introduzir variabilidade entre execuções. Além disso, a familiaridade adquirida com a ferramenta ao longo do experimento pode ter influenciado a condução das interações. A quantidade de divisões também variou entre as configurações, com 12, 17 e 23 operações no Spring PetClinic e 19, 25 e 16 no JPetStore, respectivamente para C4, C5 e C6. Essas diferenças dificultam distinguir completamente os efeitos dos mecanismos de otimização daqueles associados às intervenções do decisor.

A distribuição das execuções entre os participantes é uma ameaça à validade interna que afeta as três questões de pesquisa. Cada bloco de configurações foi conduzido por um participante diferente: um executou C1 a C3, outro executou C4 a C6 e um terceiro executou C7 e C8. Dessa forma, o participante muda junto com a configuração em parte dos contrastes de um fator. Os quatro contrastes de QP2 (C1 $\times$ C5, C2 $\times$ C6, C3 $\times$ C7 e C4 $\times$ C8) comparam execuções de participantes diferentes, inclusive os três pares com diferença significativa no JPetStore. O mesmo ocorre em C3 $\times$ C4, na QP1, e em C2 $\times$ C4, C5 $\times$ C7 e C6 $\times$ C8, na QP3. Somente C1 $\times$ C2, C5 $\times$ C6, C7 $\times$ C8 e C1 $\times$ C3 comparam execuções do mesmo participante. A vantagem de PENALTY observada no JPetStore pode, portanto, refletir também diferenças na forma como cada participante conduziu as interações, e o desenho adotado não permite separar esses dois efeitos. Há, contudo, uma comparação que mantém o participante fixo: C4, com PENALTY, e C5 e C6, com KILL, foram conduzidas pelo mesmo participante, e C4 apresentou valores mais favoráveis nos três indicadores do JPetStore, com diferenças significativas após a correção ($\hat{A}_{12}$ entre $0{,}84$ e $1{,}00$). Como esses pares também diferem no algoritmo e, em C4 $\times$ C5, no elitismo, o resultado não isola o tratamento de restrição, mas é compatível com a vantagem de PENALTY observada nos contrastes de um fator.

Os participantes também conduziram a mesma persona de formas diferentes. Na ferramenta, a coesão é minimizada internamente na forma $1/\text{valor}$, e a interface exibe esse valor armazenado, mas sinaliza as variações de coesão como se valores maiores fossem melhores. Nas execuções de C1 a C3, o participante interpretou os menores valores exibidos como maior coesão, o que constitui um desvio em relação à leitura da interface adotada nas demais configurações. As soluções escolhidas nas pausas confirmam essa diferença. Em C1 a C3, nos dois sistemas, a solução escolhida ficou, em mediana, entre os percentis 0,01 e 0,13 do valor armazenado de 1/Coesão na população, ou seja, entre as soluções de maior coesão. Em C4 a C7 e em C8 no Spring PetClinic, ficou entre os percentis 0,98 e 1,00, entre as soluções de menor coesão. Em C8 no JPetStore, o padrão foi intermediário (percentil mediano de 0,34). O critério de coesão da persona foi, portanto, aplicado em direções opostas entre os participantes. Essa divisão coincide em parte com a separação entre PENALTY e KILL, mas C4, conduzida com o mesmo critério de C5 e C6, obteve resultados mais favoráveis que essas configurações no JPetStore, o que indica que a divergência de interpretação não explica, isoladamente, a diferença observada na QP2.

Outros aspectos da condução também variaram entre os participantes (Tabela V). O participante de C1 a C3 aplicou de 19 a 23 divisões por sistema e configuração; o de C4 a C6, de 12 a 25; e o de C7 e C8, de 3 a 10. A divisão por conteúdo predominou em C1 e C2 no Spring PetClinic, enquanto C7 e C8 usaram apenas a divisão por seleção de métodos. O tempo ativo mediano variou de 2,6 minutos (C8 no Spring PetClinic) a 23,9 minutos (C6 no JPetStore). Essas diferenças indicam que a persona não padronizou completamente a condução das interações e reforçam a ameaça associada à distribuição das execuções entre participantes.

Os pacotes exportados também apresentam divergências entre o registro de eventos da interface (`behavioral_events.json`) e o registro das interações enviadas à busca (`interactions.json`). Em parte das pausas, o primeiro contém operações aplicadas pelo DM, enquanto o segundo registra a interação sem nenhuma modificação. Isso ocorreu em 6 das 15 pausas de C4 no JPetStore, em 2 das 15 pausas de C5 no JPetStore, em 6 e

12 das 15 pausas de C7 no Spring PetClinic e no JPetStore, respectivamente, e em 6 e 8 das 15 pausas de C8 nos mesmos sistemas. Em C1 a C3, em C6 e em C5 no Spring PetClinic, os dois registros coincidem, descontadas as operações desfeitas pelo DM. Há ainda o caso inverso em uma pausa de C4 no Spring PetClinic, que contém três divisões no registro de interações sem eventos correspondentes. A Tabela V considera apenas as operações do registro de interações, e os dados exportados não permitem determinar se as operações ausentes desse registro chegaram a modificar a população. Por isso, o comportamento do DM relatado para C4, C5, C7 e C8 pode estar subestimado, sobretudo em C7 e C8 no JPetStore.

Os registros apresentam ainda duas particularidades. Na execução 3 de C4 no Spring PetClinic, o tempo ativo foi de 127,6 minutos, enquanto as outras quatro execuções dessa configuração ficaram entre 5,6 e 21,2 minutos. Esse valor não altera a mediana apresentada na Tabela V, mas afetaria qualquer análise baseada na média do tempo ativo. Os pacotes de C7 e C8 também não incluem os arquivos `anomalies.json` e `backend.log`, presentes nas exportações de C1 a C6, o que impede verificar, nessas duas configurações, as anomalias registradas pela ferramenta.

VII. Conclusão

Este trabalho investigou a influência do elitismo, das estratégias de tratamento de restrição PENALTY e KILL e dos algoritmos NSGA-III e R-NSGA-III na qualidade das fronteiras finais produzidas pela ferramenta i-toMicroservices. Para isso, foram avaliadas oito configurações em dois sistemas, Spring PetClinic e JPetStore, considerando cinco execuções por configuração, conduzidas com base na persona P3.

Nas configurações C1 a C3, com PENALTY, não se observou efeito significativo do elitismo. O R-NSGA-III apresentou um efeito grande cuja direção variou conforme o sistema. Em relação ao NSGA-III, obteve valores menos favoráveis no JPetStore e mais favoráveis no Spring PetClinic, sem significância estatística após a correção para as 28 comparações no JPetStore e sem diferença global significativa no Spring PetClinic.

Considerando também as configurações C4 a C8, os resultados permitem abordar as três questões de pesquisa da seguinte forma. Para a QP1, o efeito associado ao elitismo variou conforme o sistema, o algoritmo e o tratamento de restrição. Os contrastes apresentaram diferentes direções de efeito, sem diferenças estatisticamente significativas após a correção para múltiplas comparações no JPetStore. No Spring PetClinic, os testes globais não foram significativos. Portanto, não foi demonstrado um benefício consistente do uso de elitismo.

Para a QP2, a estratégia PENALTY apresentou resultados mais favoráveis que KILL nos contrastes C1 $\times$ C5, C2 $\times$ C6 e C4 $\times$ C8 do JPetStore, com diferenças estatisticamente significativas nos três indicadores. No Spring PetClinic, os tamanhos de efeito apresentaram direções menos consistentes, sem significância nos testes globais. Esses contrastes, no entanto, comparam execuções de participantes diferentes. Assim, a diferença observada no JPetStore pode estar associada ao tratamento de restrição, mas não pode ser atribuída exclusivamente a ele, e os resultados não permitem generalizar a vantagem de PENALTY para outros cenários.

Para a QP3, a comparação entre NSGA-III e R-NSGA-III não apresentou diferenças estatisticamente significativas nos contrastes de um único fator avaliados no JPetStore. Os tamanhos de efeito variaram conforme o sistema e os demais fatores, sem uma direção consistente de vantagem para um dos algoritmos. No Spring PetClinic, os testes globais também não indicaram diferenças estatisticamente significativas.

Como trabalhos futuros, o experimento pode ser repetido com as demais personas e com outros sistemas-alvo, para verificar se a diferença entre PENALTY e KILL observada no JPetStore se repete em outros contextos. Em um novo desenho, cada participante deveria executar todas as configurações em ordem aleatória, o que permitiria separar o efeito do participante do efeito da configuração. Também se recomenda padronizar o modo de divisão usado pelo DM, pois a divisão por conteúdo e a divisão por seleção de métodos foram usadas em proporções diferentes entre as configurações (Tabela V). A análise pode ainda ser estendida à convergência, com o cálculo de HV, IGD+ e ED nos pontos de interação e não apenas na fronteira final. Por fim, um número maior de execuções por configuração reduziria a limitação imposta por $n = 5$ e pelas 28 comparações por indicador.

VIII. Sugestões de Melhorias

A. Melhorias na usabilidade

Durante as execuções do experimento, foram identificadas oportunidades de melhoria na interface da ferramenta i-toMicroservices. Na seleção de soluções candidatas, sugere-se a implementação de destaques visuais que identifiquem automaticamente as soluções com os valores mais favoráveis para cada objetivo, como maior coesão, menor acoplamento e menor overhead. A utilização de cores ou indicadores específicos poderia facilitar a comparação entre as candidatas, sem pressupor a existência de uma única solução superior em todos os objetivos.

Outra melhoria está relacionada à validação das operações de divisão de microsserviços. Atualmente, ao confirmar uma divisão sem movimentar métodos para o novo microsserviço, a ferramenta retorna à tela anterior e apresenta uma mensagem de erro. Recomenda-se impedir a confirmação enquanto nenhum método tiver sido transferido, por exemplo, desabilitando o botão de confirmação ou apresentando uma mensagem orientativa na própria interface. Essa alteração poderia tornar o processo de interação mais claro e reduzir interrupções durante a aplicação dos operadores.

Outra sugestão consiste em apresentar uma breve descrição da persona selecionada no launcher do estudo. Atualmente, a interface permite selecionar a persona, mas poderia exibir automaticamente suas principais características e regras de decisão em um painel informativo. Por exemplo, ao selecionar a persona P3 (Extrator de Domínio Veloz), seriam apresentados seu foco na extração rápida de domínios, a preferência pela

operação Dividir e a orientação de evitar as operações Unir e Congelar. Esse recurso facilitaria a consulta às regras durante a preparação das execuções e poderia contribuir para uma aplicação mais consistente das personas, reduzindo possíveis desvios de comportamento entre participantes.

B. Melhorias nas configurações dos algoritmos

Em todas as 80 execuções, o arquivo de parâmetros exportado registra a semente aleatória como nula (`seed: null`). Sem a semente, não é possível reproduzir uma execução específica nem controlar a variação estocástica ao comparar configurações. Sugere-se que a ferramenta gere uma semente quando o usuário não informar uma e a inclua no pacote exportado.

C. Melhorias nos indicadores e visualizações

Nas fronteiras finais das 80 execuções, 95,5% dos 10.506 pontos têm Reúso igual a 1,0, e o menor valor desse objetivo na população foi 1,0 em todas as gerações analisadas. Nessas condições, o Reúso contribui de forma limitada para diferenciar as soluções candidatas exibidas ao DM. Sugere-se que a interface informe a proporção de soluções com o mesmo valor em cada objetivo e permita ocultar objetivos constantes nas visualizações. Quanto aos registros, a ferramenta poderia gravar, para cada pausa, se o conjunto de operações aplicado pelo DM foi confirmado ou descartado, o que poderia reduzir as divergências entre os registros de eventos e de interações descritas nas ameaças à validade.

REFERÊNCIAS

[1] W. K. G. Assunção, T. E. Colanzi, L. Carvalho, A. Garcia, J. A. Pereira, M. J. de Lima, and C. Lucena, "Analysis of a many-objective optimization approach for identifying microservices from legacy systems," *Empirical Software Engineering*, vol. 27, no. 2, 2022, art. 51.

[2] L. Carvalho, T. E. Colanzi, W. K. G. Assunção, A. Garcia, J. A. Pereira, M. Kalinowski, R. M. de Mello, M. J. de Lima, and C. Lucena, "On the usefulness of automatically generated microservice architectures," *IEEE Trans. Softw. Eng.*, vol. 50, no. 3, pp. 651–667, 2024.

[3] J. Castanho, J. Gomes, T. E. Colanzi, A. M. M. M. Amaral, W. K. G. Assunção, and A. Garcia, "i-toMicroservices: Empowering architects in the interactive modernization of monolithic systems," in *Proc. Brazilian Symposium on Software Engineering (SBES)*, São Paulo, Brazil, 2026.

[4] J. Castanho, C. G. Britez, W. M. Freire, A. M. M. M. Amaral, T. E. Colanzi, and W. K. G. Assunção, "Human in the loop for microservice identification: An exploratory study," in *Proc. Brazilian Symposium on Software Components, Architectures, and Reuse (SBCARS)*, São Paulo, Brazil, 2026.

[5] W. M. Freire, C. Rosa, A. M. M. M. Amaral, and T. Colanzi, "Validating an interactive ranking operator for NSGA-II to support the optimization of software engineering problems," in *Proc. Brazilian Symposium on Software Engineering (SBES)*, 2022, pp. 337–346.

[6] L. Wolschick, P. C. Gonçalves, J. Choma Neto, W. M. Freire, A. M. M. M. Amaral, and T. E. Colanzi, "Evaluating the performance of NSGA-II and NSGA-III on product line architecture design," in *Proc. Brazilian Symposium on Software Components, Architectures, and Reuse (SBCARS)*, 2024, pp. 11–20.

[7] M. Harman, S. A. Mansouri, and Y. Zhang, "Search-based software engineering: Trends, techniques and applications," *ACM Comput. Surv.*, vol. 45, no. 1, 2012, art. 11.

[8] K. Deb and H. Jain, "An evolutionary many-objective optimization algorithm using reference-point-based nondominated sorting approach, part I: Solving problems with box constraints," *IEEE Trans. Evol. Comput.*, vol. 18, no. 4, pp. 577–601, 2014.

[9] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, "A fast and elitist multiobjective genetic algorithm: NSGA-II," *IEEE Trans. Evol. Comput.*, vol. 6, no. 2, pp. 182–197, 2002.

[10] A. Vargha and H. D. Delaney, "A critique and improvement of the CL common language effect size statistics of McGraw and Wong," *Journal of Educational and Behavioral Statistics*, vol. 25, no. 2, pp. 101–132, 2000.

[11] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B*, vol. 57, no. 1, pp. 289–300, 1995.